

Projektarbeit

lego::lab Karlsruhe: Schnittstellen zu externen Displays

im Studiengang
Informatik Master

vorgelegt von

Florian Kaiser
Matrikelnummer: 79728
kaf11018@h-ka.de

an der Hochschule Karlsruhe
am 28.09.2026

Prüfer: Uwe Haneke, Matthias Mruzek-Vering

ERKLÄRUNG

Hiermit erkläre ich, dass ich die vorliegende Arbeit eigenständig und ohne unerlaubte fremde Hilfe angefertigt habe. Textpassagen, die wörtlich oder dem Sinn nach auf Publikationen oder Vorträgen anderer Autoren beruhen, sind als solche kenntlich gemacht. Der Einsatz von KI-Werkzeugen erfolgte ausschließlich im Rahmen der nachstehenden Erklärung zur Nutzung von KI-Werkzeugen. Die Arbeit wurde bisher keiner anderen Prüfungsbehörde vorgelegt und auch noch nicht veröffentlicht.

Karlsruhe, 28.09.2026

Florian Kaiser

ERKLÄRUNG ZUR NUTZUNG VON KI-WERKZEUGEN

Bei der Erstellung dieser Arbeit wurden KI-Werkzeuge unterstützend eingesetzt, insbesondere für Teile des Programmcodes sowie für Textentwürfe. Alle inhaltlichen und konzeptionellen Entscheidungen, die Durchführung und Auswertung, die Überprüfung sämtlicher Ergebnisse sowie die endgültige Fassung des Textes wurden von den Autor:innen selbst erstellt und geprüft.

Bei der Nutzung wurden die allgemein anerkannten Standards guter wissenschaftlicher Praxis sowie die einschlägigen Vorgaben des Fachbereichs zum Umgang mit KI-generierten Inhalten beachtet. Jede wesentliche Behauptung wurde eigenständig auf Plausibilität und Richtigkeit geprüft und durch geeignete Quellen belegt. Es wurden keine personenbezogenen, urheberrechtlich geschützten oder vertraulichen Daten an die KI-Systeme übermittelt. Die eigenständige Leistung der Autor:innen ist durchgängig gewahrt.

Inhaltsverzeichnis

1	Einleitung	1
1.1	Problemstellung	1
1.2	Zielsetzung der Arbeit	1
1.3	Aufbau der Arbeit	2
2	Grundlagen und verwandte Arbeiten	2
2.1	Entfernter Prozeduraufruf und Middleware	3
2.2	Serialisierung von Nachrichten	3
2.3	Eingebettete Systeme und ihre Kommunikation	4
2.4	Einordnung und Auswahlkriterien	5
2.5	Etablierte Rahmenwerke für entfernte Aufrufe	5
2.6	Serialisierung für ressourcenarme Geräte	6
2.7	Protokolle für eingebettete Systeme und Sensornetze	6
2.8	Der betrachtete Bus und PUPRemote als Transportbasis	7
2.9	Abgrenzung	8
3	Systemanalyse und Anforderungen	8
3.1	Zielsystem und Hardwareumgebung	9
3.1.1	Der LEGO Education SPIKE Prime Hub als Ausgangsplattform	9
3.1.2	Notwendigkeit einer externen Erweiterung	9
3.2	Anforderungen an die Display-Integration	10
3.2.1	Anforderungen an ein externes Display	10
3.2.2	Anforderungen an einen externen Mikrocontroller	10
3.2.3	Resultierende Systemstruktur	10
3.3	Kommunikationsanforderungen	11
3.4	Einschränkungen der Plattform	11
3.4.1	Eingeschränkte Kommunikationsrichtung	12
3.4.2	Begrenzte Paketgröße	12
3.4.3	Beschränkte Laufzeitumgebung	12
3.4.4	Wechselwirkung der Einschränkungen	13
3.5	Verallgemeinerung des Problemraums	13
4	Architektur des Systems	14
4.1	Zielsetzung der Architektur	15
4.2	Schichtenmodell	15
4.2.1	Busanbindung	16
4.2.2	Transportschicht	16
4.2.3	Kommunikationsschicht	16
4.2.4	Objektmodell	17
4.2.5	Anwendung und Anzeige	17

4.3	Rollen im Entwurf	17
4.3.1	Interceptor	17
4.3.2	Dispatcher	17
4.3.3	Stellvertreter und Adapter	18
4.4	Kommunikationsmodell	18
4.5	Datenfluss im System	18
5	Entwurf von Transport- und Kommunikationsschicht	18
5.1	Motivation und Randbedingungen	19
5.2	Transportschicht	19
5.2.1	Interceptor-Abstraktion	20
5.2.2	Frame-Struktur	21
5.2.3	Nutzlastlänge und Formatunabhängigkeit	22
5.2.4	Kosten der Rahmung	22
5.2.5	Fragmentierung und Rekonstruktion	23
5.2.6	Serialisierung	24
5.2.7	Zuverlässigkeitsmechanismen	24
5.3	Kommunikationsschicht	25
5.3.1	Aufbau einer Aufrufnachricht	26
5.3.2	Zuordnung von Anfrage und Antwort	26
5.3.3	Verteilung eingehender Aufrufe	26
5.3.4	Anfragegetriebener Rückkanal	27
6	Referenzimplementierung	27
6.1	Laufzeitumgebung	28
6.2	Hardwareaufbau	29
6.2.1	Aufbau und Komponenten	29
6.2.2	Signalzuordnung und Aufbau der Adapterplatine	29
6.3	Busanbindung	30
6.4	Transportschicht	31
6.4.1	Frame	31
6.4.2	Message	32
6.4.3	Serialisierung	33
6.5	Kommunikationsschicht	34
6.5.1	Aufrufnachricht	35
6.5.2	Verteilung eingehender Aufrufe	36
6.5.3	Rückkanal	36
6.6	Objektmodell	37
6.6.1	Referenzen	38
6.6.2	Lebenszyklus	39
6.6.3	Veraltete Referenzen	39
6.6.4	Erweiterung um einen Objekttyp	40

6.7	Ansteuerung der Anzeige	40
6.8	Ablauf eines vollständigen Aufrufs	41
6.9	Nebenläufigkeit und Fehlerbehandlung	42
6.9.1	Nebenläufigkeit	42
6.9.2	Fehlerbehandlung	43
7	Evaluation	43
7.1	Funktionaler Nachweis	44
7.2	Übertragungsaufwand	45
7.3	Reaktionszeit einer Berührung	46
7.4	Ressourcenverbrauch	47
7.5	Bewertung des Hardwareaufbaus	47
7.6	Diskussion der Ergebnisse	48
8	Fazit und Ausblick	48
8.1	Limitierungen	49
8.1.1	Kommunikationsmodell	49
8.1.2	Latenz und Durchsatz	49
8.1.3	Abstraktionsgrenzen	49
8.2	Übertragbarkeit auf andere Verbindungsklassen	50
8.3	Mögliche Erweiterungen	50
8.3.1	Ergebnis mit der Bestätigung	50
8.3.2	Ereignisgetriebener Rückkanal	51
8.3.3	Alternative Serialisierung	51
8.3.4	Integrierter Hardwareaufbau	51
8.3.5	Weitere Peripherieklassen	52
8.4	Zusammenfassung	52
9	Abbildungs- und Tabellenverzeichnis	54
10	Abkürzungsverzeichnis	55
	Bibliografie	56
	Anhang	58

1 Einleitung

Die Vermittlung von Informatik- und Technikenntnissen an Kinder und Jugendliche gewinnt zunehmend an Bedeutung. Plattformen wie die Education-Systeme von LEGO bieten hierfür einen niedrighschwelligen Einstieg in Programmierung und Robotik. Durch vereinfachte Hardware und abstrahierte Softwareumgebungen sind erste praktische Erfahrungen auch ohne umfangreiche Vorkenntnisse möglich.

Mit zunehmender Nutzung entsteht häufig der Wunsch, solche Systeme über ihren ursprünglichen Funktionsumfang hinaus zu erweitern. Insbesondere zusätzliche Hardwarekomponenten eröffnen neue Möglichkeiten, etwa bei der Visualisierung und der Interaktion. Displays mit Touch-Funktionalität sind in diesem Zusammenhang eine naheliegende Erweiterung, da sie eine direkte und intuitive Bedienung ermöglichen.

Die Erweiterung bestehender Embedded-Systeme um externe Komponenten ist allerdings nicht trivial. Neben der reinen Hardwareanbindung spielen vor allem die Kommunikation und die Integration in die bestehende Software eine wichtige Rolle. Die beteiligten Komponenten müssen koordiniert zusammenarbeiten, wobei die vorhandenen Schnittstellen und Laufzeitumgebungen oft Einschränkungen mit sich bringen.

Vor diesem Hintergrund beschäftigt sich die vorliegende Arbeit mit der Frage, wie sich externe Peripherie an ein solches System anbinden lässt, wenn die verfügbare Verbindung dafür nur eingeschränkt geeignet ist. Im Mittelpunkt steht dabei weniger die Ansteuerung eines einzelnen Geräts als eine Softwareschicht, die zwischen Anwendung und Verbindung vermittelt und die Eigenheiten der Übertragung vor der Anwendung verbirgt. Als Anwendungsfall dient die Anbindung eines **Thin-Film-Transistor (TFT)**-Touchscreen-Displays, an dem der Entwurf entwickelt, umgesetzt und bewertet wird.

1.1 Problemstellung

Die Anbindung zusätzlicher Peripherie an eine solche Plattform wird durch drei technische Einschränkungen erschwert, die gemeinsam auftreten und sich gegenseitig verstärken.

Erstens ist die Verbindung zwischen den Systemkomponenten anfragegetrieben. Sie ist zwar in beide Richtungen nutzbar, eine Übertragung kann aber nur die übergeordnete Seite anstoßen, während die untergeordnete Seite ausschließlich antwortet. Zweitens ist die je Paket übertragbare Datenmenge sehr klein und fest vorgegeben, sodass Nachrichten üblicher Größe nicht in ein einzelnes Paket passen. Drittens stehen stark beschränkte Laufzeitumgebungen zur Verfügung, die zumindest auf einer Seite weder einen vollständigen Netzwerkstack noch die üblichen Mittel nebenläufiger Programmierung bereitstellen.

Diese Rahmenbedingungen stehen im Gegensatz zu den Anforderungen interaktiver Benutzeroberflächen, die eine flexible Übertragung strukturierter Daten und eine zeitnahe Rückmeldung von Benutzereingaben voraussetzen. Gerade die Verarbeitung von Eingaben und die Übertragung zusammengesetzter Zustände sind unter diesen Bedingungen eine Herausforderung.

Daraus ergibt sich die zentrale Problemstellung dieser Arbeit: Wie lässt sich eine Middleware entwerfen, die entfernte Objekte über eine anfragegetriebene Verbindung mit sehr kleiner Paketgröße auf beschränkten Laufzeitumgebungen transparent nutzbar macht?

Die Frage ist dabei nicht an eine bestimmte Plattform gebunden, denn die Kombination aus anfragegetriebener Übertragung, kleiner Paketgröße und beschränkter Laufzeitumgebung tritt in verschiedenen Ausprägungen auf, wie Abschnitt 3.5 zeigt.

1.2 Zielsetzung der Arbeit

Ziel dieser Arbeit ist der Entwurf einer Middleware, die entfernte Objekte über eine Verbindung der beschriebenen Art transparent nutzbar macht.

Der Entwurf soll die drei genannten Einschränkungen auf wenige Schichten eingrenzen, sodass sie oberhalb davon nicht mehr sichtbar sind. Dazu gehören:

- die Zerlegung von Nachrichten in Pakete und deren Rahmung,
- ein anfragegetriebener Rückkanal für Ergebnisse und Ereignisse
- sowie eine Abstraktion, die entfernte Objekte wie lokale erscheinen lässt.

Ein weiterer Schwerpunkt liegt darauf, den Entwurf vom konkreten Übertragungsweg zu lösen, damit er auf andere Verbindungen derselben Klasse übertragbar bleibt.

Die Bewertung stützt sich auf drei Kriterien. Das erste ist der funktionale Nachweis, dass sich eine interaktive Oberfläche über die entwickelte Abstraktion umsetzen lässt. Das zweite ist der Übertragungsaufwand je Aufruf, gemessen in benötigten Paketen und in der daraus folgenden Verzögerung. Das dritte ist der Ressourcenverbrauch, vor allem auf der Steuereinheit, deren Laufzeitumgebung am stärksten eingeschränkt ist.

1.3 Aufbau der Arbeit

Die vorliegende Arbeit ist wie folgt aufgebaut.

Kapitel 2 führt die Grundlagen zum entfernten Prozeduraufruf, zur Serialisierung und zur Kommunikation eingebetteter Systeme ein. Anschließend ordnet es die Arbeit in bestehende Ansätze ein und benennt die Lücke, die sie schließt.

Kapitel 3 analysiert das Zielsystem und leitet die Anforderungen an die Display-Integration und an die Kommunikation ab. Den Anforderungen werden die Einschränkungen der Plattform gegenübergestellt, bevor das Kapitel mit einer Verallgemeinerung des Problemraums schließt.

Kapitel 4 beschreibt die Architektur mit ihrem Schichtenmodell, den wiederkehrenden Rollen im Entwurf und dem Kommunikationsmodell. Kapitel 5 vertieft den Entwurf der Transport- und der Kommunikationsschicht, wobei beide Kapitel auf der konzeptionellen Ebene bleiben.

Kapitel 6 stellt die Referenzimplementierung vor und bildet den Entwurf auf die konkrete Hardware, die Laufzeitumgebungen und den Bus ab. Kapitel 7 bewertet die Lösung hinsichtlich Funktionalität, Übertragungsaufwand und Ressourcenverbrauch. Kapitel 8 diskutiert die Grenzen des Ansatzes und seine Übertragbarkeit auf andere Verbindungen und fasst die Ergebnisse zusammen. Der Anhang enthält das Beispielprogramm der Steuereinheit und den Schaltplan der Adapterplatine.

2 Grundlagen und verwandte Arbeiten

Die in dieser Arbeit entwickelte Middleware baut auf bekannten Ansätzen für entfernte Aufrufe und für die Kommunikation in verteilten und eingebetteten Systemen auf. Die ersten drei Abschnitte führen die Begriffe ein, die in den Entwurfskapiteln benötigt werden. Anschließend wird die eigene Lösung in dieses Umfeld eingeordnet. Da das Feld sehr breit ist, werden ausgewählte Vertreter betrachtet und anhand einheitlicher Kriterien verglichen. Ziel ist es, die Lücke zu benennen, die die vorliegende Arbeit schließt.

2.1 Entfernter Prozeduraufruf und Middleware

Bei einem entfernten Prozeduraufruf, englisch [Remote Procedure Call \(RPC\)](#), ruft ein Programm eine Prozedur auf, die auf einem anderen Rechner ausgeführt wird. Im Quelltext sieht dieser Aufruf wie ein gewöhnlicher lokaler Aufruf aus. Die Idee wurde von Birrell und Nelson beschrieben und bildet seitdem die Grundlage der meisten Middleware-Systeme [1]. Der Aufruf wird auf der aufrufenden Seite von einem Stellvertreter entgegengenommen, der dieselbe Signatur besitzt wie die eigentliche Prozedur, sie aber nicht ausführt. Er verpackt den Namen der Prozedur und die Argumente zu einer Nachricht und übergibt sie dem Transport. Auf der ausführenden Seite nimmt ein Gegenstück die Nachricht entgegen, liest die Argumente aus, ruft die eigentliche Prozedur auf und schickt deren Rückgabewert zurück. Dieses Gegenstück wird klassisch als Skelett bezeichnet. Das Umwandeln von Argumenten und Rückgabewerten in eine übertragbare Form heißt Marshalling.

Das Ziel dieses Aufbaus ist die Aufrufstransparenz. Der Aufrufer soll nicht wissen müssen, ob eine Prozedur lokal oder entfernt ausgeführt wird. Vollständig erreichen lässt sich das allerdings nicht. Ein entfernter Aufruf dauert um Größenordnungen länger als ein lokaler, er kann teilweise fehlschlagen, während der Aufrufer weiterläuft, und Zeiger in den lokalen Speicher haben auf der Gegenseite keine Bedeutung. Waldo et al. zeigen, dass sich diese Unterschiede nicht dauerhaft verbergen lassen und in der Schnittstelle sichtbar bleiben sollten [2]. Transparenz wird deshalb meist als Aussage über die Aufrufsyntax verstanden und weniger als Zusicherung gleicher Laufzeiteigenschaften.

Die Schicht, die Stellvertreter, Marshalling und Transport bereitstellt, wird als Middleware bezeichnet. Sie liegt zwischen der Anwendung und der Verbindung, bietet der Anwendung eine einheitliche Schnittstelle an und verbirgt die Eigenheiten der Übertragung [3]. Ein häufig verwendeter Aufbau für solche Systeme ist das Broker-Muster. Es beschreibt den Stellvertreter auf der Client-Seite, den vermittelnden Broker und das Gegenstück auf der Server-Seite als eigenständige Rollen [4].

Der ursprüngliche Ansatz kennt nur einen festen Satz von Prozeduren. Objektorientierte Middleware erweitert ihn auf entfernte Objekte, die zur Laufzeit entstehen und über eine Referenz angesprochen werden. Der Stellvertreter entspricht dann dem Proxy-Muster [5]. Er implementiert dieselbe Schnittstelle wie das entfernte Objekt, führt dessen Referenz mit und gibt jeden Aufruf zusammen mit dieser Referenz weiter. Bekannte Vertreter dieses Ansatzes sind [Common Object Request Broker Architecture \(CORBA\)](#) [6] und Java [Remote Method Invocation \(RMI\)](#) [7]. Die Aufteilung in einen Stellvertreter auf der aufrufenden und ein Gegenstück auf der ausführenden Seite findet sich in Abschnitt 4 wieder, wo das Gegenstück als Adapter bezeichnet wird.

2.2 Serialisierung von Nachrichten

Eine Nachricht liegt im Programm als strukturierter Wert vor, etwa als Objekt, als Liste oder als Abbildung. Übertragen wird dagegen eine Folge von Bytes. Die interne Darstellung eines Werts im Arbeitsspeicher lässt sich dafür nicht direkt verwenden, da sie Verweise enthält und von Wortbreite, Byte-Reihenfolge und Laufzeitumgebung abhängt. Serialisierung bezeichnet die Umwandlung eines strukturierten Werts in eine Bytefolge, Deserialisierung den umgekehrten Weg.

Die gebräuchlichen Formate unterscheiden sich vor allem in zwei Punkten. Der erste ist die Kodierung. Textbasierte Formate wie die [JavaScript Object Notation \(JSON\)](#) oder [Extensible Markup Language \(XML\)](#) sind ohne Werkzeuge lesbar und erleichtern damit die Fehlersuche, benötigen aber mehr Platz, weil Schlüssel und Strukturzeichen als Klartext mit übertragen werden. Binäre Formate stellen dieselben Werte deutlich kürzer dar, ihre Ausgabe ist ohne Kenntnis des Formats jedoch nicht mehr zu deuten. Der zweite Punkt ist die Bindung an ein Schema. Schemafreie Formate führen die Struktur in der Nachricht selbst mit, sodass Sender und Empfänger nichts vorab vereinbaren müssen. Schemagebundene Formate setzen eine geteilte Beschreibung der Datenstruktur voraus und sparen dafür die Feldnamen in der Nachricht ein. Welche Vertreter für ein Gerät mit sehr kleinen Paketen in Frage kommen, behandelt Abschnitt 2.6.

Für diese Arbeit ist eine weitere Eigenschaft binärer Formate wichtig, denn ihre Ausgabe kann jedes beliebige Byte enthalten, auch das Nullbyte. Ein Empfänger kann die Länge der Nutzlast deshalb nicht aus dem Inhalt ableiten, etwa indem er Nullbytes am Ende eines Pakets als Füllung abschneidet, sodass die Rahmung die Länge ausdrücklich mitführen muss. Bei einem textbasierten Format fällt dieser Unterschied nicht auf, da dessen Ausgabe kein Nullbyte enthält, und er zeigt sich erst beim Wechsel auf eine binäre Kodierung. Abschnitt 5.2.3 greift das auf.

2.3 Eingebettete Systeme und ihre Kommunikation

Eingebettete Systeme verfügen über erheblich weniger Speicher und Rechenleistung als ein Arbeitsplatzrechner. [Request for Comments \(RFC\) 7228](#) fasst solche Geräte unter dem Begriff *constrained nodes* zusammen und ordnet sie nach verfügbarem Arbeits- und Programmspeicher in Klassen ein [8]. Die betrachteten Größenordnungen liegen bei einigen zehn bis einigen hundert Kilobyte Arbeitsspeicher. In diesem Rahmen werden Entwurfsentscheidungen wichtig, die auf einem gewöhnlichen Rechner kaum eine Rolle spielen.

Auf solchen Geräten kommen angepasste Laufzeitumgebungen zum Einsatz, beispielsweise MicroPython als eine für Mikrocontroller ausgelegte Implementierung von Python [9]. Der Sprachkern bleibt dabei weitgehend erhalten, während die Standardbibliothek stark verkleinert ist und ihr Umfang vom jeweiligen Port abhängt. Auf stark beschränkter Hardware fehlen zudem häufig ein vollständiger Netzwerkstack und die üblichen Mittel nebenläufiger Programmierung. Ohne Netzwerkstack stehen auch die darauf aufbauenden Abstraktionen von Sockets bis zu fertigen Protokollbibliotheken nicht zur Verfügung, und ohne Nebenläufigkeit gibt es keinen Hintergrundprozess, der Daten entgegennimmt, während die Anwendung weiterläuft. Hinzu kommt der kleine Heap, bei dem jede Zuweisung den Druck auf die Speicherbereinigung erhöht, weshalb Puffer nach Möglichkeit vorab angelegt und wiederverwendet werden.

Die Verbindung zwischen einem Mikrocontroller und seiner Peripherie erfolgt über Bussysteme, die für kurze Strecken und wenige Leitungen ausgelegt sind. Viele von ihnen arbeiten nach dem Master-Slave-Prinzip. Eine Seite, der Master, stößt jede Übertragung an, die andere Seite antwortet ausschließlich. [Inter-Integrated Circuit \(I2C\)](#) [10] und [Serial Peripheral Interface \(SPI\)](#) [11] sind verbreitete Vertreter, auf Feldebene folgt Modbus im [Remote Terminal Unit \(RTU\)](#)-Modus demselben Muster [12]. Ein Slave, bei dem Daten anfallen, kann diese nicht von sich aus schicken. Er hält sie bereit, bis der Master sie abfragt. Dieses wiederholte Abfragen wird als Polling bezeichnet. Wie schnell ein Ereignis auf der Slave-Seite beim Master ankommt, hängt damit vom Abfragetakt des Masters ab und nicht vom Zeitpunkt, an dem es entstanden ist.

Die je Übertragung nutzbare Datenmenge ist auf solchen Bussen klein und häufig fest vorgegeben. Die größte in einem Paket übertragbare Nutzlast wird als [Maximum Transmission Unit \(MTU\)](#) bezeichnet. Ist eine Nachricht länger, muss sie in mehrere Pakete zerlegt werden. Damit der Empfänger sie wieder zusammensetzen kann, trägt jedes Paket zusätzliche Steuerinformationen, die üblicherweise als Header vorangestellt werden. Diese Steuerinformationen gehen von der ohnehin knappen Nutzlast ab, sodass ihre Größe bei kleinen Paketen unmittelbar auf die Anzahl der nötigen Übertragungen durchschlägt. Wie sich diese Eigenschaften am betrachteten Zielsystem konkret darstellen, zeigt Abschnitt 3.4.

2.4 Einordnung und Auswahlkriterien

Für den Vergleich werden Kriterien herangezogen, die sich direkt aus den Rahmenbedingungen des Zielsystems ergeben. Das Zielsystem nutzt einen Master-Slave-Bus mit sehr kleinen, festen Paketen und läuft in stark eingeschränkten Laufzeitumgebungen.

Folgende Achsen werden betrachtet:

- **Abstraktionsgrad.** Bietet der Ansatz nur den Transport von Nachrichten, einen entfernten Prozeduraufruf oder darüber hinaus die Abstraktion entfernter Objekte?
- **Serialisierung.** Werden Daten textbasiert oder binär kodiert, und ist dafür ein vorab geteiltes Schema nötig?
- **Transportbindung.** Ist der Ansatz an einen konkreten Übertragungsweg gebunden oder von diesem unabhängig?
- **Fragmentierung.** Bringt der Ansatz Mechanismen für die Rahmung und das Zerlegen großer Nachrichten in kleine Pakete mit?
- **Eignung für einen Master-Slave-Bus.** Setzt der Ansatz voraus, dass die untergeordnete Seite eigenständig senden kann, oder kommt er mit einem rein anfragegetriebenen Kanal aus?
- **Ressourcenbedarf.** Lässt sich der Ansatz innerhalb der Grenzen von MicroPython und Pybricks betreiben?

Die betrachteten Ansätze liegen dabei nicht alle auf derselben Ebene, denn einige sind vollständige Rahmenwerke, andere beschränken sich auf die Beschreibung eines Nachrichtenformats, und wieder andere behandeln lediglich die Kodierung von Daten oder die Anbindung an einen bestimmten Bus. Ein Vergleich, der diese Unterschiede außer Acht lässt, stellt somit Ansätze nebeneinander, die sich gegenseitig gar nicht ersetzen können. Im abschließenden Vergleich wird die Ebene deshalb in einer eigenen Spalte ausgewiesen.

Diese Kriterien strukturieren die folgende Betrachtung und münden in den abschließenden Vergleich in Tabelle I.

2.5 Etablierte Rahmenwerke für entfernte Aufrufe

Entfernte Prozeduraufrufe wurden früh standardisiert. Der [Open Network Computing Remote Procedure Call \(ONC RPC\)](#) [13], [14] legt ein Protokoll und mit der External Data Representation ein eigenes Serialisierungsformat fest [15]. Der Ansatz ist auf leistungsfähigere Netzwerke ausgelegt und nicht für Kanäle mit Paketgrößen im Bereich weniger Byte gedacht.

JSON-RPC verfolgt eine deutlich schlankere Idee [16], da die Spezifikation ausschließlich das Format der Anfrage- und Antwortnachrichten auf Basis der [JSON](#) beschreibt und den Transport bewusst der Anwendung überlässt. Diese Trennung ist dem hier verfolgten Ansatz ähnlich, allerdings setzt JSON-RPC voraus, dass eine darunterliegende Schicht vollständige Nachrichten zustellen kann. Es definiert weder eine Rahmung noch eine Fragmentierung für sehr kleine Pakete und sieht keinen Mechanismus für einen anfragegetriebenen Rückkanal auf einem Master-Slave-Bus vor.

Am anderen Ende des Spektrums steht [gRPC Remote Procedure Call \(gRPC\)](#) [17]. Das Rahmenwerk verbindet Protocol Buffers als schemagebundene Serialisierung mit [Hypertext Transfer Protocol \(HTTP\)/2](#) als Transport und unterstützt unter anderem Datenströme in beide Richtungen. Diese Leistungsfähigkeit erfordert jedoch einen vollständigen [HTTP/2](#)-Stack und setzt eine bidirektionale Verbindung voraus. Für den betrachteten LEGO-Bus und die eingesetzten Laufzeitumgebungen ist [gRPC](#) zu schwergewichtig und zu stark an seinen Transport gebunden.

Zusammengefasst setzen die etablierten Rahmenwerke entweder einen leistungsfähigen Transport voraus oder standardisieren nur die Nachrichtenebene. Rahmung, Fragmentierung und der Rückkanal bleiben dann offen, und genau diese darunterliegende Schicht behandelt die vorliegende Arbeit.

2.6 Serialisierung für ressourcenarme Geräte

Da die Serialisierung die Nachrichtengröße und damit die Anzahl der nötigen Pakete bestimmt, ist sie für ein System mit kleinen Paketen besonders relevant. Die [JSON](#) ist schemafrei und gut lesbar, erzeugt aber durch Klartextschlüssel und Strukturzeichen vergleichsweise große Ausgaben [18]. Binäre und schemafreie Formate wie MessagePack [19] und die [Concise Binary Object Representation \(CBOR\)](#) [20], [21] erreichen bei gleichem Datenmodell deutlich kompaktere Darstellungen. Schemagebundene Formate wie Protocol Buffers gehen noch einen Schritt weiter und setzen eine geteilte Beschreibung der Datenstruktur voraus [22]. Für sehr kleine Geräte existiert mit Nanopb [23] eine ressourcenschonende Implementierung dieses Ansatzes.

In der vorliegenden Arbeit wurde zunächst die [JSON](#) verwendet, wofür es zwei praktische Gründe gab. Zum einen steht das Format in beiden Laufzeitumgebungen ohne zusätzliche Abhängigkeit zur Verfügung, zum anderen ist die Nutzlast im Klartext lesbar. Auf einem Bus, dessen Datenverkehr sich nur mit erheblichem Aufwand mitschneiden lässt, stellt das bei der Fehlersuche einen deutlichen Vorteil dar. Solange die übrigen Schichten noch entwickelt wurden, war diese Lesbarkeit wichtiger als eine kompakte Kodierung.

Mit zunehmender Reife der Umsetzung änderte sich diese Gewichtung. Bei einer Nutzlast von wenigen Byte je Paket wirkt sich jedes zusätzliche Zeichen direkt auf die Anzahl der zu übertragenden Pakete und damit auf die Dauer eines Aufrufs aus. Im weiteren Verlauf wurde deshalb auf MessagePack [19] gewechselt. Das Format bildet dasselbe Datenmodell ab, kommt ebenfalls ohne vorab geteiltes Schema aus und stellt die Daten binär und damit deutlich kürzer dar. Die Lesbarkeit geht dabei verloren. Sie lässt sich bei der Fehlersuche aber zurückgewinnen, indem auf die textbasierte Kodierung umgeschaltet wird, da beide Formate hinter derselben Schnittstelle liegen.

Das Kodieren und Dekodieren der Nutzlast ist dafür an einer einzigen Stelle gebündelt. Ein Wechsel der Kodierung betrifft diese Stelle und die Rahmung, die dafür eine ausdrückliche Längenangabe je Paket benötigt. Der entfernte Aufruf und das Objektmodell bleiben unverändert, und der beschriebene Wechsel zeigt, dass diese Trennung in der Praxis funktioniert. Die Evaluation vergleicht beide Kodierungen und gibt den Overhead in benötigten Paketen je Aufruf an.

2.7 Protokolle für eingebettete Systeme und Sensornetze

Neben den allgemeinen Rahmenwerken existieren Protokolle, die näher an der betrachteten Domäne liegen. Firmata [24] ermöglicht die Steuerung eines Mikrocontrollers von einem übergeordneten Rechner aus und überträgt dazu einen festgelegten Satz von Befehlen über eine serielle Verbindung. Die Aufteilung in einen steuernden Rechner und ein reagierendes Gerät ähnelt der hier vorliegenden Situation. Firmata beschränkt sich allerdings auf einen vordefinierten Befehlsumfang und bietet weder einen allgemeinen entfernten Aufruf noch eine Abstraktion entfernter Objekte.

[Message Queuing Telemetry Transport \(MQTT\)](#) [25] ist auf ressourcenarme Geräte und kleine Pakete ausgelegt und kommt ohne eine durchgehende [Transmission Control Protocol \(TCP\)](#)-Verbindung aus. Es folgt jedoch einem Modell aus Veröffentlichen und Abonnieren, benötigt ein Gateway sowie einen Vermittler und setzt voraus, dass das Gerät eigenständig veröffentlichen kann. Auf einem reinen Master-Slave-Bus, auf dem die untergeordnete Seite nicht von sich aus senden darf, ist dieses Modell nicht unmittelbar anwendbar.

Näher am hier betrachteten Problem liegen Protokolle, die eine Nachricht über mehrere kleine Pakete hinweg übertragen und dabei ohne eine darunterliegende Transportschicht auskommen. Das Transportprotokoll ISO 15765-2, im Fahrzeugbereich als ISO-TP bekannt, überträgt Nachrichten von bis zu 4095 Byte über CAN-Rahmen mit acht Byte Nutzlast [26]. Es nummeriert die Folgerahmen fortlaufend und lässt den Empfänger im Flusskontrollrahmen angeben, wie viele Rahmen er am Stück annimmt. Die Aufgabenstellung entspricht damit

weitgehend der Rahmung und Fragmentierung dieser Arbeit, allerdings bleibt ISO-TP auf den Transport beschränkt und kennt weder Aufrufe noch entfernte Objekte.

Ein ähnliches Vorgehen findet sich in CANopen, wo das Service Data Object Datensätze segmentiert überträgt, die größer sind als ein einzelner CAN-Rahmen [27]. Dort wird zudem jeder Segmentabschnitt einzeln bestätigt, was dem Stop-and-Wait dieser Arbeit entspricht. Die adressierten Daten sind jedoch Einträge eines vorab festgelegten Objektverzeichnisses und keine zur Laufzeit erzeugten Objekte mit eigenen Methoden.

Im Umfeld ressourcenarmer Geräte löst **Constrained Application Protocol (CoAP)** dieselbe Aufgabe auf Anwendungsebene [28]. Der Block-wise Transfer aus RFC 7959 zerlegt eine Repräsentation in nummerierte Blöcke, deren Größe zwischen 16 und 1024 Byte ausgehandelt wird, und überträgt jeden Block mit einer eigenen Anfrage des Clients [29]. Damit ist der Ansatz dem hier entwickelten Rückkanal sehr ähnlich, denn auch dort fordert der Client jeden Block einzeln an. Die kleinste vorgesehene Blockgröße liegt allerdings bereits über der Nutzlast, die der betrachtete Bus je Paket zulässt, und **CoAP** setzt einen Datagrammdienst wie **User Datagram Protocol (UDP)** voraus.

Diese Protokolle liegen nah an der betrachteten Domäne, lösen aber jeweils einen Teil der Aufgabe. Sie zielen auf Gerätesteuerung mit festem Befehlssatz, auf nachrichtenbasiertes Veröffentlichen und Abonnieren oder auf die segmentierte Übertragung von Daten. Einen allgemeinen, objektorientierten entfernten Aufruf über einen anfragegetriebenen Kanal mit Paketen von wenigen Byte bietet keines von ihnen.

2.8 Der betrachtete Bus und PUPRemote als Transportbasis

Der Hub und die angeschlossenen Geräte verkehren über **LEGO Power Functions 2.0 (LPF2)**, ein Protokoll, das auf einer **Universal Asynchronous Receiver Transmitter (UART)**-Verbindung über die Sensorports aufsetzt [30]. Der Hub ist dabei der Master und stößt jede Übertragung an. Ein Gerät meldet sich beim Anstecken mit den Modi an, die es unterstützt. Jeder Modus beschreibt einen Kanal mit festem Namen, fester Länge und festem Datentyp. Der Hub wählt einen dieser Modi aus und liest dessen Wert oder schreibt einen Wert hinein.

PUPRemote [31] nimmt in diesem Umfeld eine Sonderstellung ein, da es in dieser Arbeit als Baustein der eigenen Lösung eingesetzt wird. Die Bibliothek erschließt den **LEGO Powered Up (PUP)**- und **LPF2**-Bus und stellt darauf benannte Aufrufe bereit. Jeder Aufruf belegt einen eigenen Modus des Busses und ist über feste Formatangaben für beide Richtungen beschrieben. Der Hub schreibt die Argumente in den zugehörigen Modus und liest anschließend den Rückgabewert aus demselben Modus zurück. Mit PUPRemote werden auf beiden Seiten Befehle registriert, die anschließend vom Master aufgerufen werden können. Die Länge der Befehlsnamen, der Argumente und der Rückgabewerte ist dabei durch die festen Formatangaben begrenzt. PUPRemote besitzt damit durchaus eine eigene Aufrufsemantik und ist nicht auf reinen Datentransport beschränkt.

Diese Semantik trägt jedoch nur so weit, wie sich ein Aufruf auf einen vorab registrierten Modus und ein einzelnes Paket fester Größe abbilden lässt. Die Anzahl der Modi ist durch den Bus begrenzt, die Formate stehen zur Übersetzungszeit fest, und für Nachrichten, die größer sind als ein Paket, ist kein Mechanismus vorgesehen. Eine Middleware, die beliebige Methoden auf einer zur Laufzeit wachsenden Menge entfernter Objekte anbieten soll, kann daher nicht einen Modus je Aufruf vergeben.

Die vorliegende Arbeit nutzt PUPRemote deshalb nur als Busanbindung. Registriert wird ein einziges Kommando, dessen Nutzlast aus Sicht von PUPRemote ein Block fester Länge ohne Struktur ist. Die Zerlegung von Nachrichten in Pakete, deren Rahmung, die Zuordnung von Antworten zu Anfragen, der anfragegetriebene Rückkanal sowie das Objektmodell aus Stellvertretern und serverseitigen Adaptern liegen vollständig darüber. PUPRemote übernimmt damit die Rolle der Busanbindung und kann durch andere Bibliotheken ersetzt werden, die denselben Austausch von Blöcken leisten.

2.9 Abgrenzung

Tabelle I fasst die betrachteten Ansätze entlang der eingangs definierten Kriterien zusammen.

Tabelle I: Vergleich der betrachteten Ansätze entlang der Auswahlkriterien

Ansatz	Ebene	Abstraktionsgrad	Serialisierung	Transportbindung	Fragmentierung	Eignung kleiner Master-Slave-Bus
gRPC	Middleware	RPC und Datenströme	Protocol Buffers, schemagebunden	an HTTP/2 gebunden	über HTTP/2	ungeeignet, setzt Push voraus
JSON-RPC	Nachrichtenformat	nur Nachrichtenformat	JSON, textbasiert	unabhängig, offen	nicht definiert	offen, Rückkanal fehlt
Message-Pack und CBOR	Serialisierung	nur Serialisierung	binär, schemafrei	entfällt	entfällt	entfällt
Firmata	Geräteprotokoll	Gerätesteuerung mit festen Befehlen	binär, fest	seriell, fest	nein	passend, aber fester Befehlssatz
ISO-TP	Transportprotokoll	nur Transport	entfällt	an CAN gebunden	ja, bis 4095 Byte	passend, aber ohne Aufrufe
CANopen SDO	Geräteprotokoll	Zugriff auf ein Objektverzeichnis	feste Einträge	an CAN gebunden	ja, segmentiert	passend, aber festes Verzeichnis
CoAP Block-wise	Anwendungsprotokoll	Representational State Transfer (REST)-artiger Zugriff	binär, schemafrei	setzt UDP voraus	ja, ab 16 Byte	Blockgröße zu groß
MQTT	Nachrichtenprotokoll	Veröffentlichen und Abonnieren	binär, kompakt	unabhängig, braucht Gateway	teilweise	setzt eigenständiges Senden voraus
PUPRemote	Transportanbindung, hier als Baustein verwendet	entfernter Aufruf, ein Modus je Aufruf	feste Formatangaben je Modus	an PUP und LPF2 gebunden	nein, ein Paket	passend, aber nur ein Paket
Diese Arbeit	Middleware	entfernter Aufruf und entfernte Objekte	MessagePack, gekapselt und austauschbar	gekapselt, PUPRemote als erste Bindung	ja, eingebaut	passend, anfragegetriebener Rückkanal

Aus dem Vergleich wird die Lücke deutlich. Die leistungsfähigen Rahmenwerke setzen einen Transport voraus, den das Zielsystem nicht bietet. Die schlanken Ansätze standardisieren nur Teilaspekte und lassen Rahmung, Fragmentierung und den Rückkanal offen. Die domänennahen Protokolle lösen eine andere Aufgabe oder setzen voraus, dass die untergeordnete Seite eigenständig senden kann. PUPRemote liegt schließlich eine Ebene tiefer. Es erschließt den Bus und wird in dieser Arbeit als Busanbindung genutzt, ersetzt aber nicht die gesuchte Middleware.

Die vorliegende Arbeit verbindet diese Aspekte zu einer zusammenhängenden Lösung. Sie stellt einen transportunabhängig entworfenen entfernten Aufruf samt Objektmodell bereit, bringt Rahmung und Fragmentierung für sehr kleine Pakete mit und setzt einen anfragegetriebenen Rückkanal für einen Master-Slave-Bus um. All das läuft innerhalb der Grenzen von MicroPython und Pybricks. Der Beitrag liegt damit weniger in einem einzelnen neuen Baustein als in der Kombination bekannter Konzepte für einen bisher nicht abgedeckten Anwendungsfall.

3 Systemanalyse und Anforderungen

Dieses Kapitel analysiert das Zielsystem und leitet daraus die Anforderungen ab. Zunächst wird die vorhandene Plattform betrachtet und begründet, warum eine externe Erweiterung nötig ist, bevor die Anforderungen an Display, Mikrocontroller und Kommunikation formuliert und den Einschränkungen der Plattform gegenübergestellt werden. Das Kapitel schließt mit einer Verallgemeinerung des Problemraums.

3.1 Zielsystem und Hardwareumgebung

Ausgangspunkt der vorliegenden Arbeit ist eine bestehende Hardwareplattform aus dem LEGO-Education-Umfeld, die die technischen Rahmenbedingungen festlegt, in denen die in Abschnitt 1 motivierte Display-Integration umgesetzt werden muss. Im Folgenden wird zunächst die zentrale Hardwarekomponente vorgestellt und anschließend im Hinblick auf die Anbindung eines Touchscreen-Displays analysiert, woraus sich die Notwendigkeit einer externen Erweiterung ergibt.

3.1.1 Der LEGO Education SPIKE Prime Hub als Ausgangsplattform

Den Kern des Zielsystems bildet der LEGO Education SPIKE Prime Hub [32]. Hierbei handelt es sich um einen programmierbaren Steuerbaustein, der primär für den Einsatz im Bildungsbereich konzipiert ist und über sechs Ein- und Ausgabeports zum Anschluss von LEGO-kompatiblen Sensoren und Aktoren verfügt. Für die Interaktion mit dem Nutzer stellt der Hub eine Matrix aus 5×5 [Light Emitting Diodes \(LEDs\)](#), drei Tasten und einen einfachen Lautsprecher bereit.

Intern basiert der Hub auf einem STM32F413-Mikrocontroller [33] mit einem ARM-Cortex-M4-Kern, einer Taktfrequenz von etwa 100 MHz, rund 1 bis 1,5 MB Flash-Speicher sowie 320 kB [Static Random Access Memory \(SRAM\)](#) [34]. Die Programmierung kann grafisch über die offizielle LEGO-Software oder textbasiert mittels MicroPython erfolgen. Welche Firmware konkret eingesetzt wird und wie sich diese Wahl auf die spätere Lösung auswirkt, wird in Abschnitt 3.4 vertieft.

Für die vorliegende Arbeit sind drei Eigenschaften des Hubs von besonderer Bedeutung:

- Der Hub stellt ausschließlich passive, an die Sensor- und Motorports gebundene Erweiterungsmöglichkeiten bereit. Eine direkte Anbindung beliebiger Peripheriegeräte über offene Schnittstellen wie [SPI](#) [11] oder [I2C](#) [10] ist nicht vorgesehen.
- Die verfügbaren Anzeige- und Eingabemöglichkeiten beschränken sich auf die genannte [LED-Matrix](#) sowie die Hub-Tasten.
- Rechenleistung und Arbeitsspeicher sind für einen Mikrocontroller zwar typisch, für grafische Benutzeroberflächen jedoch stark begrenzt.

Diese Eigenschaften bilden den Rahmen, in dem die Display-Integration entworfen werden muss.

3.1.2 Notwendigkeit einer externen Erweiterung

Aus den in Abschnitt 1.1 motivierten Anforderungen an eine grafische Benutzeroberfläche mit Touch-Funktionalität ergibt sich ein direkter Konflikt mit der beschriebenen Plattform. Die im Hub integrierten Ausgabe- und Eingabemöglichkeiten beschränken sich auf eine niedrig auflösende [LED-Matrix](#) und einfache Tasten und sind damit für die Darstellung komplexer Inhalte sowie für eine differenzierte Benutzerinteraktion ungeeignet. Eine Erweiterung des Hubs selbst ist ebenfalls nicht vorgesehen, da er als geschlossene Komponente konzipiert ist und keine Schnittstellen zum direkten Anschluss grafischer Peripherie bereitstellt.

Die geforderte Display-Funktionalität lässt sich daher nur außerhalb des Hubs umsetzen. Die Ansteuerung des Displays muss an eine externe Hardwarekomponente abgegeben werden, die an einen der vorhandenen Sensorports des Hubs angeschlossen wird. Hieraus ergeben sich zwei eigenständige Teilprobleme, die in den folgenden Abschnitten weiter ausgearbeitet werden:

- die Wahl einer geeigneten externen Hardware zur Ansteuerung eines Displays sowie

- eine geeignete Kommunikation zwischen dem Hub und dieser externen Komponente.

3.2 Anforderungen an die Display-Integration

Die Anforderungen werden in drei Gruppen gegliedert. Die Anforderungen D1 bis D3 betreffen das Display selbst, S1 bis S3 den Mikrocontroller, der es ansteuert, und K1 bis K6 im folgenden Abschnitt die Kommunikation zwischen beiden Einheiten.

3.2.1 Anforderungen an ein externes Display

Bevor konkrete Hardwarekomponenten betrachtet werden, lassen sich aus der Zielsetzung der Arbeit allgemeine Anforderungen an ein externes Display ableiten:

- **D1 – Grafische Darstellung.** Das Display soll die Darstellung einfacher grafischer Elemente wie Schaltflächen, Beschriftungen und Anzeigen ermöglichen.
- **D2 – Berührungseingabe.** Es soll zugleich Benutzereingaben über einen Touchscreen entgegennehmen.
- **D3 – Embedded-typische Auslegung.** Auflösung, Größe und Energieaufnahme orientieren sich an typischen Embedded-Anwendungen. Damit kommen kleine **TFT**-Displays mit einer Auflösung von etwa 240×320 Pixeln in Frage.

Solche Displays sind in unterschiedlichen Ausführungen verfügbar, wobei im Embedded-Bereich Module mit ILI9341-Display-Controller [35] weit verbreitet sind. Sie unterstützen eine Auflösung von 240×320 Pixeln bei einer Farbtiefe von 18 Bit und werden über **SPI** angesteuert. Für die Erkennung von Berührungen kommen typischerweise kapazitive Touchcontroller wie der FT6x06 [36] zum Einsatz, die über **I2C** angebunden werden und neben Einzelberührungen auch Mehrfingergesten erfassen können. Solche Module sind kostengünstig verfügbar und werden in der Maker- und Embedded-Community häufig in Verbindung mit Mikrocontrollern der ESP32-Familie eingesetzt.

3.2.2 Anforderungen an einen externen Mikrocontroller

Da der SPIKE Prime Hub selbst kein **TFT**-Display über **SPI** anbinden kann, muss zwischen Hub und Display ein zusätzlicher Mikrocontroller vermitteln. Er übernimmt die Ansteuerung des Displays und die Verarbeitung der Touch-Eingaben und kommuniziert gleichzeitig mit dem Hub. Aus dieser Doppelrolle ergeben sich folgende Anforderungen an die Hardware:

- **S1 – Displayschnittstellen.** Sie muss über geeignete Schnittstellen zur Ansteuerung typischer **TFT**-Displays verfügen, insbesondere **SPI** für die Bildschirmdaten und **I2C** für den Touch-Controller.
- **S2 – Rechenleistung und Speicher.** Sie muss ausreichend Rechenleistung und Speicher bieten, um eine grafische Bibliothek wie etwa **Light and Versatile Graphics Library (LVGL)** [37] ausführen zu können.
- **S3 – Busanbindung.** Sie muss über eine Schnittstelle verfügen, die kompatibel zu den Sensorports des SPIKE Prime Hubs ist, oder eine entsprechende Anbindung über **LPF2** unterstützen.

Diese Anforderungen erfüllen Erweiterungsboards aus dem Bildungs- und Maker-Bereich, die speziell für die Anbindung an LEGO-Hubs entworfen wurden. Ein Beispiel sind die ESP32-basierten Boards der LMS-ESP32-Reihe [38]. Sie geben sich gegenüber dem Hub als LEGO-Sensor aus und können dadurch über das **LPF2**-Protokoll kommunizieren. Welche Hardware in dieser Arbeit konkret eingesetzt wird und wie die Software dafür eingerichtet ist, beschreibt Abschnitt 6.

3.2.3 Resultierende Systemstruktur

Aus diesen Überlegungen ergibt sich eine Systemstruktur aus drei Teilen. Der SPIKE Prime Hub führt die Anwendung aus, ein externer Mikrocontroller steuert das Display an, und ein **TFT**-Touchscreen-Display dient zur Anzeige und Eingabe, wobei Hub und Mikrocontroller über einen

Sensorport des Hubs und das LPF2-Protokoll verbunden sind. Im Folgenden wird der Hub als Steuereinheit bezeichnet, während Mikrocontroller und Display zusammen die Anzeigeeinheit bilden. Wie die Kommunikation zwischen beiden aussehen muss und welchen Einschränkungen sie unterliegt, betrachten die folgenden Abschnitte.

3.3 Kommunikationsanforderungen

Der vorige Abschnitt legt fest, aus welchen Komponenten das System besteht. Offen ist noch, was die Verbindung zwischen Steuer- und Anzeigeeinheit leisten muss. Die folgenden Anforderungen leiten sich aus dem Anwendungsfall einer interaktiven Oberfläche ab und beziehen sich nicht auf einen bestimmten Übertragungsweg. Sie sind mit K1 bis K6 nummeriert, damit Abschnitt 7 später auf sie verweisen kann.

- **K1 – Strukturierte Nachrichten unbestimmter Länge.** Ein Bedienelement lässt sich nicht durch einen einzelnen Wert beschreiben. Zum Erzeugen einer Schaltfläche gehören Position, Abmessungen und Beschriftung. Ein Beschriftungstext hat keine feste Länge, und eine Auswahlliste enthält unterschiedlich viele Einträge. Die Verbindung muss deshalb zusammengesetzte Werte übertragen können, deren Länge erst zur Laufzeit feststeht. Feste Formatangaben je Aufruf, wie sie die in Abschnitt 2 betrachtete Transportbibliothek verwendet, reichen dafür nicht aus.
- **K2 – Aufrufe mit zuordenbarem Ergebnis.** Viele Aufrufe liefern einen Rückgabewert. Das Erzeugen eines Objekts liefert eine Referenz, über die es später angesprochen wird. Das Auslesen eines Zustands liefert den entsprechenden Wert. Zu jeder Anfrage muss also eine Antwort zurückkommen. Werden mehrere Anfragen nacheinander abgesetzt, muss erkennbar bleiben, welche Antwort zu welcher Anfrage gehört.
- **K3 – Rückfluss von Ereignissen.** Berührungen entstehen auf der Anzeigeeinheit, ausgewertet werden sie aber von der Anwendung auf der Steuereinheit. Informationen müssen daher auch dann von der Anzeige- zur Steuereinheit gelangen, wenn sie keine Antwort auf einen Aufruf sind. Ereignisse sollen dabei nicht verloren gehen. Lässt sich ein Verlust nicht vermeiden, muss er zumindest erkennbar sein.
- **K4 – Antwortzeit.** Berührung und Reaktion auf dem Bildschirm sollen für den Benutzer zusammengehören. Als Richtwert dient die bei direkter Manipulation übliche Grenze von etwa 100 Millisekunden [39], [40]. Gemeint ist dabei der gesamte Vorgang aus Erkennung, Übertragung, Verarbeitung und Rückmeldung, nicht die Übertragung eines einzelnen Pakets.
- **K5 – Begrenzter Speicherbedarf.** Auf beiden Seiten der Verbindung arbeitet ein Mikrocontroller. Puffer brauchen deshalb eine feste Obergrenze, die schon beim Entwurf bekannt ist. Verfahren, die im ungünstigen Fall beliebig viel Speicher belegen, etwa das Sammeln aller bisher aufgetretenen Ereignisse, kommen nicht in Frage.
- **K6 – Unabhängigkeit vom Übertragungsweg.** Der Übertragungsweg ist durch die Plattform vorgegeben und gehört nicht zum eigentlichen Problem. Seine Eigenschaften sollen sich deshalb nur in einem klar abgegrenzten Teil des Entwurfs auswirken. Prüfen lässt sich das daran, wie viel geändert werden müsste, um denselben Dienst über einen anderen Weg anzubieten.

K1 bis K3 betreffen den Inhalt der Übertragung, K4 und K5 die Bedingungen, unter denen sie stattfindet, und K6 den Aufbau des Entwurfs. Der folgende Abschnitt stellt diesen Anforderungen die Eigenschaften der Plattform gegenüber.

3.4 Einschränkungen der Plattform

Steuer- und Anzeigeeinheit sind über einen Sensorport des Hubs und das LPF2-Protokoll gekoppelt, woraus sich drei Einschränkungen ergeben, die den Anforderungen aus dem vorigen Abschnitt entgegenstehen. Sie werden im Folgenden einzeln beschrieben und den betroffenen Anforderungen zugeordnet, wobei es sich um Eigenschaften der Kopplung selbst handelt und

nicht um Schwächen einer bestimmten Umsetzung. Wie der Entwurf darauf reagiert, zeigen Abschnitt 4 und Abschnitt 5, die konkrete Umsetzung beschreibt Abschnitt 6.

3.4.1 Eingeschränkte Kommunikationsrichtung

Das LPF2-Protokoll arbeitet nach dem Master-Slave-Prinzip [30]. Der Hub ist dabei der Master. Er wählt den aktiven Modus des angeschlossenen Geräts aus und stößt jede Übertragung an. Das Gerät meldet sich als Sensor an und stellt Werte bereit, die der Hub abrufen, während es von sich aus nicht senden kann.

Die in Abschnitt 2 beschriebene Bibliothek PUPRemote bildet das direkt ab und bietet ein einziges Zugriffsmuster an. Die Steuereinheit schreibt Daten in einen Modus und liest im selben Vorgang die Antwort zurück. Jede Übertragung besteht damit aus Anfrage und Antwort, und die Anzeigeeinheit antwortet ausschließlich.

Für die Anforderungen bedeutet das, dass sich weder Ergebnisse (K2) noch Ereignisse (K3) zustellen lassen, sondern beides nur bereitgehalten und abgefragt werden kann. Entsteht ein Ergebnis erst nach der letzten Anfrage, ist eine weitere Anfrage nötig, und eine Berührung zwischen zwei Anfragen muss bis zur nächsten Anfrage zwischengespeichert werden. Wann eine Rückmeldung eintrifft, bestimmt damit die Seite, die sie abholt. Die zeitliche Auflösung von Ereignissen ist dadurch durch den Abfragetakt der Steuereinheit begrenzt, was sich direkt auf K4 auswirkt.

3.4.2 Begrenzte Paketgröße

Ein Modus des Busses überträgt eine feste, vorab vereinbarte Anzahl von Bytes. Zusammen mit der auf dem Hub eingesetzten Firmware [41] liegt die nutzbare Obergrenze bei 16 Byte je Übertragung, oberhalb dieses Werts treten Prüfsummenfehler auf. Dieser Wert ist nicht dokumentiert, sondern wurde im Rahmen dieser Arbeit durch Ausprobieren bestimmt. Da jedes Paket zusätzlich Steuerinformationen für das Zusammensetzen tragen muss, bleibt für die Nachricht selbst noch weniger übrig. In der Referenzimplementierung sind es 13 nutzbare Byte je Paket, wie Abschnitt 6 zeigt.

Schon eine einfache Aufrufnachricht mit Objektreferenz, Methodenname und wenigen Argumenten überschreitet diesen Rahmen deutlich. K1 lässt sich mit einem einzelnen Paket also nicht erfüllen, und Nachrichten müssen in mehrere Pakete zerlegt werden. Hinzu kommt, dass die Steuerinformationen bei einer Nutzlast von wenigen Byte einen großen Anteil der Übertragung ausmachen.

Eine weitere Beschränkung ergibt sich aus der Stromversorgung, da ein Display mehr Strom benötigt, als die Logikversorgung des Ports liefert, weshalb die Anzeigeeinheit die höhere Versorgungsspannung über den Port anfordert. In diesem Fall verkürzt sich die zulässige Länge der Modusnamen von elf auf fünf Zeichen, wodurch auch die Namen der Kanäle knapp werden. Abschnitt 6.2 geht auf die Versorgung näher ein.

3.4.3 Beschränkte Laufzeitumgebung

Der Hub wird in einer für Mikrocontroller ausgelegten Python-Variante programmiert, wie sie Abschnitt 2.3 beschreibt und deren Funktionsumfang gegenüber einer vollständigen Laufzeitumgebung deutlich eingeschränkt ist. Konkret handelt es sich um MicroPython [9] in der Ausprägung von Pybricks [41], einer Firmware für LEGO-Hubs. Abschnitt 6.1 geht auf die Unterschiede zwischen beiden Seiten ein.

Ein Netzwerkstack und die darauf aufbauenden Abstraktionen stehen nicht zur Verfügung. Die üblichen Bausteine verteilter Kommunikation lassen sich deshalb nicht verwenden und müssen durch eigene ersetzt werden.

Schwerer wiegt, dass auf der Steuereinheit keine echte Nebenläufigkeit zur Verfügung steht, da es keinen Hintergrundprozess gibt, der Pakete entgegennimmt oder Ergebnisse einsammelt, während die Anwendung weiterläuft. Das Warten auf ein Ergebnis findet deshalb im Kontroll-

fluss der Anwendung selbst statt, sodass die Anwendung stillsteht, solange das Ergebnis eines Aufrufs nicht vorliegt. Mehrere Aufrufe können sich somit nicht überlappen, und ihre Übertragungszeiten addieren sich.

Dazu kommt der begrenzte Arbeitsspeicher auf beiden Seiten, wodurch K5 auf dieser Plattform zu einer harten Grenze wird. Puffer für unvollständig empfangene Nachrichten, für bereitgehaltene Ergebnisse und für zwischengespeicherte Ereignisse benötigen jeweils eine feste Obergrenze, zudem muss festgelegt sein, was beim Erreichen dieser Grenze geschieht.

3.4.4 Wechselwirkung der Einschränkungen

Einzeln betrachtet ließe sich jede der drei Einschränkungen bewältigen. Kleine Pakete lassen sich durch Zerlegung überbrücken, eine fehlende Sendemöglichkeit durch regelmäßiges Abfragen, und ein Ablauf lässt sich auch ohne Nebenläufigkeit sequenziell formulieren. Zusammen verstärken sie sich jedoch gegenseitig.

Durch die kleine Paketgröße zerfällt eine Nachricht in viele Pakete. Wegen der eingeschränkten Kommunikationsrichtung erfordert jedes dieser Pakete eine eigene Anfrage der Steuereinheit samt Antwort, und für das Abholen des Ergebnisses sind weitere Anfragen nötig. Ohne Nebenläufigkeit werden all diese Anfragen nacheinander abgearbeitet.

Für den weiteren Entwurf folgt daraus, dass die Dauer eines Aufrufs vor allem von der Anzahl der nötigen Übertragungen abhängt und weniger von der Geschwindigkeit des Busses. Ein zusätzliches Byte Steuerinformation je Paket kann bei einer Nutzlast von wenigen Byte die Anzahl der Pakete und damit die Dauer eines Aufrufs erhöhen. Ziel des Entwurfs ist deshalb vor allem, Übertragungen einzusparen. Abschnitt 7 greift das auf und beziffert es.

Tabelle II fasst die Gegenüberstellung von Anforderungen und Einschränkungen zusammen.

Tabelle II: Gegenüberstellung der Kommunikationsanforderungen und der Einschränkungen der Plattform

Nr.	Anforderung	Entgegenstehende Einschränkung	Folge für den Entwurf
K1	Strukturierte Nachrichten unbestimmter Länge	Feste Paketgröße von 16 Byte	Nachrichten müssen zerlegt und wieder zusammengesetzt werden
K2	Aufrufe mit zuordenbarem Ergebnis	Keine eigenständige Übertragung durch die Anzeigeeinheit	Ergebnisse werden bereitgehalten und abgefragt, Zuordnung über eine mitgeführte Kennung
K3	Rückfluss von Ereignissen	Keine eigenständige Übertragung durch die Anzeigeeinheit	Ereignisse werden zwischengespeichert und von der Steuereinheit abgeholt
K4	Antwortzeit	Alle drei Einschränkungen gemeinsam	Anzahl der Übertragungen je Aufruf wird zur bestimmenden Größe
K5	Begrenzter Speicherbedarf	Beschränkter Arbeitsspeicher beider Seiten	Feste Obergrenzen für alle Puffer, festgelegtes Verhalten beim Überlauf
K6	Unabhängigkeit vom Übertragungsweg	Eigenheiten von Bus und PUPRemote	Alle wegababhängigen Anteile in einer austauschbaren Schicht bündeln

3.5 Verallgemeinerung des Problemraums

Die im vorigen Abschnitt beschriebenen Einschränkungen wurden am konkreten Zielsystem hergeleitet, sind jedoch nicht an dieses System gebunden. Das ist für die weitere Arbeit wichtig, denn davon hängt ab, ob der folgende Entwurf eine Einzellösung ist oder für eine ganze Klasse von Verbindungen gilt.

Die drei Eigenschaften lassen sich von der Plattform ablösen und als allgemeine Merkmale einer Verbindung formulieren. Erstens ist die Übertragung anfragegetrieben, das heißt, nur eine der beiden Seiten kann eine Übertragung anstoßen. Zweitens ist die Nutzlast je Übertragung klein und fest vorgegeben. Drittens steht auf mindestens einer Seite eine Laufzeitumgebung zur

Verfügung, die weder einen vollständigen Netzwerkstack noch die üblichen Mittel nebenläufiger Programmierung bereitstellt.

Diese Kombination tritt über den betrachteten Bus hinaus in verschiedenen Ausprägungen auf. Bei der Kommunikation über [I2C](#) treibt beispielsweise der Master den Bus, während ein Slave eine Übertragung nicht selbstständig beginnen kann, und Modbus [RTU](#) folgt demselben Muster aus Anfrage und Antwort. Auch bei Bluetooth Low Energy erfolgt der übliche Zugriff über lesende Anfragen des Clients, und die standardmäßig ausgehandelte Nutzlast liegt in derselben Größenordnung wie beim hier betrachteten Bus [42]. In allen genannten Fällen stellen sich dieselben Fragen. Wie werden Nachrichten zerlegt und wieder zusammengesetzt? Wie gelangen Ergebnisse und Ereignisse zur anfragenden Seite zurück? Und wie lässt sich all das vor der Anwendung verbergen?

Die vorliegende Arbeit behandelt den betrachteten Bus daher als einen Vertreter dieser Klasse. Der Entwurf in den folgenden Kapiteln bezieht sich deshalb auf die genannten Merkmale und nicht auf Eigenschaften einer bestimmten Plattform. Inwieweit das gelungen ist, wird am Ende der Arbeit diskutiert.

4 Architektur des Systems

Dieses Kapitel leitet die Architektur der Lösung aus den Anforderungen des vorigen Kapitels ab. Die Darstellung bleibt auf der konzeptionellen Ebene und nennt weder konkrete Bibliotheken noch Datenformate oder Klassen. Beschrieben werden die Ziele der Architektur, der geschichtete Aufbau mit den Aufgaben der einzelnen Schichten, die wiederkehrenden Rollen innerhalb dieser Schichten sowie das Kommunikationsmodell. Wie sich der Entwurf auf eine konkrete Hardware, Laufzeitumgebung und einen konkreten Bus abbilden lässt, zeigt Abschnitt 6.

4.1 Zielsetzung der Architektur

Die Architektur verfolgt mehrere Ziele, die sich direkt aus den zuvor formulierten Anforderungen ergeben. Im Mittelpunkt steht die Aufrufstransparenz auf der Anwendungsseite, denn die Anwendung soll mit gewöhnlichen Methodenaufrufen arbeiten und nichts über Pakete, Bestätigungen oder das Abholen von Ergebnissen wissen müssen.

Ein zweites Ziel ist die Unabhängigkeit vom konkreten Übertragungsweg. Die höheren Schichten sollen so entworfen sein, dass der Transport hinter einer einheitlichen Schnittstelle liegt und ausgetauscht werden kann. Hinzu kommen die Bewältigung der kleinen Paketgröße durch Rahmung und Fragmentierung, ein anfragegetriebener Rückkanal für Ergebnisse und Ereignisse sowie ein sparsamer Umgang mit Speicher und Rechenzeit. Schließlich soll die Architektur eine klare und symmetrische Struktur besitzen, in der beide Seiten dieselben Schnittstellen teilen.

Aus diesen Zielen ergibt sich ein geschichteter Aufbau nach dem Vorbild einer Middleware mit entferntem Aufruf. Jede Schicht kapselt eine klar umrissene Aufgabe und stellt der darüberliegenden Schicht eine höhere Abstraktion bereit. Der Vorteil dieses Aufbaus ist, dass sich die schwierigen Eigenschaften des Zielsystems, also die geringe Paketgröße und die eingeschränkte Kommunikationsrichtung, auf wenige Schichten eingrenzen lassen und oberhalb dieser Schichten nicht mehr sichtbar sind.

4.2 Schichtenmodell

Das System ist in fünf Schichten gegliedert, die auf beiden Seiten der Verbindung vorhanden sind, wie Abbildung 1 zeigt.



Abbildung 1: Schichtenmodell der Architektur. Beide Seiten sind gleich aufgebaut und verkehren jeweils nur mit der unmittelbar darunterliegenden Schicht.

Zwei Eigenschaften dieses Aufbaus sind hervorzuheben. Zum einen ist er symmetrisch, da beide Seiten dieselben Schichten mit denselben Aufgaben besitzen und sich lediglich in der Richtung unterscheiden, aus der ein Aufruf eintrifft. Zum anderen ist er streng geschichtet, denn jede Schicht spricht ausschließlich mit der unmittelbar darunterliegenden, sodass eine Änderung innerhalb einer Schicht die übrigen nicht berührt.

Die beiden Seiten nehmen dabei feste Rollen ein. Die Steuereinheit ruft Methoden auf und stößt jede Übertragung an, weshalb sie im Folgenden als Client bezeichnet wird, während die

Anzeigeeinheit die Aufrufe ausführt, ausschließlich antwortet und deshalb als Server bezeichnet wird. Die Rollen decken sich mit der Verteilung auf dem Bus, auf dem der Hub als Master arbeitet, und wechseln im Betrieb nicht, auch nicht bei Ereignissen, da auch diese vom Client abgefragt werden.

Die folgenden Abschnitte beschreiben die Schichten von unten nach oben. Für jede Schicht werden ihre Aufgabe, die nach oben angebotene Abstraktion und die Aufgaben benannt, die sie bewusst nicht übernimmt.

4.2.1 Busanbindung

Die Busanbindung ist die einzige Schicht mit Kenntnis des tatsächlichen Übertragungswegs. Ihre Aufgabe besteht darin, einen Block fester Länge zur Gegenseite zu befördern und einen ebensolchen Block als Antwort entgegenzunehmen, ohne den Inhalt dieses Blocks oder dessen Bedeutung zu kennen.

Nach oben bietet sie damit eine sehr schmale Abstraktion an, nämlich einen paketweisen, vom Client angestoßenen Austausch fester Größe. Das ist beabsichtigt, denn nur so bleibt die Schicht austauschbar, und jeder Übertragungsweg, der einen anfragegetriebenen Austausch von Blöcken fester Länge leisten kann, ist als Unterbau geeignet.

Nicht zu ihren Aufgaben gehören die Zerlegung größerer Nachrichten, die Zuordnung von Antworten zu Anfragen und jede Form der Auslegung des Inhalts. Die Paketgröße ist für diese Schicht eine gegebene Eigenschaft des Übertragungswegs und keine Größe, die sie beeinflusst.

4.2.2 Transportschicht

Die Transportschicht vermittelt zwischen Nachrichten beliebiger Länge und den kleinen Paketen des Übertragungswegs. In ihr wirkt sich damit die zentrale Einschränkung des Zielsystems aus.

Ihre erste Aufgabe ist die Serialisierung, bei der eine strukturierte Nachricht in eine Folge von Bytes überführt und auf der Gegenseite wieder ausgelesen wird. Ihre zweite Aufgabe ist die Rahmung, bei der jedes Paket Steuerinformationen erhält, mit denen die Gegenseite die ursprüngliche Nachricht wiederherstellen kann. Dazu gehören eine Kennung der Nachricht, die Position des Pakets innerhalb der Nachricht, die Angabe, ob es das letzte Paket ist, und die Anzahl der tatsächlich genutzten Bytes. Ihre dritte Aufgabe ist die Fragmentierung, also das Zerlegen einer Nachricht in eine Folge solcher Pakete und deren Zusammensetzen auf der Gegenseite.

Nach oben verbirgt diese Schicht die Paketgröße vollständig, sodass höhere Schichten mit Nachrichten arbeiten, deren Länge sie nicht zu beachten brauchen.

Zwei Entwurfsentscheidungen dieser Schicht sind besonders wichtig. Erstens ist die Rahmung vom Serialisierungsformat getrennt, und beide sind an je einer Stelle gebündelt, sodass sich das Format wechseln lässt, ohne die Rahmung anzutasten. Zweitens muss die Rahmung die Länge der Nutzlast ausdrücklich mitführen und darf sie nicht aus dem Inhalt ableiten, etwa durch das Entfernen von Füllbytes am Ende. Andernfalls schränkt die Rahmung die zulässigen Inhalte ein und bindet die Schicht an ein textbasiertes Format. Bei einer Nutzlast von wenigen Byte je Paket sind die Steuerinformationen außerdem ein wesentlicher Kostenfaktor der gesamten Übertragung.

4.2.3 Kommunikationsschicht

Die Kommunikationsschicht stellt den entfernten Aufruf her. Auf dem Client bildet sie aus dem Namen einer Methode, deren Argumenten und der Angabe des Scopes eine Nachricht, übergibt diese nach unten und nimmt anschließend das Ergebnis entgegen. Auf dem Server nimmt sie eine Nachricht entgegen, wählt den zuständigen Empfänger, ruft die benannte Methode auf und stellt deren Ergebnis zur Abholung bereit.

In dieser Schicht liegt außerdem die Behandlung des Rückkanals. Da der Server nicht von sich aus senden kann, wird das Ergebnis nicht zugestellt, sondern bereitgehalten und auf

Anfrage herausgegeben. Die Kommunikationsschicht verbirgt diesen Umstand, sodass ein Aufruf nach oben als gewöhnlicher, synchroner Methodenaufruf erscheint, der zurückkehrt, sobald das Ergebnis vorliegt.

Diese Schicht kennt die aufgerufenen Objekte nicht und befördert einen Aufruf zu einem benannten Empfänger, ohne zu wissen, was dieser darstellt.

4.2.4 Objektmodell

Das Objektmodell hebt den entfernten Aufruf auf die Ebene entfernter Objekte. Grafische Elemente wie Bildschirme, Beschriftungen und Schaltflächen werden als Objekte abgebildet, die auf dem Server bestehen und auf dem Client durch Stellvertreter vertreten werden.

Grundlage ist eine gemeinsame abstrakte Schnittstelle je Objekttyp, die auf beiden Seiten vorliegt. Damit ein Stellvertreter ein bestimmtes entferntes Objekt anspricht, vergibt der Server beim Erzeugen eines Objekts eine Referenz und verwaltet die Objekte in einer Registratur. Der Stellvertreter führt diese Referenz mit und übergibt sie bei jedem Aufruf. Auf diese Weise lassen sich beliebig viele Objekte erzeugen und gezielt ansprechen.

Nach oben bietet diese Schicht eine Sicht an, die sich von einer rein lokalen Programmierung nicht unterscheidet, womit das Ziel der Aufruftransparenz erreicht ist.

4.2.5 Anwendung und Anzeige

Die oberste Schicht unterscheidet sich auf beiden Seiten, da hier die eigentliche Aufgabe liegt. Auf der Steuereinheit ist es die Anwendung, die das Objektmodell nutzt und nichts von der Kommunikation weiß. Auf der Anzeigeeinheit ist es die Darstellung und die Entgegennahme von Eingaben, also die Ansteuerung der Anzeigehardware und die Erkennung von Berührungen.

Beide Seiten sind über die darunterliegenden Schichten vollständig entkoppelt, weshalb ein Wechsel der Anzeigehardware ausschließlich diese oberste Schicht auf der Anzeigeeinheit berührt.

4.3 Rollen im Entwurf

Innerhalb der Schichten treten drei wiederkehrende Rollen auf. Sie sind als Entwurfsmuster zu verstehen und legen fest, welche Verantwortung an welcher Stelle liegt, während die Umsetzung offenbleibt.

4.3.1 Interceptor

Der Interceptor bildet die Schnittstelle zwischen Kommunikationsschicht und Busanbindung und folgt dem gleichnamigen Muster aus [43]. Eine für beide Seiten gemeinsame Schnittstelle legt fest, wie ein Block zur Gegenseite gelangt und wie die Antwort zurückkommt. Auf dem Client verpackt der Interceptor einen Methodenaufruf, sendet dessen Pakete und holt anschließend das Ergebnis ab. Auf dem Server nimmt er die Pakete entgegen, setzt die Nachricht zusammen und stellt das Ergebnis zur Abholung bereit.

Da diese Schnittstelle ohne Bezug auf einen konkreten Übertragungsweg formuliert ist, ist der Interceptor der Ansatzpunkt für die Unabhängigkeit vom Übertragungsweg. Ein anderer Übertragungsweg wird angebunden, indem eine weitere Umsetzung dieser Rolle bereitgestellt wird, ohne dass die höheren Schichten davon berührt werden.

4.3.2 Dispatcher

Der Dispatcher ordnet eine eingehende Nachricht der auszuführenden Methode zu. Jede Nachricht führt dazu die Angabe ihres Scopes, eine Methodenkennung und die Argumente mit sich. Anhand des Scopes wählt der Dispatcher den zuständigen Empfänger und ruft dort die benannte Methode auf.

Für jeden Objekttyp kann ein eigener Empfänger registriert werden, was das Routing der Nachrichten von der Umsetzung der Methoden entkoppelt. Das Objektmodell lässt sich dadurch schrittweise erweitern, ohne die darunterliegenden Schichten zu verändern.

4.3.3 Stellvertreter und Adapter

Stellvertreter und Adapter sind die beiden Seiten desselben Objekttyps. Der Stellvertreter implementiert die gemeinsame Schnittstelle auf dem Client und leitet jeden Methodenaufruf weiter. Der Adapter implementiert dieselbe Schnittstelle auf dem Server und enthält die eigentliche Logik, die der Dispatcher aufruft.

Dass beide dieselbe Schnittstelle erfüllen, ist die Grundlage der Aufruftransparenz, denn für die Anwendung ist weder erkennbar noch relevant, ob sie mit einem Stellvertreter oder mit einer lokalen Umsetzung arbeitet.

4.4 Kommunikationsmodell

Aus Sicht der Anwendung ist die Kommunikation synchron, da ein Aufruf erst zurückkehrt, wenn das Ergebnis vorliegt. Intern folgt die Übertragung dagegen dem anfragegetriebenen Muster des Übertragungswegs, bei dem jede Übertragung vom Client angestoßen wird und der Server ausschließlich antwortet.

Logisch werden zwei Kanäle unterschieden. Über den ersten Kanal sendet der Client die Pakete eines Aufrufs, und der Server bestätigt jedes Paket. Über den zweiten Kanal fragt der Client den Zustand und das Ergebnis ab, indem er zunächst prüft, ob ein Ergebnis bereitsteht, und es anschließend Paket für Paket abholt.

Ereignisse wie Berührungen werden nach demselben Prinzip behandelt, indem der Server sie puffert und der Client sie bei Bedarf abfragt. Damit ist auch die Ereignisbehandlung an den Takt des Clients gebunden, was die zeitliche Auflösung begrenzt. Dieser anfragegetriebene Rückkanal ist die Antwort der Architektur auf die eingeschränkte Kommunikationsrichtung.

4.5 Datenfluss im System

Der Weg eines Aufrufs durch die Schichten lässt sich in vier Phasen gliedern. Zunächst nimmt der Stellvertreter den Methodenaufruf entgegen und übergibt ihn der Kommunikationsschicht. Diese bildet aus Methodennamen, Argumenten und Scope eine Nachricht, welche die Transportschicht serialisiert, in Pakete zerlegt und mit Steuerinformationen versieht.

In der zweiten Phase überträgt der Client die Pakete. Der Server bestätigt jedes empfangene Paket und setzt die Nachricht zusammen, sobald das letzte Paket eingetroffen ist. In der dritten Phase übergibt die Kommunikationsschicht die zusammengesetzte Nachricht dem Dispatcher, der die zugehörige Methode auf dem Adapter aufruft. Das Ergebnis wird wiederum zu einer Nachricht verpackt und zur Abholung bereitgestellt.

In der letzten Phase fragt der Client ab, ob das Ergebnis bereitsteht, und holt es anschließend Paket für Paket ab. Die Kommunikationsschicht setzt die Antwort zusammen, liest die Nutzlast aus und gibt das Ergebnis an den Stellvertreter zurück, der es an die Anwendung weiterreicht.

An diesem Ablauf zeigt sich das Verhältnis von Nutzlast und Steuerverkehr. Ein einzelner Aufruf zerfällt in eine Folge von Paketen, die jeweils einzeln bestätigt werden, gefolgt von wiederholten Abfragen nach dem Ergebnis. Die Dauer eines Aufrufs hängt damit vor allem von der Anzahl der Übertragungen ab und weniger von der Geschwindigkeit des Übertragungswegs, was die Evaluation aufgreift und bezieht.

5 Entwurf von Transport- und Kommunikationsschicht

Dieses Kapitel beschreibt den Entwurf der Transport- und der Kommunikationsschicht. Die beiden Schichten bilden die Grundlage für eine zuverlässige und effiziente Kommunikation zwischen der Anwendung und dem darunterliegenden Übertragungsweg.

Die Transportschicht, im [Open Systems Interconnection \(OSI\)](#)-Modell als Transport Layer bezeichnet, ist für die Zerlegung von Nachrichten beliebiger Länge in kleinere Pakete und deren korrekte Rekonstruktion auf der Empfängerseite verantwortlich. Dort stellt sie außerdem Funktionen wie Stauvermeidung (engl. congestion avoidance) und die Sicherstellung einer fehlerfreien Übertragung bereit [44].

Die Kommunikationsschicht setzt auf der Transportschicht auf und bildet die Schnittstelle zwischen der Anwendung und dem Transport. Sie kapselt die Details der Verbindung und stellt der Anwendung ein einfaches Kommunikationsmodell bereit. Im [OSI](#)-Modell entspricht sie am ehesten dem Session Layer, der für die Verwaltung von Kommunikationssitzungen und die Zuordnung von Anfragen und Antworten zuständig ist.

5.1 Motivation und Randbedingungen

Um die Entscheidungen in beiden Schichten nachvollziehen zu können, werden zunächst Motivation und Randbedingungen zusammengefasst. Aus den vorherigen Kapiteln geht hervor, dass die Transportschicht Nachrichten zuverlässig und effizient übertragen muss, unabhängig vom zugrunde liegenden Übertragungsweg. Dazu gehört auch die Serialisierung der Nutzlast, die in der Referenzimplementierung als Codec umgesetzt ist. Die Kommunikationsschicht muss dafür sorgen, dass Anfragen und Antworten zuverlässig zugeordnet werden, und sie stellt die Aufruftransparenz her.

Die Zuordnung zum [OSI](#)-Modell ist dabei bewusst nicht streng. Rahmung und Übertragungswiederholung gehören dort zur Sicherungsschicht, und der betrachtete Bus deckt diese Schicht auch ab, allerdings nur für einzelne Blöcke und ohne jeden Bezug zu einer Nachricht. Da die Blockgröße nicht veränderbar ist und der Bus keine Kennung je Nachricht kennt, müssen Rahmung und Wiederholung oberhalb davon erneut stattfinden, diesmal bezogen auf eine vollständige Nachricht. Ebenso wird die Serialisierung hier der Transportschicht zugeordnet und nicht der darüberliegenden Aufrufschicht, wie es bei klassischen [RPC](#)-Rahmenwerken üblich ist. Der Grund liegt in Abschnitt 5.2.3: Erst das Längenfeld der Rahmung erlaubt ein binäres Format, und damit hängt die Wahl des Formats unmittelbar an der Rahmung. Beide Zuordnungen folgen also der Aufgabe und nicht dem Modell.

5.2 Transportschicht

Wie bereits beschrieben, zerlegt die Transportschicht Nachrichten beliebiger Länge in Pakete fester Größe und setzt sie auf der Empfängerseite wieder zusammen. Ein solches Paket wird in diesem Kapitel als Block bezeichnet, sobald es um die Schnittstelle zum Übertragungsweg geht, und als Frame, sobald es die Steuerinformationen der Transportschicht trägt. Dazu muss jedes Paket Steuerinformationen tragen, wie es auch bei bekannten Protokollen wie [TCP](#) oder [UDP](#) der Fall ist.

Im Folgenden wird beschrieben, welchen Übertragungsweg die Schicht nach unten voraussetzt, wobei lediglich gefordert ist, dass er Blöcke begrenzter Größe befördert. Welche [OSI](#)-Schichten dieser Weg abdeckt, ist für den Entwurf ohne Belang und je nach System verschieden, beim hier betrachteten Bus sind es Bitübertragung und Sicherung. Anschließend werden die benötigten Steuerinformationen beschrieben, ohne feste Größen und Formate vorzugeben, damit der Entwurf auf andere Systeme übertragbar bleibt, während Abschnitt 6.4 die konkrete Umsetzung zeigt.

In verteilten Systemen durchläuft eine Nachricht den Schichtenstapel zweimal, auf der Senderseite abwärts und auf der Empfängerseite aufwärts. Jede Schicht fügt auf dem Weg nach

unten eigene Steuerinformationen hinzu, die auf dem Weg nach oben wieder ausgewertet und entfernt werden, was im Allgemeinen als Kapselung und Entkapselung bezeichnet wird [45]. Die folgenden Abschnitte betrachten deshalb stets beide Richtungen.

5.2.1 Interceptor-Abstraktion

Die Transportschicht setzt nach unten einen Übertragungsweg voraus, über den sie möglichst wenig wissen darf, damit die Anforderungen aus Abschnitt 3.3 erfüllt werden können. Jede Eigenschaft, die sie voraussetzt, schließt Übertragungswege aus, die diese Eigenschaft nicht bieten. Die Schnittstelle richtet sich deshalb danach, was die betrachtete Verbindungsklasse mindestens leisten muss, und nicht nach den Fähigkeiten eines bestimmten Busses.

Da nur der Client die Übertragung anstoßen kann, lässt sich jede Interaktion auf denselben Ablauf zurückführen:




Abbildung 2: Ablauf eines Aufrufs an der Interceptor-Schnittstelle. Jede der drei Phasen besteht aus Wiederholungen derselben Operation, und jede wird vom Client angestoßen.

Die Schnittstelle bietet daher eine einzige Operation, bei der ein Block begrenzter Größe übergeben wird und im selben Vorgang ein Block zurückkommt. Ob dieser Block Nutzlast, eine Bestätigung oder eine Anfrage nach dem Ergebnis enthält, spielt für die Schnittstelle keine Rolle, da sie ihn nur befördert und nicht liest. Die drei Phasen in Abbildung 2 unterscheiden sich also nur im Inhalt der Blöcke.

Eine umfangreichere Schnittstelle wäre denkbar, würde aber Übertragungswege ausschließen. Eine Zustellung ohne vorherige Anfrage setzt voraus, dass der Server von sich aus senden kann. Ein Warten auf eine Meldung des Servers setzt zusätzlich voraus, dass er dies zu einem selbst gewählten Zeitpunkt tut. Beides leistet der hier betrachtete Bus nicht, und beides ist auch für die übrigen Vertreter der in Abschnitt 3.5 beschriebenen Klasse nicht vorauszusetzen. Die Schnittstelle bildet daher die Schnittmenge dessen, was alle Übertragungswege dieser Klasse leisten können.

Beide Seiten erfüllen dieselbe Schnittstelle und unterscheiden sich allein in der Richtung, aus der ein Block eintrifft. Der Client übergibt Blöcke und erhält Antworten, der Server nimmt Blöcke entgegen und beantwortet sie. Die Schnittstelle ist also symmetrisch, und eine Änderung des Übertragungswegs betrifft genau eine Stelle pro Seite.

Den Inhalt der Blöcke wertet die Schnittstelle nicht aus, denn sie kennt weder die Zugehörigkeit eines Blocks zu einer Nachricht noch seine Position darin, setzt nichts zusammen, erkennt keine Wiederholungen und ordnet keine Antworten zu. Alles, was eine Struktur voraussetzt, liegt darüber und wird in den folgenden Abschnitten beschrieben. Die Interceptor-Schnittstelle erfüllt damit die Anforderung K6 aus Abschnitt 3.3.

5.2.2 Frame-Struktur

Für die Schnittstelle aus dem vorherigen Abschnitt genügt ein Block ohne weitere Struktur. Die Transportschicht gibt den Blöcken eine Struktur, um aus einer Folge unabhängiger Blöcke eine Nachricht beliebiger Länge zu machen. Dazu benötigt jeder Block neben der Nutzlast Steuerinformationen, die unter anderem die Zugehörigkeit zu einer Nachricht und die Position innerhalb der Nachricht beschreiben. Diese Steuerinformationen werden in einem Header zusammengefasst, der jedem Block vorangestellt wird. Ein Block mit dieser Struktur wird im Folgenden als Frame bezeichnet.

Die folgenden Felder sind für die Rahmung eines Frames notwendig. Größe und Format der Felder werden dabei bewusst nicht vorgegeben, damit der Entwurf auf andere Systeme übertragbar bleibt. Eine konkrete Ausprägung zeigt Abschnitt 6.4, und Abschnitt 7 vergleicht sie mit einer früheren Fassung, die dieselbe Aufgabe mit deutlich mehr Steuerinformationen löste.

Zugehörigkeit: Ohne Kennung der Nachricht lässt sich nicht entscheiden, ob ein eintreffender Block zu einer laufenden Übertragung gehört. Das ist auch bei einem rein synchronen Austausch nötig, bei dem immer nur eine Nachricht gleichzeitig unterwegs ist. Da direkt nach dem Absetzen einer Anfrage gelesen wird, hat die Gegenseite diese unter Umständen noch nicht verarbeitet. Gelesen wird dann die Antwort auf die vorangegangene Anfrage, und erst die Kennung macht solche veralteten Antworten erkennbar.

Position: Die Blöcke müssen in der richtigen Reihenfolge zusammengesetzt werden. Dazu muss die Position jedes Blocks innerhalb der Nachricht bekannt sein. Über die Position lassen sich außerdem Wiederholungen erkennen und verwerfen, die durch Übertragungsfehler oder Paketverlust entstehen.

Art: Über denselben Kanal werden sowohl Nutzlast als auch Steuerinformationen wie Bestätigungen, Anfragen nach dem Ergebnis und Fehlermeldungen übertragen. Da die Schnittstelle selbst nicht zwischen diesen Arten unterscheidet, muss der Header die Art des Blocks angeben.

Länge der Nutzlast: Der Übertragungsweg liefert Blöcke fester Größe, unabhängig davon, wie viel davon tatsächlich genutzt wird. Ohne ausdrückliche Angabe der Länge muss sie aus dem Inhalt abgeleitet werden. Warum das die Schicht an bestimmte Formate bindet, behandelt der nächste Abschnitt.

Ende der Nachricht: Der Empfänger kennt die Gesamtlänge der Nachricht nicht vorab. Daher muss das Ende der Nachricht explizit markiert werden, um zu erkennen, wann die Übertragung abgeschlossen ist. Man könnte das Ende daraus ableiten, dass der letzte Block nicht vollständig gefüllt ist. Ist die Nachrichtenlänge aber ein exaktes Vielfaches der Nutzlastgröße,

ist auch der letzte Block voll und wird nicht als Ende erkannt. Der Empfänger würde dann auf einen Block warten, der nie kommt.

5.2.3 Nutzlastlänge und Formatunabhängigkeit

Neben den Steuerinformationen trägt ein Block die Nutzlast. Der Übertragungsweg liefert Blöcke fester Größe, die Länge der Nutzlast in einem Block ist aber nicht immer gleich. Eine fehlende Längenangabe ist unproblematisch, solange sich das Ende der Nutzlast aus ihrem Format ergibt. Bei textbasierten Formaten wie [JSON](#) oder [XML](#) ist das der Fall, denn sie enthalten keine Nullbytes, sodass Füllbytes am Ende eines Blocks eindeutig erkannt und entfernt werden können. Binäre Formate wie [CBOR](#) oder das in der Referenzimplementierung verwendete [MessagePack](#) besitzen diese Eigenschaft nicht.

Ohne Längenfeld ist die Transportschicht also an textbasierte Formate gebunden. Ein Wechsel des Formats oder die freie Wahl des Formats durch die Entwickler ist dann nicht möglich. Formatunabhängigkeit ist dabei keine ungewöhnliche Anforderung, denn Protokolle wie [HTTP](#) erlauben es beispielsweise, den Inhaltstyp der Nutzlast anzugeben, um verschiedene Formate zu unterstützen [46].

Um Formatunabhängigkeit zu erreichen, muss die Länge der Nutzlast ausdrücklich angegeben werden. Dazu nimmt der Header ein Längenfeld auf, das angibt, wie viele Bytes des Blocks tatsächlich zur Nutzlast gehören.

Die Breite dieses Feldes folgt aus der Blockgröße. Bezeichnet MTU die Größe eines Blocks und H die Größe des Headers, jeweils in Byte, so verbleibt als Nutzlast

$$P = MTU - H \quad (1)$$

Die MTU ist dabei die maximale Größe eines Blocks, die der Übertragungsweg befördern kann. Das Längenfeld muss jeden Wert von 0 bis P ausdrücken können. Seine Breite b in Bit beträgt damit

$$b = \lceil \log_2(P + 1) \rceil \quad (2)$$

Da das Längenfeld selbst Teil des Headers ist, hängen Formel 1 und Formel 2 voneinander ab: H bestimmt P , P bestimmt b , und b geht wieder in H ein. Aufgelöst wird das, indem der kleinste Header gewählt wird, für den beide Gleichungen zugleich gelten. Abschnitt 6.4 führt diese Rechnung für die konkrete Blockgröße aus.

Das Längenfeld ist damit die Voraussetzung für Formatunabhängigkeit.

5.2.4 Kosten der Rahmung

Jedes Byte des Headers ist Overhead und steht nicht für die Nutzlast zur Verfügung. Bei den hier betrachteten Blockgrößen bestimmt dieser Overhead den Aufwand der Übertragung maßgeblich.

Deutlich wird das, wenn Blöcke statt Bytes gezählt werden. Eine Nachricht der Länge L zerfällt in

$$N = \left\lceil \frac{L}{P} \right\rceil \quad (3)$$

Blöcke. Übertragen werden damit $N \cdot MTU$ Bytes, unabhängig davon, wie viel davon genutzt wird. Der letzte Block ist in der Regel nur teilweise gefüllt und wird trotzdem mit der vollen Blockgröße übertragen. Als Maß dient die Nutzlasteffizienz, also das Verhältnis von tatsächlich genutzten zu übertragenen Bytes:

$$\eta = \frac{L}{N \cdot MTU} \quad (4)$$

Daran lässt sich ablesen, wie stark Headergröße und Blockgröße die Effizienz beeinflussen. Wird der Header bei gleicher Blockgröße um ein Byte verkleinert, wächst P um eins, was

nach Formel 3 bereits N um einen ganzen Block verringern kann. Eingespart wird dann eine vollständige Übertragung und somit ein Round Trip.

Neben Blockgröße und Headerbreite beeinflusst auch die Länge der Nutzlast L die Effizienz, die selbst bei gleichem Inhalt vom gewählten Serialisierungsformat abhängt, wobei Abschnitt 7 vergleicht, wie sich zwei verschiedene Formate auswirken. Die Nutzlasteffizienz hängt also von drei Faktoren ab, nämlich von Blockgröße, Headerbreite und Länge der Nutzlast.

Headerbreite und Nutzlastlänge wirken über dieselbe Aufrundung, jedoch auf unterschiedliche Weise, denn eine kürzere Nutzlast senkt N nur dann, wenn sie eine Blockgrenze unterschreitet, während ein kleinerer Header alle Blockgrenzen zugleich verschiebt. Bei kleiner MTU ist deshalb zu erwarten, dass die Rahmung stärker auf die Anzahl der Übertragungen wirkt als die Wahl des Serialisierungsformats, obwohl das Format die Nutzlast direkter verkleinert. Abschnitt 7 prüft diese Erwartung.

5.2.5 Fragmentierung und Rekonstruktion

Die Zerlegung einer Nachricht folgt unmittelbar aus den bisherigen Festlegungen. Die serialisierte Nutzlast wird in Abschnitte von höchstens P Byte geteilt, jeder Abschnitt erhält die Kennung der Nachricht und seine Position, und der letzte wird als solcher markiert. Der letzte Abschnitt ist dabei in der Regel kürzer als P , die tatsächliche Länge trägt das Längenfeld.

Wichtig ist, dass diese Zuordnung eindeutig ist, denn zu einer Nachricht und einer Position gehört immer derselbe Block. Die Zerlegung ist damit wiederholbar und nicht an einen Fortschritt gebunden, also idempotent, sodass die Wiederholung einer Übertragung das Ergebnis nicht verändert.

Wann ist eine Nachricht vollständig?. Die Gesamtlänge einer Nachricht ist dem Empfänger nicht bekannt, er kann die Vollständigkeit also nicht durch einen Vergleich mit ihr feststellen, sondern nur an den eingetroffenen Blöcken erkennen. Trägt der Block an Position n die Endmarkierung, besteht die Nachricht aus $n + 1$ Blöcken. Vollständig ist sie, sobald jede Position von 0 bis n mindestens einmal eingetroffen ist.

Die Steuerinformationen haben dabei verschiedene Aufgaben, denn Endmarkierung und Position bestimmen, wie viele Blöcke zur Nachricht gehören, während das Längenfeld angibt, wie viele Bytes eines Blocks dazugehören. Die Prüfung auf Vollständigkeit kommt somit ohne Kenntnis des Inhalts aus.

Was passiert bei Übertragungswiederholungen?. Ein Block wird erneut übertragen, wenn die zugehörige Bestätigung ausbleibt. Das kann daran liegen, dass er den Empfänger nicht erreicht hat, dass ihn eine Prüfsumme des Übertragungswegs als beschädigt verworfen hat oder dass die Bestätigung selbst verloren ging. Für den Sender sind diese Fälle nicht unterscheidbar, weshalb er in allen gleich reagiert und den Block erneut sendet. Die Mechanismen dafür werden in Abschnitt 5.2.7 beschrieben.

Da die Zerlegung eindeutig ist, hat der wiederholte Block denselben Inhalt wie der ursprüngliche, was dem Empfänger allein jedoch nicht hilft, denn hängt er den Block ein zweites Mal an, entsteht eine falsche Nachricht. Die Rekonstruktion muss Wiederholungen deshalb selbst abfangen und Blöcke verwerfen, deren Position bereits vorliegt, wodurch auch sie idempotent wird.

Was passiert bei einer abgebrochenen Übertragung?. Bricht eine Übertragung ab, bevor die Nachricht vollständig ist, bleiben die bereits eingetroffenen Blöcke liegen. Der Empfänger kann nicht entscheiden, ob die Übertragung noch fortgesetzt wird, da er weder die Gesamtzahl der Blöcke noch einen Zeitpunkt kennt, zu dem er aufgeben dürfte. Erkennbar wird der Abbruch erst daran, dass eine neue Übertragung beginnt, also ein Block an Position 0 eintrifft. Die Position ist dafür verlässlicher als die Kennung, da sich die Kennung nach einer festen Anzahl von Nachrichten wiederholt.

Für den Umgang mit den liegengebliebenen Blöcken bestehen zwei Möglichkeiten:

- Die unvollständige Nachricht wird verworfen, sobald eine neue beginnt. Das ist der einfachere Weg, setzt aber voraus, dass nie mehr als eine Nachricht gleichzeitig übertragen wird.
- Die unvollständige Nachricht bleibt erhalten und kann später fortgesetzt werden. Das erlaubt mehrere gleichzeitige Übertragungen, verlangt aber einen Puffer je Kennung, eine Regel, wann eine Nachricht endgültig aufgegeben wird, und eine Laufzeitumgebung, die mehrere Übertragungen nebenläufig verwalten kann.

Der Entwurf wählt die erste Möglichkeit, da die betrachtete Verbindungsklasse anfragegetrieben ist und der Client ohnehin nur eine Nachricht zugleich senden kann. Hinzu kommt, dass die in Abschnitt 3.4 beschriebene Laufzeitumgebung die für die zweite Möglichkeit nötige Nebenläufigkeit nicht bereitstellt.

Wie viel Speicher benötigt die Rekonstruktion? Der Empfänger muss alle Blöcke einer Nachricht halten, bis sie vollständig ist. Anforderung K5 verlangt dafür eine zur Entwurfszeit bekannte Obergrenze, die sich aus den bisherigen Festlegungen ergibt. Ist b_{pos} die Breite des Positionsfelds in Bit, lassen sich $2^{b_{\text{pos}}}$ Positionen unterscheiden, und die längste übertragbare Nachricht umfasst höchstens

$$L_{\text{max}} = 2^{b_{\text{pos}}} \cdot P \quad (5)$$

Bytes. Dieser Wert ist zugleich die Obergrenze des Puffers, den die Gegenseite bereithalten muss.

5.2.6 Serialisierung

Die in Abschnitt 2.2 eingeführte Serialisierung überführt einen strukturierten Wert in eine Bytefolge und liest ihn auf der Gegenseite wieder aus. Sie liegt damit zwischen der Kommunikationsschicht, die mit Werten arbeitet, und der Fragmentierung, die mit Bytes arbeitet. Aus Abschnitt 5.2.3 folgt dabei eine Reihenfolge, denn das Format kann erst dann frei gewählt werden, wenn die Rahmung die Länge der Nutzlast ausdrücklich mitführt.

Für die Transportschicht ist die Nutzlast ohne Struktur. Sie nimmt eine Bytefolge entgegen, zerlegt sie und setzt sie auf der Gegenseite wieder zusammen. Welche Werte darin vorkommen und wie sie angeordnet sind, wertet sie nicht aus, sodass das Format austauschbar ist, ohne dass die Rahmung geändert werden muss.

Die Wahl des Formats ist an drei Bedingungen gebunden, die sich aus den bisherigen Abschnitten ergeben.

Erstens muss das Format kompakt sein. Nach Formel 3 bestimmt die Länge der Nutzlast unmittelbar die Anzahl der Blöcke, in die eine Nachricht zerfällt, und damit die Anzahl der Übertragungen.

Zweitens muss es ohne Schema auskommen. Welche Objekte und Methoden es gibt, steht nicht vorab fest und ändert sich während der Entwicklung. Ein schemagebundenes Format würde einen Übersetzungsschritt einführen und die Kommunikationsschicht an diesen Schritt binden.

Drittens muss der Decoder klein sein. Er läuft auf beiden Seiten der Verbindung, und beide sind Mikrocontroller. Anforderung K5 gilt hier also auch für den Umfang der eingesetzten Bibliothek und nicht nur für die Puffer.

Welches Format diese Bedingungen erfüllt, zeigt Abschnitt 6. Wie stark sich die Wahl auf die Anzahl der Übertragungen auswirkt, misst Abschnitt 7.

5.2.7 Zuverlässigkeitsmechanismen

Die bisherigen Abschnitte setzen voraus, dass ein Block die Gegenseite erreicht, was jedoch nicht garantiert ist. Ein Block kann auf dem Weg verloren gehen oder vom Übertragungsweg als beschädigt verworfen werden, zudem kann die Bestätigung ausbleiben, obwohl der Block angekommen ist.

Für diese Fälle wird Stop-and-Wait [Automatic Repeat reQuest \(ARQ\)](#) [44] verwendet, bei dem ein Block gesendet und auf dessen Bestätigung gewartet wird, die bei Ausbleiben

ein erneutes Senden des Blocks auslöst. Verfahren mit Sendefenster erlauben dagegen mehrere unbestätigte Blöcke gleichzeitig und erreichen dadurch einen höheren Durchsatz, weshalb sie weit verbreitet sind und beispielsweise in Mobilfunkstandards und in [TCP](#) eingesetzt werden. Sie setzen jedoch voraus, dass mehrere Blöcke gleichzeitig unterwegs sein können und die Gegenseite Bestätigungen ohne eigene Anfrage zurücksenden kann. In der betrachteten Verbindungsklasse besteht jede Übertragung aus Anfrage und Antwort, sodass ohnehin nie mehr als ein Block unterwegs ist. Stop-and-Wait bildet damit genau das ab, was die Verbindung zulässt.

Die drei genannten Fehlerfälle sind für den Sender nicht unterscheidbar, da er in allen Fällen dasselbe sieht, nämlich eine ausbleibende Bestätigung. Eine Unterscheidung würde zudem nichts bringen, weil die Reaktion immer dieselbe ist. Der Empfänger erkennt die Wiederholung an der Position und verwirft sie, wie in Abschnitt 5.2.5 beschrieben.

Wiederholungen brauchen eine Obergrenze, denn ohne sie wartet der Client endlos, sobald der Server dauerhaft nicht antwortet. Aus einem Fehler auf der einen Seite wird dann ein Stillstand der Anwendung auf der anderen. Mit einer Obergrenze scheitert der Aufruf nach einer bekannten Zeit und die Anwendung behält die Kontrolle. Das ist zugleich die Voraussetzung dafür, dass K4 geprüft werden kann, denn eine Antwortzeit lässt sich nur angeben, wenn sie nach oben begrenzt ist.

Dieselbe Überlegung gilt für das Abholen des Ergebnisses, denn der Client fragt so lange nach, bis ein Ergebnis vorliegt, und benötigt auch dafür eine Obergrenze. Für den Server folgt daraus die Zusicherung, dass jeder Aufruf ein Ergebnis oder eine Fehlermeldung hinterlassen muss, auch wenn die Ausführung selbst fehlschlägt. Bleibt beides aus, wartet der Client auf etwas, das nie eintritt. Die Fehlerbehandlung ist damit Teil des Protokolls und wird nicht der Umsetzung überlassen.

Drei Aufgaben übernimmt die Schicht ausdrücklich nicht. Sie korrigiert keine Fehler, sondern verlässt sich auf die Prüfsumme des Übertragungswegs und wiederholt den betroffenen Block. Sie sichert die Reihenfolge nicht gesondert ab, da der Kanal sequenziell arbeitet, wobei das Positionsfeld die Rekonstruktion gleichwohl von der Reihenfolge unabhängig macht. Außerdem betreibt sie keine Stauvermeidung, da auf einer Punkt-zu-Punkt-Verbindung mit einem Master und einer einzigen Nachricht gleichzeitig kein Stau entstehen kann.

5.3 Kommunikationsschicht

Mit der Transportschicht lassen sich Nachrichten beliebiger Länge übertragen, was für eine Anwendung jedoch noch keine geeignete Schnittstelle darstellt, da sie mit Methodenaufrufen arbeitet. Diese Lücke schließt die Kommunikationsschicht, indem sie einen Aufruf auf eine Nachricht abbildet, ihn über die Transportschicht befördert und das Ergebnis an die aufrufende Stelle zurückgibt.

Von der Transportschicht kennt sie nur zwei Vorgänge, nämlich das Senden einer Nachricht und das Eintreffen einer Antwort. In wie viele Blöcke die Nachricht dabei zerfällt, wie oft ein Block wiederholt wird und in welchem Format die Nutzlast vorliegt, bleibt verborgen.

Die Schicht stellt einen [RPC](#) her, wie er in Abschnitt 2 eingeführt wurde. Die Anwendung ruft eine Methode auf, die auf einem anderen Gerät ausgeführt wird, und erhält deren Rückgabewert, wobei an der Aufrufstelle nicht erkennbar ist, dass eine Übertragung stattgefunden hat, was als Aufruftransparenz bezeichnet wird.

Die dort betrachteten Rahmenwerke setzen dafür Eigenschaften voraus, die diese Verbindung nicht bietet. Sie erwarten einen Transport, der Nachrichten beliebiger Länge zuverlässig befördert, und einen Rückkanal, über den der Server sein Ergebnis von sich aus zustellt. Beides ist hier nicht gegeben, weshalb die folgenden Abschnitte einen eigenen Aufrufmechanismus entwickeln, der mit den Mitteln der Transportschicht auskommt.

Dabei ist zu klären, welche Angaben eine Aufrufnachricht mitführen muss, wie eine Antwort ihrer Anfrage zugeordnet wird, wie der Server den zuständigen Empfänger auswählt und auf welchem Weg ein Ergebnis zurückgelangt.

5.3.1 Aufbau einer Aufrufnachricht

Ein [RPC](#) muss so viel mitführen, dass der Server den Aufruf ohne weitere Rückfrage durchführen kann, wofür drei Angaben nötig sind. Die Methodenkennung legt fest, was ausgeführt wird, die Argumente liefern die Werte, mit denen es ausgeführt wird, und der Scope bestimmt, welcher Empfänger die Methode ausführt. Wie das funktioniert, beschreibt der übernächste Abschnitt.

Angaben über Typen oder Signaturen werden nicht mitgeführt, denn nach Abschnitt 5.2.6 kommt das Format ohne Schema aus und überträgt nur Werte, keine Beschreibungen von Werten. Ob eine Methode existiert oder bestimmte Argumente erwartet, stellt sich somit erst auf dem Server und damit zur Laufzeit heraus.

Das Ergebnis nimmt denselben Weg zurück und ist ebenfalls eine Nachricht, die entweder den Rückgabewert oder eine Fehlermeldung trägt. Welcher der beiden Fälle vorliegt, ist am Schlüssel zu erkennen, unter dem der Inhalt steht. Das folgt aus der Zusicherung in Abschnitt 5.2.7, denn der Client wartet auf genau eine Antwort und muss auch im Fehlerfall eine erhalten.

Diese Angaben werden mit jedem Aufruf übertragen, und nach Formel 3 wirkt sich ihre Länge direkt auf die Anzahl der Blöcke aus. Zwei Festlegungen halten sie deshalb kurz. Die Argumente werden in der Reihenfolge der Parameter übertragen, ohne ihre Namen. Die Methode wird über eine Kennung fester Länge bezeichnet, die beide Seiten auf dieselbe Weise aus ihrem Namen berechnen, sodass keine Tabelle zwischen Namen und Kennungen gepflegt werden muss.

Beide Festlegungen setzen voraus, dass Client und Server dieselbe Schnittstelle kennen. Sie erreichen damit dasselbe wie ein schemagebundenes Format, das Bezeichner einmal vorab vereinbart und in der Nachricht nur noch Werte überträgt. Als Vereinbarung dient hier die gemeinsame Schnittstelle der Objekttypen aus Abschnitt 4. Es entsteht kein eigener Übersetzungsschritt, und das Serialisierungsformat bleibt schemafrei.

Fehler in dieser Vereinbarung fallen unterschiedlich auf. Eine unbekannte Methodenkennung erkennt der Server und antwortet mit einer Fehlermeldung, während eine abweichende Reihenfolge der Argumente nur auffällt, wenn sich dabei ihre Anzahl ändert. Vertauschte Werte gleicher Art werden dagegen ohne Fehler ausgeführt.

5.3.2 Zuordnung von Anfrage und Antwort

Jede Antwort muss der Anfrage zugeordnet werden, zu der sie gehört. Der Frame führt nach Abschnitt 5.2.2 bereits eine Kennung je Nachricht mit, und ein Aufruf entspricht genau einer Nachricht. Diese Kennung identifiziert also zugleich den Aufruf, und eine zweite Angabe in der Nutzlast ist nicht nötig.

Die Kennung stammt damit aus dem Header, und ihr Wertebereich folgt aus dessen Breite. Sie wiederholt sich nach einer festen Anzahl von Aufrufen, was zulässig ist, solange zwischen zwei gleichen Kennungen kein älteres Ergebnis mehr unterwegs sein kann. Eine eigene Kennung der Kommunikationsschicht wäre von der Headerbreite unabhängig, müsste aber in jeder Nachricht zusätzlich übertragen werden und würde nach Formel 3 die Anzahl der Übertragungen erhöhen. Die Übernahme der Kennung aus dem Header ist also eine Abwägung zwischen doppelten Steuerinformationen und einer strengen Trennung der Schichten.

5.3.3 Verteilung eingehender Aufrufe

Der Server erhält eine Nachricht mit Methodenkennung, Argumenten und Scope und muss daraus bestimmen, wer den Aufruf ausführt. Die Adressierung ist zweistufig und mit dem Routing in [REST](#)-Frameworks vergleichbar. Dort ist ein Controller für einen Ressourcentyp zuständig, eine Methode darin für die Operation, und die Kennung der einzelnen Ressource kommt als Parameter an. Hier benennt der Scope die Art des Empfängers, der Methodenname die Operation, und die Referenz des einzelnen Objekts reist als Argument mit.

Der Unterschied liegt im Satz der Operationen. **REST** beschränkt ihn auf wenige festgelegte Verben, während hier jede Methode des Objektmodells aufrufbar ist. Die Referenz ist außerdem kein Pfad, sondern eine Kennung, die der Server beim Erzeugen des Objekts vergibt. Wie sie gebildet wird, gehört zum Objektmodell und wird in Abschnitt 6.6 gezeigt.

Die zweistufige Adressierung hat einen weiteren Vorteil, da die Kennungen der Methoden nur innerhalb eines Scopes eindeutig sein müssen. Gleichnamige Methoden können somit auf verschiedenen Arten von Empfängern nebeneinander bestehen, und eine zufällige Übereinstimmung zweier Kennungen stört nur, wenn sie im selben Scope auftritt. Der Server prüft das beim Registrieren eines Empfängers und nicht erst beim Aufruf.

Verteilung und Ausführung bleiben dabei getrennt, denn die Verteilung wählt anhand des Scopes den Empfänger aus, während die Ausführung beim Empfänger selbst liegt. Ein weiterer Empfänger kann somit registriert werden, ohne die Verteilung oder die darunterliegenden Schichten zu ändern, wodurch sich das Objektmodell erweitern lässt.

Findet sich für einen Scope kein Empfänger, muss der Aufruf mit einer Fehlermeldung beantwortet werden. Nach Abschnitt 5.2.7 wartet der Client auf genau eine Antwort, und ein stillschweigendes Verwerfen würde ihn bis zur Obergrenze warten lassen.

5.3.4 Anfragegetriebener Rückkanal

Aufgrund der eingeschränkten Kommunikationsrichtung aus Abschnitt 3.4 kann der Server keine Übertragung anstoßen. Ein Ergebnis kann er deshalb nicht zustellen, sondern nur bereithalten, bis es abgeholt wird. Hinzu kommt, dass die Ausführung noch nicht abgeschlossen ist, wenn der letzte Block des Aufrufs bestätigt wurde. Der Client muss also zunächst feststellen, ob ein Ergebnis vorliegt, und es anschließend abholen.

Ereignisse folgen demselben Muster, unterscheiden sich jedoch in einem Punkt. Ein Ergebnis erwartet der Client, weil er den zugehörigen Aufruf abgesetzt hat, ein Ereignis dagegen nicht, sodass er regelmäßig nachfragen muss, ohne zu wissen, ob es etwas abzuholen gibt.

Die zeitliche Auflösung hängt damit vom Abfragetakt ab, denn ein Ereignis, das zwischen zwei Abfragen auftritt, wird erst bei der nächsten bemerkt. Häufigeres Abfragen verkürzt zwar diese Verzögerung, kostet jedoch je Abfrage eine Übertragung und damit Zeit, die für Aufrufe fehlt, während selteneres Abfragen Übertragungen spart und die Verzögerung verlängert. Beide Ziele lassen sich also nicht zugleich erreichen.

Zwischen zwei Abfragen können mehrere Ereignisse auftreten, die der Server puffern muss, wobei der Puffer nach K5 begrenzt ist. Läuft er über, gehen Ereignisse verloren, weshalb für diesen Fall ein Verhalten festgelegt sein muss, da ein stilles Verwerfen für die Anwendung nicht erkennbar wäre.

Am anfragegetriebenen Rückkanal wirkt sich die eingeschränkte Kommunikationsrichtung direkt auf die Anwendung aus. Ob die erreichbare Antwortzeit die Anforderung K4 einhält, prüft Abschnitt 7. Eine Möglichkeit, diesen Weg für reine Darstellungsreaktionen zu umgehen, zeigt Abschnitt 6.7.

6 Referenzimplementierung

Dieses Kapitel bildet den Entwurf aus Abschnitt 4 und Abschnitt 5 auf eine konkrete Hardware, zwei konkrete Laufzeitumgebungen und einen konkreten Bus ab. Hier stehen die Zahlen, die der Entwurf offengelassen hat, also die Blockgröße, die Breite der Felder im Header und das gewählte Serialisierungsformat. Der Aufbau folgt den Schichten von unten nach oben und schließt mit dem Ablauf eines vollständigen Aufrufs sowie der Nebenläufigkeit.

6.1 Laufzeitumgebung

Client und Server laufen beide unter MicroPython, allerdings in sehr unterschiedlichen Ausprägungen.

Auf dem Hub läuft Pybricks [41], eine Firmware, die die Software von LEGO ersetzt und eine stark reduzierte Variante von MicroPython bereitstellt. Für die Umsetzung sind vier Einschränkungen von Bedeutung. Ganzzahlen sind auf $2^{30} - 1$ begrenzt, da die Firmware ohne Unterstützung für lange Ganzzahlen übersetzt ist, und schon eine größere Konstante im Quelltext verhindert das Laden des Moduls. Threads stehen nicht zur Verfügung, ebenso wenig einige Teile der Standardbibliothek wie `memoryview` oder das Modul `warnings`. Außerdem nimmt der Hub nur einzelne Dateien an, keine Pakete mit Unterverzeichnissen.

Grund für die alternative Firmware sind die Einschränkungen von LEGO. Der Hub ist ein geschlossenes System, das nur die von LEGO bereitgestellten Sensoren und Aktoren akzeptiert. Erst die Pybricks-Firmware [41] erlaubt die Anbindung externer Geräte, jedoch auch nur durch die bereitgestellte Schnittstelle LPF2 und PupRemote [31], [38].

Die Module der Middleware liegen dagegen in einer Paketstruktur. Ein eigenes Werkzeug, der Bundler in `tools/bundler.py`, führt deshalb alle Module, die der Client benötigt, zu einer einzigen Datei `pybricks_bundle.py` zusammen. Er löst die Importe innerhalb des Projekts auf, sortiert die Module so, dass jedes nach seinen Abhängigkeiten steht, und ersetzt dabei `struct` durch das auf dem Hub vorhandene `ustruct`. Das Anwendungsprogramm auf dem Hub importiert anschließend nur noch diese Datei.

Auf dem ESP32 läuft MicroPython mit der Anbindung an `LVGL`, wobei diese Umgebung deutlich umfangreicher ausfällt und lange Ganzzahlen, Threads, `uasyncio` sowie einen Zufallszahlengenerator bietet. Knapp ist hier vor allem der Arbeitsspeicher, da `LVGL` einen großen Teil des Heaps für die Darstellung belegt. Welche Folgen das für die Nebenläufigkeit hat, beschreibt Abschnitt 6.9.

Der gemeinsame Code muss in beiden Umgebungen laufen und richtet sich deshalb nach der engeren, also nach Pybricks. Das betrifft vor allem die Transportschicht, den Codec und die Stellvertreter. Code, der nur auf dem Server läuft, darf die Möglichkeiten des ESP32 nutzen. Tabelle III ordnet die Module der Referenzimplementierung den Schichten aus Abschnitt 4 zu.

Tabelle III: Zuordnung der Module zu den Schichten aus Abschnitt 4

Schicht	Module
Anwendung und Anzeige	hub/main.py , display/server/driver/
Objektmodell	display/protocol/ , display/client/ mit remote.py , display/server/ , middleware/rpc/registry.py
Kommunikations-schicht	middleware/rpc/dispatcher.py , middleware/rpc/names.py , middleware/errors.py , Aufrufteil von transport/pupremote/client.py und server.py
Transportschicht	middleware/frame.py , message.py , codec.py , queue.py , constants.py , Übertragungsteil von client.py und server.py
Busanbindung	transport/base.py , transport/pupremote/binding.py , vendor/pupremote/

6.2 Hardwareaufbau

Der Hardwareaufbau ist kein eigener Beitrag dieser Arbeit, sondern der Träger, auf dem die Software läuft. Er besteht deshalb aus handelsüblichen Baugruppen, die über eine einfache Adapterplatine verbunden werden. Eine eigene Schaltungsentwicklung, etwa für die Spannungsversorgung, findet nicht statt.

6.2.1 Aufbau und Komponenten

Der Aufbau erfüllt die Anforderungen D1 bis D3 und S1 bis S3 aus Abschnitt 3.1 mit handelsüblichen Baugruppen. Das Displaymodul bietet die geforderte grafische Darstellung und die Berührungseingabe bei einer für Embedded-Anwendungen typischen Auflösung, das ESP32-Board die nötigen Schnittstellen, genügend Speicher für die Anzeigebibliothek und eine Anbindung an den Bus des Hubs.

Der Aufbau besteht aus drei Teilen. Das LMS-ESP32-Board [38] bildet den Mikrocontroller der Anzeigeeinheit, wird über das Kabel eines LEGO-Sensors direkt an einen Port des Hubs angeschlossen und übernimmt die Busanbindung. Das Displaymodul enthält das **TFT**-Display mit dem Controller ILI9341[47], einen kapazitiven Touchcontroller sowie einen Steckplatz für eine SD-Karte. Die Adapterplatine verbindet schließlich beide Baugruppen und enthält dabei keine aktiven Bauteile, sondern lediglich Steckverbinder und Leiterbahnen.

Signalseitig benötigt die in Abschnitt 6.3 beschriebene Anbindung nur eine **UART**-Verbindung auf zwei Leitungen des ESP32, die das LMS-ESP32-Board bereits zum Anschluss des Hubs führt. Die Adapterplatine muss sich deshalb nur um die Signale des Displays kümmern. Versorgt wird der Aufbau über den Port des Hubs, im beschriebenen Aufbau über Port B, wobei der ESP32 die 8V-Versorgung anfordert, da das Display mehr Strom benötigt, als die Logikversorgung liefert. Wie Abschnitt 3.4 beschreibt, verkürzt das die zulässige Länge der Kommandonamen auf fünf Zeichen.

6.2.2 Signalzuordnung und Aufbau der Adapterplatine

Das Display wird über **SPI** angesteuert, der Touchcontroller über **I2C**, wobei Abbildung 7 im Anhang die Schaltung der Adapterplatine zeigt. Die SPI-Leitungen MOSI, MISO, SCK und CS sind an den ESP32 geführt, ebenso der Touchcontroller über SDA und SCL.

Die Hintergrundbeleuchtung ist nicht an den ESP32 geführt und leuchtet dauerhaft. Die Interrupt-Leitung des Touchcontrollers ist zwar verbunden, wird jedoch nicht genutzt, da der Controller abgefragt wird (Abschnitt 6.7). Gleiches gilt für die Auswahlleitung der SD-Karte, die ebenfalls an den ESP32 geführt ist, während die SD-Karte selbst in dieser Arbeit nicht verwendet wird.

Bei der Pinbelegung ist GPIO 12 zu beachten. Der Pin wird beim Start des ESP32 ausgelesen und legt die Spannung des Flash-Speichers fest. Solange nur das Display an MISO hängt, ist das unkritisch, da die Leitung beim Start kaum getrieben wird. Wird die SD-Karte genutzt, teilt sie sich diese Leitung und kann sie über ihren Pull-up-Widerstand beim Start auf High ziehen, sodass der ESP32 nicht mehr zuverlässig startet. Für eine spätere Nutzung der SD-Karte müsste MISO deshalb auf einen anderen Pin gelegt werden.

Die Platine wurde mit KiCad entworfen und extern gefertigt, wobei beide Baugruppen aufgesteckt werden und sich ohne Löten tauschen lassen. Eine integrierte Trägerplatine, die ESP32, Display und Versorgung auf einer Platine vereint, war ursprünglich als zweite Ausbaustufe geplant. Sie wurde aus Zeitgründen nicht umgesetzt und wird in Abschnitt 8 als Erweiterung aufgegriffen.

6.3 Busanbindung

Die Busanbindung wird nicht entworfen, sondern vorgefunden, denn beide Seiten verwenden PUPRemote [31] in Version 1.6, auf dem Hub als `PUPRemoteHub` und auf dem ESP32 als `PUPRemoteSensor`. Die Bibliothek setzt das LPF2-Protokoll um, über das der Hub mit angeschlossenen Sensoren kommuniziert.

Gegenüber dem Hub gibt sich der ESP32 als Ultraschallsensor aus, da der Hub nur Geräte mit bekannter Kennung annimmt. Beim Verbindungsaufbau handeln beide Seiten zunächst bei 2400 Baud die Eigenschaften des Geräts aus und wechseln anschließend auf 115200 Baud. Danach überwacht die Bibliothek die Verbindung selbstständig und baut sie nach einem Abbruch neu auf. Zusätzlich fordert der ESP32 die 8-V-Versorgung am Port an, da das Display mehr Strom benötigt, als die Logikversorgung liefert.

PUPRemote bildet benannte Kommandos auf die Modi des Busses ab und bringt dafür eine eigene Aufrufsemantik mit festen Formaten je Kommando mit, die hier jedoch nicht genutzt wird. Registriert ist stattdessen ein einziges Kommando `xfer`, dessen Format in beide Richtungen ein Block von 16 Byte ist, siehe Listing 1. Für PUPRemote besitzt dieser Block keine Struktur, sodass alles Weitere in den Schichten darüber liegt.

```
COMMAND = "xfer"

def register_interceptor(self):
    self.remote.add_command(
        self.COMMAND,
        from_hub_fmt=f"{FRAME_SIZE}s",
        to_hub_fmt=f"{FRAME_SIZE}s",
    )
```

Listing 1: Registrierung des einzigen Kommandos

Ein Austausch im Sinne von Abschnitt 5.2.1 ist auf dem Hub ein Aufruf von `remote.call`. Dabei wird der Block in den Modus des Kommandos geschrieben und anschließend der Inhalt desselben Modus zurückgelesen. Zwischen beidem wartet die Bibliothek nicht, sofern keine Wartezeit angegeben ist. Hat der ESP32 den Block bis zum Lesen noch nicht verarbeitet, liefert der Lesevorgang die vorige Antwort. Solche veralteten Antworten erkennen die darüberliegenden Schichten an Kennung, Position und Art des Frames, wie in Abschnitt 5.2.7 beschrieben.

Auf dem ESP32 ruft ein Task der Ereignisschleife etwa jede Millisekunde `process` auf, wobei je Durchlauf höchstens ein Kommando bearbeitet wird. Für jedes eintreffende Kommando ruft PUPRemote den registrierten Rückruf auf. Die Bibliothek findet ihn, indem sie den Kommandonamen im Namensraum des Hauptprogramms auswertet. Das Hauptprogramm muss den Rückruf deshalb unter dem Namen `xfer` bereitstellen.

Zwei Grenzen der Busanbindung wirken sich auf den gesamten Entwurf aus. Die Blockgröße ist mit der Firmware des Hubs auf 16 Byte begrenzt, darüber treten Prüfsummenfehler auf. Außerdem dürfen Kommandonamen bei angeforderter 8-V-Versorgung höchstens fünf Zeichen

lang sein. Oberhalb dieser Schicht ist davon nur noch die Blockgröße sichtbar, und zwar als Zahl, aus der Abschnitt 6.4 die Nutzlast ableitet.

6.4 Transportschicht

Die Transportschicht setzt den Entwurf aus Abschnitt 5.2.2 in konkrete Feldbreiten um. Die folgenden Abschnitte beschreiben den Aufbau eines Frames, die Zerlegung einer Nachricht in Frames und die Serialisierung der Nutzlast.

6.4.1 Frame

Die Blockgröße ist durch die Busanbindung vorgegeben, da die Firmware des Hubs einen Modus auf 16 Byte begrenzt. Damit steht die in Abschnitt 5.2.3 eingeführte *MTU* fest, und alle weiteren Größen leiten sich daraus ab.

Der Header belegt drei Byte.

Tabelle IV: Aufbau des Frame-Headers

Byte	Bits	Inhalt
0	8	Kennung der Nachricht
1	8	Position innerhalb der Nachricht
2	4 obere	Art des Frames
2	4 untere	Länge der Nutzlast in Byte

Tabelle IV zeigt den Aufbau des Headers, der für die Nutzlast 13 Byte je Frame übrig lässt.

Diese Aufteilung erfüllt die Bedingungen aus Abschnitt 5.2.3. Bei einem Header von drei Byte ergibt Formel 1 eine Nutzlast von 13 Byte, und Formel 2 verlangt dafür ein vier Bit breites Längenfeld. Die obere Hälfte des dritten Bytes enthält die Art des Frames, die untere Hälfte die Länge der Nutzlast, sodass das Längenfeld den Header nicht vergrößert. Ein Header von zwei Byte wäre nur möglich, wenn Kennung oder Position schmaler ausfielen, was die Anzahl unterscheidbarer Nachrichten oder die maximale Nachrichtenlänge verringern würde.

Listing 2 zeigt die Umwandlung von Bytes in einen Frame, bei der auch eine zu kurze Eingabe abgefangen und das dritte Byte in Art und Länge aufgeteilt wird.

```
@classmethod
def from_bytes(cls, data):
    if data is None or len(data) < cls.HEADER_SIZE:
        return cls.create_error(payload=b"short")

    g_id, frame_nr, b2 = unpack(cls._header_fmt, bytes(data[:cls.HEADER_SIZE]))
    length = b2 & 0x0F
    start = cls.HEADER_SIZE

    return cls(g_id, frame_nr, b2 >> 4, data[start:start + length])
```

Listing 2: Funktion zur Erzeugung eines Frames aus Bytes

Gültig bleibt die Aufteilung, solange die Nutzlast 15 Byte nicht überschreitet, da das Längenfeld keine größeren Werte darstellen kann. Bei einem Header von drei Byte entspricht das einer Blockgröße von höchstens 18 Byte. Größere Blöcke würden ein Längenfeld von einem vollen Byte und damit einen Header von vier Byte erfordern. Listing 3 zeigt die umgekehrte Umwandlung eines Frames in Bytes, bei der eine zu lange Nutzlast abgewiesen wird.

```

def to_bytes(self):
    n = len(self.payload)
    if n > MAX_PAYLOAD:
        raise ValueError("payload grew beyond {} bytes: {}".format(MAX_PAYLOAD, n))

    b2 = (self.opcode << 4) | n

    return pack(self._header_fmt, self.g_id, self.frame_nr, b2) + self.payload

```

Listing 3: Funktion zur Umwandlung eines Frames in Bytes

Die Position hat durch ihre Breite von acht Bit einen Wertebereich von 0 bis 255. Der Wert `0xFF` ist für Frames reserviert, die sich auf keine Position innerhalb einer Nachricht beziehen. Für Nutzlastframes stehen damit 255 Werte zur Verfügung, was nach Formel 5 die Länge einer Nachricht auf $13 \cdot 255 = 3315$ Byte begrenzt. Dieser Wert ist zugleich die nach K5 geforderte Obergrenze des Puffers.

Für die Art des Frames sind von 16 darstellbaren Werten acht belegt (siehe Tabelle V). Acht Werte kämen gerade noch mit drei Bit aus, allerdings bliebe dann kein Wert für eine weitere Art frei. Das eingesparte Bit würde außerdem nichts bringen, denn im Längenfeld könnte es Werte bis 31 darstellen, obwohl die Nutzlast 13 Byte nie überschreitet. In der Position würde es über die Bytegrenze hinausreichen und Bitoperationen über zwei Byte erfordern. Die Breite von vier Bit ist daher eine pragmatische Entscheidung.

Tabelle V: Werte für die Art des Frames und ihre Bedeutung

Wert	Name	Bedeutung
0x0	DATA	Nutzlastframe, weitere folgen
0x1	DATA_LAST	Nutzlastframe, letzter der Nachricht
0x2	ACK	Bestätigung eines empfangenen Frames
0x3	NACK	Ergebnis noch nicht bereit oder nichts weiter vorhanden
0x4	ERR	Fehlermeldung, kann eine kurze Beschreibung tragen
0x5	READY	Anfrage, ob ein Ergebnis bereitliegt
0x6	NEXT	Anfrage nach dem Ergebnisframe an der angegebenen Position
0x7	DONE	Antwort auf READY, das Ergebnis liegt zur Abholung bereit

6.4.2 Message

Ein `Message`-Objekt enthält die Kennung und die serialisierte Nutzlast einer Nachricht. Es dient beiden Seiten als Container für die Nachricht, die über den Bus übertragen wird. Beim Senden wird die Nutzlast gesetzt, und das Objekt liefert daraus die Frames. Beim Empfangen werden Frames gesammelt, und daraus wird die Nutzlast rekonstruiert.

Die Zerlegung ist als Funktion über Position und Nutzlast umgesetzt. In einer früheren Version lieferte ein Generator die Frames nacheinander. Diese Variante wurde verworfen, da sie das Wiederholen einzelner Frames erschwerte.

Listing 4 berechnet den zugehörigen Abschnitt direkt aus dem Index, ohne einen Fortschritt mitzuführen. Dieselbe Position liefert damit immer denselben Frame, wie es Abschnitt 5.2.5 fordert. Der Rückkanal ist darauf angewiesen, da er Ergebnisframes einzeln über ihre Position anfordert und dieselbe Position mehrfach anfragen kann.

```

def frame_at(self, index: int):
    if index < 0:
        return None

    start = index * PAYLOAD_SIZE
    if start >= len(self.payload) and not (index == 0 and not self.payload):
        return None

    chunk = self.payload[start:start + PAYLOAD_SIZE]
    last = start + PAYLOAD_SIZE >= len(self.payload)

    return Frame(
        g_id=self.g_id,
        frame_nr=index % 256,
        opcode=OP_DATA_LAST if last else OP_DATA,
        payload=chunk,
    )

```

Listing 4: Funktion zur Erzeugung von Frames aus einer Nachricht

Für das Einsammeln eingehender Frames gibt es zwei Wege, die sich in Speicherbedarf und Zusicherung unterscheiden. `collect_frame` behält jeden Frame, bis die Nachricht vollständig ist, und sortiert die Frames nach ihrer Position. Diese Variante ist von der Reihenfolge der Ankunft unabhängig, hält aber alle Frames einer Nachricht gleichzeitig im Speicher. `append_frame` hängt die Nutzlast direkt an und verwirft den Frame, was Speicher spart, aber die richtige Reihenfolge voraussetzt. `get_payload` liefert in beiden Fällen die vollständige Nutzlast.

Der Rückkanal verwendet den sammelnden Weg, der Hinweg den anhängenden. Die in Abschnitt 5.2.5 beschriebene Unabhängigkeit von der Reihenfolge ist damit nur auf dem Rückkanal umgesetzt. Für den hier betrachteten Bus genügt das, da er sequenziell arbeitet. Bei einem Übertragungsweg, der umsortiert, müsste auch der Hinweg auf den sammelnden Weg wechseln.

6.4.3 Serialisierung




Abbildung 3: Klassendiagramm des Codecs

Die Wahl des Formats ist an einer Stelle gebündelt, an der ein `Codec` zwei Operationen festlegt: `encode` wandelt ein Python-Objekt in Bytes um, `decode` wandelt Bytes wieder in ein Python-

Objekt um. Abbildung 3 zeigt die Schnittstelle des Codecs, ihre zwei Umsetzungen in der Referenzimplementierung sowie die Stellen, an denen sie verwendet werden. Eine Umsetzung muss dabei lediglich die Bedingung aus Formel 6 erfüllen, nach der ein Wert beim Kodieren und anschließenden Dekodieren unverändert zurückkommen muss. Formal lässt sich das als

$$\text{decode} \circ \text{encode} = \text{id}_D \quad (6)$$

ausdrücken. Das Zeichen $\circ$ bezeichnet die Hintereinanderausführung, wobei die rechte Funktion zuerst angewendet wird. id_D ist die Identität auf der Menge D , also die Funktion, die jeden Wert unverändert zurückgibt. Die Formel besagt damit, dass Kodieren und anschließendes Dekodieren für jeden Wert aus D dasselbe Ergebnis liefert wie gar keine Umwandlung.

D umfasst dabei nur die Werte, die das jeweilige Format unterstützt. Für die hier eingesetzte MessagePack-Umsetzung sind das Wahrheitswerte, Ganzzahlen im Bereich von 16 Bit, Zeichenketten, Bytefolgen sowie Listen und Abbildungen über diesen Typen. Außerhalb von D gilt die Eigenschaft nicht, ein Tupel etwa kommt als Liste zurück. Die Umkehrung gilt ebenfalls nicht, da sich derselbe Wert auf mehrere Arten kodieren lässt und eine fremde Bytefolge deshalb nicht zwingend unverändert zurückkommt.

Die MessagePack-Umsetzung deckt bewusst nur den Teil des Formats ab, den das System tatsächlich austauscht. Fließkommazahlen fehlen ebenso wie die Erweiterungstypen des Formats. Übertragen werden Pixelkoordinaten, Objektreferenzen und kurze Texte, und jeder weggelassene Typ verkleinert den Decoder, der auf beiden Seiten läuft, was dem dritten Kriterium aus Abschnitt 5.2.6 entspricht.

Enger als im Format vorgesehen ist auch der Wertebereich der Ganzzahlen. Er endet bei 16 Bit, obwohl MessagePack auch 32 und 64 Bit kennt. Der Grund liegt in der Laufzeitumgebung des Hubs, die ohne Unterstützung für lange Ganzzahlen übersetzt ist, sodass sich dort keine Konstante oberhalb von $2^{30} - 1$ darstellen lässt. Die Zweige des Encoders für größere Werte enthielten solche Konstanten und verhinderten das Laden des gesamten Moduls, unabhängig davon, ob je ein so großer Wert übertragen wird. Für die hier auftretenden Werte reichen 16 Bit aus.

Welcher Codec verwendet wird, legt eine einzige Zuweisung fest. Möglich ist dieser Wechsel nur, weil die Rahmung die Länge der Nutzlast ausdrücklich mitführt. Die binäre Kodierung erzeugt Nullbytes, und ohne Längenfeld würde das Abschneiden von Füllbytes Teile der Nutzlast entfernen.

Zusätzlich steht ein JSON-Codec zur Verfügung, der bei der Fehlersuche hilfreich ist, da ein mitgeschnittener Frame seine Nutzlast dann im Klartext zeigt. Wie sich die beiden Formate auf die Anzahl der Übertragungen auswirken, vergleicht Abschnitt 7.

6.5 Kommunikationsschicht

Die Kommunikationsschicht ist auf beide Seiten verteilt. Auf dem Client, also dem Hub, bildet `PyBricksInterceptor.call()` einen Methodenaufruf auf eine Nachricht ab und wartet auf das Ergebnis, während auf dem Server, also dem ESP32, `MiddlewareInterceptor` die Nachricht entgegennimmt, sie der Verteilung übergibt und das Ergebnis zur Abholung bereitlegt. Beide Klassen übernehmen zugleich Aufgaben der Transportschicht, wie Tabelle III zeigt, weshalb die folgenden Abschnitte ausschließlich den Teil beschreiben, der zur Kommunikationsschicht gehört.

Die Umsetzung folgt dem Entwurf aus Abschnitt 5.3 und legt zwei Punkte fest, die dort nur als Prinzip beschrieben wurden. Erstens werden Argumente nach ihrer Position übertragen, wobei objektgebundene Methoden die Referenz des Objekts als erstes Argument erhalten. Zweitens werden Methoden über eine Kennung von 16 Bit angesprochen, die beide Seiten aus dem Methodennamen berechnen.

6.5.1 Aufrufnachricht

Die Nutzlast einer Nachricht tritt in drei Ausprägungen auf, je nach Richtung und Ausgang des Aufrufs.

Tabelle VI: Aufbau der Nutzlast je Ausprägung

Ausprägung	Schlüssel	Inhalt
CommandPayload	s, c, a	Scope, Methodenkennung, Liste der Argumente
DataPayload	d	Rückgabewert
ErrorPayload	e, k	Fehlerbeschreibung, optional die Fehlerart

Tabelle VI zeigt die drei Ausprägungen, deren Schlüssel jeweils einbuchstabig sind. Die Argumente stehen als Liste in der Reihenfolge der Parameter, wie sie die gemeinsamen Schnittstellen in `display/protocol` festlegen. Die Methode wird durch eine Kennung von 16 Bit bezeichnet, die Listing 5 aus ihrem Namen berechnet.

```
def name_hash(name):
    h = 5381
    for ch in name:
        h = ((h * 33) ^ ord(ch)) & 0xFFFF
    return h
```

Listing 5: Berechnung der Methodenkennung aus dem Methodennamen

Das Verfahren ist eine auf 16 Bit begrenzte Variante des bekannten djb2-Hashs [48]. Die eingebaute Funktion `hash` ist dafür nicht verwendbar, da CPython ihr Ergebnis je Prozess zufällig verändert und MicroPython es anders berechnet. Die Maskierung nach jedem Schritt hält alle Zwischenwerte unter 2^{30} , was auf dem Hub aus demselben Grund nötig ist wie die Begrenzung der Ganzzahlen in Abschnitt 6.4. Ein gebräuchlicher 32-Bit-Hash wie FNV würde diese Grenze überschreiten.

Die Breite von 16 Bit stellt eine Abwägung dar, denn MessagePack kodiert Werte bis 65535 in drei Byte, gegenüber 13 Byte für den Namen `create_label`. Eine Kennung von acht Bit wäre zwar ein Byte kürzer, bei zehn Methoden in einem Scope läge die Wahrscheinlichkeit einer Kollision dann jedoch bei etwa 16,3 %. Eine Kollision liegt vor, wenn zwei verschiedene Methodennamen denselben Hashwert ergeben, wobei die Wahrscheinlichkeit dafür mit der Anzahl der Methoden pro Scope steigt. Die folgende Gleichung

$$PKollision = 1 - \prod_{i=0}^{n-1} \left(1 - \frac{i}{N}\right) \quad (7)$$

schätzt die Wahrscheinlichkeit ab, dass bei n Methoden in einem Scope und N möglichen Kennungen mindestens zwei denselben Hashwert liefern. Sie ist nur eine Näherung, da sie gleichverteilte Hashwerte annimmt und djb2 nicht gleichverteilt ist. Nach Formel 7 liegt die Wahrscheinlichkeit einer Kollision bei 16 Bit und zehn Methoden bei etwa 0,069 %, bei 20 Methoden bei etwa 0,29 % und bei 50 Methoden bei 1,852 %.

Kollisionen sind somit möglich, werden jedoch beim Start des Servers erkannt. Der Server trägt dazu jede Methode in ein Dictionary ein, wobei der Hashwert als Schlüssel dient und eine zweite Methode mit demselben Hashwert zu einer Ausnahme führt, die den Start verhindert. Listing 6 zeigt die Funktion, die diese Indizierung vornimmt und in der Basisklasse `RPCDispatcher` liegt, von der alle Empfänger erben. Die genaue Struktur beschreibt Abschnitt 6.6.

```

def _index_methods(self):
    index = {}
    for name in dir(self):
        if name.startswith("_") or name in self.NOT_REMOTE:
            continue
        if not callable(getattr(self, name)):
            continue

        h = name_hash(name)
        if h in index:
            raise ValueError("hash collision in scope '{}': {} and {}".format(
                self.scope, index[h], name))
        index[h] = name
    return index

```

Listing 6: Funktion zur Registrierung einer Methode

Ergebnis und Fehler unterscheiden sich allein im Schlüssel. Der Client prüft, ob `e` vorhanden ist, und löst in diesem Fall eine Ausnahme aus. Welche Ausnahme das ist, bestimmt die Fehlerart unter `k`, wie Abschnitt 6.6 beschreibt. Antworten enthalten keinen Scope, denn der Server braucht ihn zur Auswahl des Empfängers, während eine Antwort immer an den einen Aufrufer zurückgeht, der auf sie wartet.

6.5.2 Verteilung eingehender Aufrufe

Die Zuordnung eines Aufrufs zur ausführenden Methode erfolgt in zwei Stufen. Zunächst wird anhand des Scopes ein Dispatcher ausgewählt, wobei der Scope die Art des Empfängers benennt, der den Aufruf ausführt, und im `CommandPayload` unter dem Schlüssel `s` mitgeführt wird. Die Dispatcher sind in einem `RPCDispatcherPool` registriert, wobei jeder einen eigenen Scope bedient. Die Registrierung erfolgt beim Start des Servers, und der Versuch, einen Scope ein zweites Mal zu belegen, löst eine Ausnahme aus.

Anschließend schlägt der ausgewählte Dispatcher die Methodenkennung aus `c` nach und ruft die Methode mit den Argumenten aus `a` auf. Dass diese Kennungen innerhalb eines Scopes eindeutig sind, prüft der Dispatcher beim Aufbau seines Index, wie Listing 6 zeigt.

Findet sich eine Kennung nicht im Index, löst der Dispatcher eine Ausnahme aus. Sie wird in eine Fehlermeldung überführt und erreicht den Client, womit die Zusicherung aus Abschnitt 5.2.7 auch für Aufrufe gilt, die es nicht gibt.

Aufruflbar ist damit jede öffentliche Methode eines Adapters. Das ist enger als ein Zugriff über den bloßen Namen, bei dem auch Attribute wie die Registratur erreichbar wären, aber weiter gefasst als die gemeinsame Schnittstelle in `display/protocol`. Der Adapter für Screens etwa erbt die Rückrufe der Anzeigebibliothek, die ebenfalls im Index stehen. Für die betrachtete Punkt-zu-Punkt-Verbindung, in die kein Dritter Nachrichten einspeisen kann, ist das hinnehmbar. Bei mehreren Teilnehmern müsste der Index auf die Methoden der Schnittstelle beschränkt werden.

6.5.3 Rückkanal

Nach der Bestätigung des letzten Frames ist ein Aufruf zwar vollständig übertragen, aber noch nicht ausgeführt. Der Server muss das Ergebnis erst berechnen und legt es anschließend in einem Ausgangspuffer ab, bis der Client es abholt.

Das Abholen erfolgt über denselben anfragegetriebenen Kanal wie die Übertragung der Aufrufe. Der Client fragt in einem festen Intervall mit `READY` an, ob ein Ergebnis bereitliegt. Der Server antwortet mit `DONE`, wenn das der Fall ist, und sonst mit `NACK`. Liegt das Ergebnis vor, holt der Client es mit `NEXT` Frame für Frame ab, wobei jede Anfrage die Position des nächsten Frames angibt. Der Server beantwortet jede Anfrage mit `frame_at(index)`, sodass eine wiederholte Anfrage denselben Frame liefert. Listing 7 zeigt die Beantwortung beider Anfragen.

```

if frame.opcode == OP_READY:
    if self.__is_result_ready__(frame.g_id):
        return Frame.create_done(g_id=frame.g_id).to_bytes()
    return Frame.create_no_ack(g_id=frame.g_id).to_bytes()

if frame.opcode == OP_NEXT:
    msg = self.outgoing.get(frame.g_id)
    if msg is None:
        return Frame.create_error(g_id=frame.g_id, payload=b"nomsg").to_bytes()

    res_frame = msg.frame_at(frame.frame_nr)
    if res_frame is None:
        return Frame.create_no_ack(g_id=frame.g_id, frame_nr=frame.frame_nr).to_bytes()

    return res_frame.to_bytes()

return Frame.create_error(g_id=frame.g_id, payload=b"badop").to_bytes()

```

Listing 7: Beantwortung der beiden Anfragen auf dem Server

Die Grenzen dieses Ablaufs sind als Konstanten festgelegt.

Tabelle VII: Grenzen des Rückkanals

Konstante	Wert	Bedeutung
RESULT_POLL_MS	50 ms	Abstand zwischen zwei READY-Anfragen, siehe Abschnitt 7
MAX_RESULT_WAIT_MS	5000 ms	Wartezeit, nach der ein Aufruf als gescheitert gilt
MAX_FRAME_ATTEMPTS	8	Anfragen je Position, bevor das Abholen abbricht
MAX_KEPT_RESULTS	4	Ergebnisse, die der Server zur Abholung bereithält
MAX_EVENTS	10	gepufferte Ereignisse je Objekt

Der Server behält nur die jüngsten Ergebnisse und verwirft ältere, wodurch der Speicherbedarf nach K5 begrenzt bleibt. Da der Client streng nacheinander aufruft, fragt er ohnehin nur nach dem Ergebnis seines letzten Aufrufs. Ereignisse nutzen keinen eigenen Mechanismus. Der Server legt sie je Objekt in der Registratur ab und hält dort die letzten zehn vor, wobei bei Überlauf das älteste Ereignis verworfen und gezählt wird. Abgefragt werden sie über einen gewöhnlichen Aufruf wie `is_button_pressed`, der den Puffer dabei leert und die Anzahl der verworfenen Ereignisse mitliefert. Jede Abfrage kostet einen vollständigen Aufruf mit Übertragung, Wartezeit und Abholung. Ein Verlust ist für die Anwendung damit erkennbar, wie Abschnitt 5.3 es verlangt.

Wie viel Zeit ein Aufruf im Warten auf das Ergebnis verbringt, misst Abschnitt 7. Reaktionen, die ohne diesen Weg auskommen, weil der Server sie selbst ausführt, behandelt Abschnitt 6.7.

6.6 Objektmodell

Das Objektmodell bildet die grafischen Elemente der Anzeige auf Objekte ab, die die Anwendung auf dem Hub wie lokale Objekte benutzt. Bildschirme, Beschriftungen und Schaltflächen heißen in der Umsetzung Screens, Labels und Buttons. Je Objekttyp gibt es eine Basisklasse in `display/protocol`. Sie wird auf dem Client von einem Stellvertreter erfüllt, der jeden Methodenaufruf weiterleitet, und auf dem Server von einem Adapter, der ihn ausführt. Die Adapter erben zusätzlich von `RPCDispatcher` und werden dadurch über ihren Scope erreichbar, wie Abschnitt 6.5.2 beschreibt. Jeder Stellvertreter hält ein `RemoteObject`, das die Referenz des Objekts führt und sie jedem Aufruf voranstellt. Dass die Stellvertreter es halten und nicht von ihm erben, liegt an Pybricks. Die Laufzeitumgebung unterstützt keine Mehrfachvererbung, und die eine mögliche Basisklasse belegt bereits die gemeinsame Schnittstelle des Objekttyps. Abbildung 4 zeigt diese Beziehungen beispielhaft.




Abbildung 4: Klassen des Objektmodells auf beiden Seiten

6.6.1 Referenzen

Eine Referenz ist eine Ganzzahl von 16 Bit, die der Server beim Erzeugen eines Objekts vergibt und die aus zwei Teilen besteht. Die unteren zehn Bit bezeichnen einen Slot, also die Position des Objekts in der Tabelle der Registratur, während die oberen sechs Bit die Generation dieses Slots enthalten, einen Zähler, der bei jeder Freigabe um eins steigt. Dieses Verfahren ist als Generational Handle bekannt und wird unter anderem in der Spieleentwicklung für Referenzen auf wiederverwendete Plätze eingesetzt [49].

```
def _slot(self, ref):
    index = ref & SLOT_MASK
    if index >= len(self._slots):
        return None
    slot = self._slots[index]
    if slot[2] is None or slot[0] != ref >> SLOT_BITS:
        return None
    return slot
```

Listing 8: Auflösung einer Referenz in der Registratur

Ein Slot speichert neben dem Objekt und seiner Generation auch die Art des Objekts und die Referenz seines Parents. Die Art ist `screen`, `label` oder `button`, und jede Methode eines Adapters gibt beim Nachschlagen an, welche Art sie erwartet. Übergibt die Anwendung etwa die Referenz eines Screens an `set_text`, wird das erkannt, bevor auf das Objekt zugegriffen wird.

Zehn Bit erlauben 1024 gleichzeitig bestehende Objekte, wobei der Speicher des ESP32 bereits bei deutlich weniger Objekten erschöpft ist und diese Grenze in der Praxis somit nicht erreicht wird. Die Breite von 16 Bit folgt aus Abschnitt 6.4, da der Codec Ganzzahlen nur bis zu dieser Größe überträgt und MessagePack eine Referenz damit in höchstens drei Byte kodiert. Eine Referenz in Textform wie `obj_12` belegt dagegen sieben Byte.

6.6.2 Lebenszyklus

Objekte entstehen immer innerhalb eines übergeordneten Objekts, wobei Screens vom Display und Labels sowie Buttons von einem Screen erzeugt werden. Ein Button besteht aus dem Server aus zwei Objekten, dem Button selbst und dem Label für seine Beschriftung. Beide werden getrennt registriert, und der Stellvertreter auf dem Client erhält beide Referenzen. So lässt sich die Beschriftung über den Scope `label` ändern, ohne dass der Button-Adapter dafür eine eigene Methode braucht.

Die Registratur bildet dabei den Objektbaum der Anzeigebibliothek nach. Jeder Eintrag kennt seinen Parent, und `release_tree` gibt ein Objekt zusammen mit allen darin erzeugten Objekten frei. Das ist nötig, weil `LVGL` beim Löschen eines Objekts auch dessen Kinder löscht. Ohne den Baum würden deren Einträge in der Registratur bestehen bleiben und auf nicht mehr vorhandene Objekte verweisen.

Gelöscht wird über die Methode `delete()`, die jeder Objekttyp anbietet. Der Adapter löscht dabei zuerst das `LVGL`-Objekt und gibt anschließend die Einträge frei, wobei auch die Ereignisse des Objekts und alle Bindings entfallen, an denen es beteiligt ist. Den gerade angezeigten Screen kann die Anwendung hingegen nicht löschen, da `LVGL` nicht festlegt, was angezeigt wird, wenn der aktive Screen fehlt. Ein solcher Aufruf wird deshalb mit einem Fehler beantwortet.

`clear()` löscht alle Objekte auf einmal. Die Registratur allein zu leeren genügt dafür nicht, da `LVGL` die Objekte in einem eigenen Baum hält und sie nicht freigibt, wenn die letzte Python-Referenz entfällt. Der Server lädt daher zuerst einen leeren Screen und löscht anschließend jeden Screen der Registratur mit allem, was darauf liegt. Die Slots bleiben dabei erhalten und werden einzeln freigeben, damit ihre Generationen weiterzählen.

6.6.3 Veraltete Referenzen

Nach dem Löschen eines Objekts kann dessen Stellvertreter auf dem Client weiter bestehen, wobei seine Referenz dann veraltet ist. Da freie Slots wiederverwendet werden, kann derselbe Slot inzwischen ein neues Objekt enthalten. Ohne Generation würde ein Aufruf über den alten Stellvertreter unbemerkt das neue Objekt verändern. Mit Generation passt die Referenz nicht mehr zum Slot, und der Aufruf wird abgewiesen.

Die Prüfung geschieht an zwei Stellen. Auf dem Server prüft die Registratur jede Referenz wie in Listing 8. Auf dem Client führt der `PyBricksInterceptor` eine Session, die bei `clear()` und bei einem Verbindungsabbruch endet. Jeder Stellvertreter merkt sich die Session, in der er entstanden ist. Gehört er zu einer früheren Session, löst er den Fehler aus, ohne eine Übertragung zu starten. Nach einem Verbindungsabbruch ist das die einzige verlässliche Prüfung, denn der ESP32 kann in der Zwischenzeit neu gestartet sein und seine Registratur von vorn aufbauen. Damit eine alte Referenz auch in diesem Fall nicht zufällig passt, beginnen die Generationen nach einem Start bei einem zufälligen Wert.

Beide Prüfungen melden denselben Fehler, wobei die Fehlernutzlast neben der Beschreibung unter `e` eine Fehlerart unter `k` trägt und der Client anhand dieser Art die passende Ausnahme auslöst. `StaleReferenceError` steht dabei für ein nicht mehr vorhandenes Objekt, `WrongKindError` für eine Referenz der falschen Art, während alle übrigen Fehler als `RemoteError` ankommen. Alle drei erben von `RuntimeError`, wodurch die Anwendung gezielt auf eine veraltete Referenz reagieren und beispielsweise die Oberfläche neu aufbauen kann, ohne den Fehlertext auswerten zu müssen.

Ganz ausgeschlossen sind Verwechslungen allerdings nicht. Nach 64 Freigaben desselben Slots wiederholt sich die Generation, und ein Stellvertreter, der die ganze Zeit bestanden hat, passt wieder. Löscht die Anwendung einen Screen, bleiben außerdem die Stellvertreter der Elemente darauf auf dem Client gültig, da der Client sie nicht kennt. Ihr nächster Aufruf erreicht den Server und wird erst dort abgewiesen.

6.6.4 Erweiterung um einen Objekttyp

Wie weit das Objektmodell erweiterbar ist, zeigt sich an einem zusätzlichen Element. Für einen Fortschrittsbalken sind vier Schritte nötig. Zunächst entsteht in `display/protocol` eine Basisklasse `ProgressBarBase` mit den Methoden, die beide Seiten teilen, etwa `set_value` und `delete`. Anschließend wird auf dem Client ein Stellvertreter ergänzt, der wie die übrigen ein `RemoteObject` hält, und auf dem Server ein Adapter, der von `RPCDispatcher` erbt und den Scope `progress` belegt. Der Adapter erzeugt das `LVGL`-Objekt und trägt es mit der Art `progress` in die Registratur ein.

Der vierte Schritt betrifft eine bestehende Klasse, denn ein Fortschrittsbalken wird auf einem Screen erzeugt. Der Screen-Adapter und der Screen-Stellvertreter brauchen deshalb je eine zusätzliche Methode `create_progress_bar`. Transport- und Kommunikationsschicht bleiben dagegen unberührt, da ein neuer Scope lediglich registriert und eine neue Methodenkennung beim Start indiziert wird.

Die Grenze der Erweiterbarkeit liegt damit im Objektmodell selbst. Ein neuer Objekttyp kostet drei neue Klassen und einen Eingriff in das erzeugende Objekt. Soll das neue Element außerdem Ereignisse liefern, kommt ein Rückruf bei der Anzeigebibliothek hinzu, wie ihn bisher nur Buttons anmelden.

6.7 Ansteuerung der Anzeige

Die Ansteuerung der Anzeige bildet auf dem Server die oberste Schicht aus Abschnitt 4. Sie ist die einzige Stelle mit Kenntnis der Anzeigehardware und liegt in `display/server/driver`. Die Darstellung übernimmt `LVGL` in der MicroPython-Anbindung [50], die auch den Treiber für den Displaycontroller ILI9341 mitbringt. Das Display ist über `SPI` angebunden, der kapazitive Touchcontroller über `I2C`.

Aufgebaut wird die Anzeige vom `ESPDisplayAdapter`, der die `I2C`-Verbindung öffnet, den Touchcontroller erzeugt und ihn dem Displaytreiber übergibt, welcher ihn als Zeigegerät bei `LVGL` anmeldet. Anschließend reicht er das `LVGL`-Modul an die Adapter für Screens, Labels und Buttons weiter. Ausschließlich diese Adapter rufen `LVGL` auf, während die Schichten darunter die Bibliothek nicht kennen.

Das Zeichnen ist von der Ausführung der Aufrufe getrennt. Der Treiber startet beim Initialisieren eine Ereignisschleife, die in festem Takt über einen Hardware-Timer den Task-Handler von `LVGL` einplant, welcher geänderte Bereiche neu zeichnet und die Eingabegeräte abfragt. Gemessen liegt dieser Takt bei 40 ms, siehe Abschnitt 7.3. Ein Adapter ändert somit lediglich den Zustand eines Objekts, beispielsweise den Text eines Labels, wobei die Änderung erst beim nächsten Durchlauf des Task-Handlers sichtbar wird. Ein Aufruf kann deshalb bereits abgeschlossen sein, bevor die Änderung auf dem Display erscheint.

Der Touchcontroller wird regelmäßig abgefragt, seine Interrupt-Leitung dagegen nicht genutzt. `LVGL` ruft dazu bei jedem Durchlauf die Funktion `touch_read_cb` auf, die das Registerabbild des Controllers liest, wobei jede Abfrage eine `I2C`-Transaktion kostet, auch wenn keine Berührung vorliegt. Die Funktion darf zudem keine Ausnahme weitergeben, weshalb ein fehlgeschlagener Lesevorgang als fehlende Berührung gemeldet wird, wie Abschnitt 6.9 begründet.

Erkennt `LVGL` eine Berührung auf einem Button, löst es ein Ereignis aus. Der Screen-Adapter registriert dafür beim Erzeugen eines Buttons die Methode `on_event` für die Ereignisse `PRESSED` und `RELEASED`. `on_event` ermittelt über die Registratur die Referenz des Buttons, übersetzt den Ereigniscode in einen Namen wie `press` und ergänzt einen Zeitstempel. Das Ergebnis wird im Ereignispuffer des Objekts abgelegt, aus dem der Client es wie in Abschnitt 6.5 beschrieben abfragt.

Der Puffer beantwortet zwei verschiedene Fragen, und beide werden in einem Aufruf beantwortet. Die erste ist der aktuelle Zustand, also ob ein Button gerade gedrückt ist. Dafür hält die Registratur das jüngste Ereignis getrennt vor, das eine Abfrage überdauert. Die zweite ist, was seit der letzten Abfrage geschehen ist. Dafür wird der Puffer beim Abfragen geleert

und die Anzahl der Drucke gezählt. Ohne diese Trennung ginge eine kurze Berührung verloren, die vor der nächsten Abfrage schon wieder beendet ist, weil dann nur noch das Loslassen im Puffer stünde. Da eine Abfrage einen vollständigen Aufruf kostet, ist dieser Fall der Normalfall und nicht die Ausnahme.

Vor dem Ablegen prüft `on_event`, ob für das Ereignis ein Binding besteht. Ein Binding legt fest, dass ein Ereignis auf einem Objekt eine Aktion auf einem anderen auslöst. Der Client legt es einmal mit einem gewöhnlichen Aufruf an. Danach führt der Server die Aktion direkt im Rückruf aus, ohne dass eine Übertragung nötig ist. Das Ereignis wird unabhängig davon gepuffert und steht der nächsten Abfrage zur Verfügung. Der Client erfährt von der ausgeführten Aktion selbst jedoch nichts. Welcher Screen gerade angezeigt wird, weiß er nur, solange er die Ereignisse regelmäßig abfragt und die Bindings selbst nachhält.

Tabelle VIII: Aktionen, die an ein Ereignis gebunden werden können

Wert	Name	Wirkung auf das Ziel
0x1	ACT_SHOW_SCREEN	Screen laden und anzeigen
0x2	ACT_SHOW	Objekt sichtbar machen
0x3	ACT_HIDE	Objekt verbergen
0x4	ACT_TOGGLE	Sichtbarkeit umkehren

Die Menge der Aktionen ist absichtlich klein und fest vorgegeben, da sie weder Bedingungen noch Zustand oder Berechnungen enthält. Bindings bleiben somit auf Reaktionen beschränkt, die lediglich die Darstellung betreffen, beispielsweise den Wechsel zwischen zwei Screens, während die Logik der Anwendung weiterhin auf dem Client liegt. Unbekannte Aktionen weist `bind` ebenso zurück wie Referenzen, die veraltet sind oder die falsche Art haben (Abschnitt 6.6).

6.8 Ablauf eines vollständigen Aufrufs

Nachdem die vorigen Abschnitte die Schichten einzeln beschrieben haben, verfolgt dieser Abschnitt einen einzelnen Aufruf durch alle Schichten. Als Beispiel dient folgende Zeile

```
counter_label.set_text("Counter: {}".format(counter))
```

aus dem Beispielprogramm des Hubs (siehe Listing 9). Sie ändert den Text eines Labels und liefert keinen Rückgabewert, wobei der Einfachheit halber `counter = 42` angenommen wird.

Aufruf auf dem Client. `counter_label` ist ein Stellvertreter vom Typ `Label`, dessen Methode `set_text` zunächst prüft, ob er zur aktuellen Session gehört, und den Aufruf anschließend an `PyBricksInterceptor.call()` übergibt. Die Referenz des Labels wird dabei den Argumenten vorangestellt. Die Kommunikationsschicht bildet daraus einen `CommandPayload` mit dem Scope `label`, der Methodenkennung von `set_text` und der Argumentliste aus Referenz und Text, wobei die Nachricht die nächste freie Kennung erhält.

Zerlegung. `MessagePack` kodiert diese Nutzlast in 32 Byte, die bei 13 Byte Nutzlast je Frame nach Formel 3 in drei Frames zerfallen. Die ersten beiden tragen `DATA`, der letzte `DATA_LAST` mit den verbleibenden sechs Byte.

Übertragung. Der Client sendet jeden Frame einzeln und wartet auf dessen Bestätigung. Jeder Austausch ist ein Aufruf von `remote.call` und damit ein Round Trip über den Bus. Stimmen Kennung oder Position der Antwort nicht, war die Antwort veraltet oder der Frame ist verloren gegangen, und der Client wiederholt seine letzte Übertragung. Der Server legt jeden neuen Frame ab und bestätigt ihn sofort. Mit dem letzten Frame setzt er die Nutzlast zusammen und startet die Ausführung als eigenen Task der Ereignisschleife. Der letzte Frame wird bestätigt, bevor der Aufruf ausgeführt wird.

Ausführung. Der Task dekodiert die Nutzlast, wählt über den Scope den Label-Adapter aus und schlägt dort die Methodenkennung nach. `set_text` löst die Referenz in der Registratur auf, prüft dabei Generation und Art und setzt den Text des `LVGL`-Objekts. Sichtbar wird der

neue Text erst beim nächsten Durchlauf des Task-Handlers, wie in Abschnitt 6.7 beschrieben wurde. Das Ergebnis `None` wird als `DataPayload` kodiert, das der Server anschließend unter der Kennung im Ausgangspuffer ablegt.

Ein sofortiges Neuzeichnen im Adapter wäre möglich, würde aber die Ereignisschleife für die Dauer der Übertragung zum Display blockieren und damit auch die Bearbeitung weiterer Frames verzögern.

Abholen. Der Client fragt mit `READY` nach, ob das Ergebnis bereitliegt. Ob ein Ergebnis schon beim ersten Versuch vorliegt, hängt davon ab, ob die Ereignisschleife des Servers den Task bis dahin ausgeführt hat. Antwortet der Server mit `NACK`, wartet der Client 50 ms und fragt erneut. Auf `DONE` folgt eine Anfrage `NEXT` für Position 0, die den einzigen Ergebnisframe liefert, gekennzeichnet mit `DATA_LAST`, womit der Abholprozess endet.

Rückgabe. Der Client dekodiert die Nutzlast und gibt den Rückgabewert `None` an den Aufrufer zurück, falls das Ergebnis nicht als Fehler gekennzeichnet ist. Andernfalls löst er die passende Ausnahme aus, wie in Abschnitt 6.6 beschrieben.

Ein Aufruf, der nur einen Text ändert, kostet damit mindestens fünf Round Trips. Nur drei davon transportieren den eigentlichen Aufruf mit seiner Nutzlast, während mindestens zwei weitere nur Steuerinformationen tragen und das Ergebnis abholen. Wie viele Round Trips in der Praxis nötig sind, misst Abschnitt 7.

Das Aufrufschema folgt somit der in Abschnitt 5.2.1 beschriebenen Abfolge. Das Sequenzdiagramm Abbildung 2 zeigt die generischen Abläufe, die hier mit einem konkreten Beispiel gefüllt wurden. Die Abbildung zeigt auch die beiden Round Trips, die der Client für das Abholen des Ergebnisses benötigt.

6.9 Nebenläufigkeit und Fehlerbehandlung

Die bisherigen Abschnitte beschreiben den Ablauf eines Aufrufs, der gelingt. Dieser Abschnitt behandelt, wie die Aufgaben auf dem Server nebeneinander laufen und wie Fehler behandelt werden.

6.9.1 Nebenläufigkeit

Auf dem Client gibt es keine Möglichkeit zur Nebenläufigkeit, sodass ein Aufruf die Anwendung blockiert, bis das Ergebnis vorliegt oder eine Obergrenze erreicht ist. Da immer nur ein Aufruf gleichzeitig unterwegs ist, braucht der Client weder Sperren noch Puffer für mehrere offene Aufrufe.

Auf dem Server laufen dagegen drei Tasks nebenläufig. Ein Task ruft etwa jede Millisekunde `process` von `PUPRemote` auf und beantwortet damit die Anfragen des Clients. `LVGL` zeichnet außerdem in einem festen Takt die Anzeige neu und fragt den Touchcontroller ab. Schließlich läuft jeder empfangene Aufruf in einem eigenen Task. Alle drei teilen sich eine einzige Ereignisschleife von `uasyncio` und damit einen Thread, weshalb sie sich nur an festen Stellen abwechseln, beispielsweise beim Warten eines der anderen Tasks.

Die Ausführung von Aufrufen lief in einer früheren Version in einem eigenen Thread. Das führte zu zwei Fehlern. Der Stack eines Threads wird vom Heap genommen, den `LVGL` bereits zum großen Teil belegt. Nach einigen Dutzend Aufrufen ließ sich deshalb kein neuer Thread mehr anlegen. Außerdem ist `LVGL` nicht reentrant [51], und der Task-Handler der Bibliothek lief teilweise im Thread mit seinem kleineren Stack. Dort lief der Stack im Rückruf des Touchcontrollers über. Mit einer gemeinsamen Ereignisschleife treten beide Fehler nicht mehr auf, da nie zwei Stellen gleichzeitig auf `LVGL` zugreifen.

Der Preis dafür ist, dass die Ereignisschleife während der Ausführung eines Aufrufs belegt ist. Anfragen des Clients werden in dieser Zeit nicht beantwortet, und die Anzeige wird nicht neu gezeichnet. Da der Client ohnehin auf das Ergebnis wartet, ist das hier unkritisch.

6.9.2 Fehlerbehandlung

Fehler werden in der Schicht behandelt, in der sie auftreten, und gelangen nach oben nur, wenn die Schicht sie nicht selbst behandeln kann. Tabelle IX fasst die Fälle zusammen.

Tabelle IX: Fehlerfälle und ihre Behandlung

Fehler	Schicht	Behandlung
Veraltete Antwort oder verlorene Bestätigung	Transport	Frame erneut senden, höchstens acht Versuche
Wiederholter Frame auf dem Server	Transport	bestätigen, aber nicht erneut ablegen
Abgebrochene Übertragung	Transport	Reste verwerfen, sobald Frame Nr. 0 einer neuen Nachricht eintrifft
Nachricht länger als 255 Frames	Transport	Aufruf scheitert auf dem Client, bevor etwas gesendet wird
Ergebnis bleibt aus	Kommunikation	nach 5000 ms Ausnahme auf dem Client
Unbekannter Scope oder Methoden-kennung	Kommunikation	Fehlermeldung an den Client, <code>RemoteError</code>
Veraltete Referenz oder falsche Art	Objektmodell	Fehlermeldung mit Fehlerart <code>StaleReferenceError</code> oder <code>WrongKindError</code>
Ausnahme in einer Methode des Adapters	Objektmodell	Fehlermeldung an den Client, <code>RemoteError</code>
Verbindungsabbruch	Busanbindung	Session beenden, <code>OSError</code> an die Anwendung
Fehler beim Lesen des Touchcontrollers	Anzeige	als fehlende Berührung werten

In der Transportschicht sind Fehler der Normalfall. Da der Client direkt nach dem Schreiben auch liest, erhält er häufig die Antwort auf die vorherige Anfrage. Er erkennt sie an Kennung, Position und Art des Frames und sendet diesen anschließend erneut. Der Server bestätigt eine Wiederholung, legt den Frame aber kein zweites Mal ab. Das gilt auch für den letzten Frame einer Nachricht. Würde dieser bei einer Wiederholung die Ausführung erneut starten, lief derselbe Aufruf zweimal, beim zweiten Mal mit einer leeren Nachricht. Erst wenn eine Obergrenze aus Tabelle VII erreicht ist, gibt der Client auf und löst eine Ausnahme aus, die den betroffenen Frame und den Aufruf nennt.

Für den Server gilt die Zusicherung aus Abschnitt 5.2.7, nach der jeder Aufruf ein Ergebnis oder eine Fehlermeldung hinterlässt. Jede Ausnahme bei der Ausführung wird abgefangen und als `ErrorPayload` im Ausgangspuffer abgelegt. Lässt sich selbst das Ergebnis nicht kodieren, legt er eine kurze Fehlermeldung ab. Anfragen, die der Server nicht zuordnen kann, beantwortet er mit einem Frame der Art `ERR`, etwa wenn nach dem Ergebnis einer unbekannten Nachricht gefragt wird.

Ein Verbindungsabbruch zeigt sich auf dem Client als `OSError: [Errno 19] ENODEV:` von `PUPRemote`. Der Client beendet dann die Session, da der Server in der Zwischenzeit neu gestartet sein kann, und reicht den Fehler an die Anwendung weiter. Ob sie es erneut versucht oder die Oberfläche neu aufbaut, entscheidet die Anwendung. Alle Stellvertreter aus der alten Session melden danach `StaleReferenceError`, wie Abschnitt 6.6 beschreibt.

Eine Stelle darf gar keinen Fehler weitergeben, nämlich der Rückruf, mit dem `LVGL` den Touchcontroller abfragt. Eine Ausnahme dort beendet die Ereignisschleife von `LVGL` dauerhaft, sodass die Anzeige nicht mehr neu gezeichnet würde, obwohl weiterhin Aufrufe ankommen. Ein fehlgeschlagener Lesevorgang wird deshalb als nicht vorhandene Berührung gewertet. Die Anwendung kann das nicht erkennen, da sie keinen Zugriff auf den Touchcontroller hat und nur die Ereignisse abfragen kann, die `LVGL` aus der Abfrage erzeugt.

7 Evaluation

Dieses Kapitel bewertet die Referenzimplementierung anhand der drei in Abschnitt 1 genannten Kriterien. Zunächst wird geprüft, ob sich eine interaktive Oberfläche über die entwickelte Abstraktion umsetzen lässt, bevor der Übertragungsaufwand je Aufruf und die Reaktionszeit auf eine Berührung gemessen werden. Daran schließen sich der Speicherbedarf, eine kurze Bewertung des Hardwareaufbaus sowie die Diskussion der Ergebnisse an.

Gemessen wird mit zwei eigenen Programmen. Das erste läuft auf dem Client und ruft `set_text` mit Texten wachsender Länge auf. Je Aufruf gibt es eine Zeile mit der Länge der Nutzlast, der Anzahl der Frames, der Anzahl der Round Trips, den Wiederholungen sowie den Zeiten für Senden, Warten und Abholen aus. Je Textlänge werden 20 Aufrufe gemessen, denen drei Aufrufe zum Aufwärmen vorausgehen. Das zweite Programm misst die Reaktion auf eine Berührung und wird dabei durch Zeitstempel auf dem Server ergänzt.

Angegeben ist jeweils der Median, da die Verteilungen durch feste Takte nicht symmetrisch sind. Beide Seiten laufen auf dem Logging-Level INFO, da die Ausgabe synchron über die serielle Verbindung erfolgt und andernfalls die Messung bestimmen würde. Vor jedem Lauf wird zudem der Server neu gestartet. Da Client und Server keine gemeinsame Zeitbasis besitzen, wird auf jedem Gerät für sich gemessen und erst in der Auswertung zusammengerechnet.

7.1 Funktionaler Nachweis

Der funktionale Nachweis ergibt sich aus dem Beispielprogramm in Listing 9 und aus den Messläufen. Das Beispielprogramm baut zwei Screens mit Labels und Buttons auf, verknüpft Buttons über Bindings mit einem Screenwechsel, schreibt fortlaufend einen Zähler und fragt die Zustände der Buttons ab. Damit sind alle Bestandteile des Objektmodells im Einsatz, also das Erzeugen von Objekten, das Ansprechen über Referenzen, das Ändern von Zuständen, lokale Reaktionen und der Rückfluss von Ereignissen.

Die Messläufe ergänzen das um die Dauer, denn über 640 aufeinanderfolgende Aufrufe hinweg trat keine einzige Wiederholung auf und kein Aufruf schlug fehl. Die Zusicherung aus Abschnitt 5.2.7, dass jeder Aufruf ein Ergebnis oder eine Fehlermeldung hinterlässt, wurde in diesen Läufen somit nie in Anspruch genommen.

Tabelle X ordnet die Kommunikationsanforderungen aus Abschnitt 3.3 dem erreichten Stand zu.

Tabelle X: Erfüllung der Kommunikationsanforderungen

Nr.	Anforderung	Stand	Begründung
K1	Strukturierte Nachrichten unbestimmter Länge	erfüllt	Nachrichten bis 3315 Byte, gemessen bis 164 Byte über 24 Frames
K2	Aufrufe mit zuordenbarem Ergebnis	erfüllt	Zuordnung über die Kennung der Nachricht, kein falsch zugeordnetes Ergebnis in 640 Aufrufen
K3	Rückfluss von Ereignissen	erfüllt	der Puffer wird beim Abfragen geleert, ein Überlauf wird gemeldet, siehe Abschnitt 7.3
K4	Antwortzeit unter 100 ms	teilweise	über ein Binding höchstens 51 ms, über den Client rund 1490 ms
K5	Begrenzter Speicherbedarf	erfüllt	feste Obergrenzen für Nachrichtenlänge, Ergebnisse und Ereignisse, siehe Tabelle VII
K6	Unabhängigkeit vom Übertragungsweg	erfüllt	alle wegabhängigen Anteile liegen in der Busanbindung, siehe Abschnitt 5.2.1

K3 und K4 werden in Abschnitt 7.3 belegt und in Abschnitt 7.6 eingeordnet.

7.2 Übertragungsaufwand

Gemessen wird in vier Konfigurationen, die jeweils eine Größe verändern. Die Nutzlast je Frame beträgt 13 Byte im aktuellsten Stand und 7 Byte in der früheren Fassung mit dem größeren Header, während als Serialisierung MessagePack[19] und die **JSON** zum Einsatz kommen. Der Vergleich trennt somit die Wirkung der Rahmung von der Wirkung des Formats.




Abbildung 5: Round Trips je Aufruf über der Textlänge, Median aus je 20 Aufrufen

Der wichtigste Befund ergibt sich aus dem Vergleich mit den gemessenen Zeiten. Ein Round Trip kostet in jeder Konfiguration und bei jeder Nachrichtenlänge 114,1 ms, wobei die Standardabweichung über alle 640 Aufrufe lediglich 0,3 ms beträgt. Die Dauer eines Aufrufs ist somit das Produkt aus der Anzahl der Round Trips und einer festen Zeit je Round Trip, da sich weder die Länge der Nutzlast noch die Wahl des Formats darüber hinaus auswirken. Jeder Wert aus Abbildung 5 lässt sich deshalb unmittelbar in eine Dauer umrechnen, sodass der kürzeste gemessene Aufruf mit 4 Round Trips 457 ms benötigt und der längste mit 27 Round Trips 3082 ms.

Die Anzahl der Round Trips folgt unmittelbar aus Formel 3. Sie setzt sich zusammen aus einem Round Trip je Frame der Nachricht, einer Anfrage `READY` und einem Round Trip je Frame des Ergebnisses. Für die gemessenen Aufrufe mit einem Ergebnis von vier Byte sind das $N + 2$ Round Trips.

Die beiden Einflussgrößen lassen sich daran trennen. Gegenüber dem heutigen Stand mit 13 Byte und MessagePack braucht die Fassung mit 7 Byte das 1,56-fache an Round Trips, die Fassung mit der **JSON** das 1,18-fache und beides zusammen das 2,09-fache. Die Rahmung wiegt also deutlich schwerer als das Format. Der Grund ist in den Daten sichtbar. Die **JSON** erzeugt bei denselben Aufrufen eine um 22 bis 23 Byte längere Nutzlast, was nach Formel 3 nicht bei jeder Textlänge eine Blockgrenze überschreitet. Ein kleinerer Header verschiebt dagegen alle Blockgrenzen zugleich. Die Erwartung aus Abschnitt 5.2.4 wird damit bestätigt.

Die Nutzlasteffizienz nach Formel 4 fällt dabei niedrig aus. Ein Aufruf mit 21 Byte Nutzlast belegt zwei Frames und somit 32 übertragene Byte, was einem Wert von 0,66 entspricht. Bei 142 Byte über elf Frames ergeben sich 0,81 und damit der höchste bei einem Header von drei Byte erreichbare Wert. Für die Dauer eines Aufrufs bleibt gleichwohl die Anzahl der Frames maßgeblich und nicht ihre Füllung.

Unabhängig von der Nachrichtenlänge kostet jeder Aufruf zwei zusätzliche Round Trips für das Abholen des Ergebnisses und somit 228 ms, was beim kürzesten Aufruf bereits die Hälfte der gesamten Dauer ausmacht. Auffällig ist zudem, dass das Abfrageintervall von 50 ms nie

zum Tragen kommt, da die gemessene Wartezeit stets genau 114 ms und damit einen einzigen Round Trip beträgt. Der Server ist folglich mit der Ausführung fertig, bevor der Client zum ersten Mal nachfragt.

7.3 Reaktionszeit einer Berührung

Die zweite Messung betrachtet den Weg von einer Berührung bis zur sichtbaren Reaktion und vergleicht dabei die beiden Wege aus Abschnitt 6.7. Über ein Binding führt der Server die Reaktion selbst aus, während über den Client das Ereignis abgefragt und mit einem zweiten Aufruf beantwortet wird. Auf dem Server werden dafür drei Zeitpunkte je Berührung festgehalten, nämlich die erste erkannte Berührung, das verarbeitete Ereignis und das abgeschlossene Neuzeichnen, auf dem Client hingegen die Zeit vom Beginn eines Abfragedurchlaufs bis zum Ende der Reaktion.

Der Touchcontroller wird von der Anzeigebibliothek alle 40 ms abgefragt. Eine Berührung wird deshalb im Mittel nach 20 ms und spätestens nach 40 ms bemerkt. Von dort bis zum verarbeiteten Ereignis vergehen 4 ms. Das Neuzeichnen dauert anschließend 6 ms, wenn ein Binding die Anzeige verändert hat, und 7 ms, wenn die Änderung von einem Aufruf des Clients stammt. Über ein Binding ist die Reaktion damit 13 ms nach der erkannten Berührung sichtbar, im ungünstigsten Fall 17 ms.

Auf dem Weg über den Client dauert allein die Reaktion 1161 ms, da sie aus zwei Aufrufen mit je 5 Round Trips besteht, nämlich dem Abfragen des Ereignisses und dem Ändern des Textes. Hinzu kommt die Zeit, bis überhaupt abgefragt wird, die nicht allein von der Pause in der Schleife der Anwendung abhängt, denn während eines laufenden Aufrufs kann nicht abgefragt werden. Der wirksame Abstand zwischen zwei Abfragen beträgt daher 572 ms zuzüglich der eingestellten Pause.

Tabelle XI: Zeit von der Berührung bis zur sichtbaren Reaktion

Teilstrecke	über ein Binding	über den Client
Erkennung durch die Anzeigebibliothek	im Mittel 20 ms	im Mittel 20 ms
Verarbeitung des Ereignisses	4 ms	4 ms
Warten auf die nächste Abfrage	entfällt	im Mittel 296 ms
Abfrage und Reaktion	entfällt	1161 ms
Neuzeichnen	6 ms	7 ms
Summe im Mittel	30 ms	rund 1490 ms
Summe im ungünstigsten Fall	51 ms	rund 1790 ms

Die Werte in Tabelle XI gelten für eine Pause von 20 ms in der Schleife der Anwendung. Gemessen wurde zusätzlich mit 0 ms und 1000 ms, wobei die Reaktion selbst in allen drei Fällen gleich lang ausfällt, da die Pause vor der Abfrage liegt. Bei einer Pause von 1000 ms steigt die Summe im Mittel auf rund 1980 ms, weil sich der Abstand zwischen zwei Abfragen entsprechend verlängert.

Dieser Abstand bestimmt zugleich, welche Berührungen überhaupt ankommen. In einer früheren Fassung lieferte eine Abfrage nur das jüngste Ereignis eines Objekts. Wurde ein Button gedrückt und wieder losgelassen, bevor die nächste Abfrage stattfand, stand im Puffer zuletzt das Loslassen, und die Berührung war vollständig verloren. Erkannt wurde sie nur, wenn sie zum Zeitpunkt der Abfrage noch andauerte, was bei einer Pause von 1000 ms ein Halten von etwa 1,6 Sekunden erforderte.

Diese Beobachtung war der Anlass für die in Abschnitt 6.7 beschriebene Trennung von Zustand und aufgelaufenen Ereignissen. Um sie zu prüfen, wurde die Messung wiederholt und dabei je Variante zwanzigmal kurz getippt. Tabelle XII stellt die Ergebnisse zusammen.

Tabelle XII: Erkannte Berührungen bei zwanzig kurzen Tippern je Variante

Pause	erkannt	gezählte Drucke	verloren	Wiederholungen
0 ms	20	20	0	0
20 ms	20	22	0	1
1000 ms	20	20	0	0

Kein Tipper ging verloren, und zwar unabhängig von der Pause in der Schleife. Bei einer Pause von 20 ms weist der Lauf 22 gezählte Drucke bei 20 erkannten Berührungen aus. Zweimal fielen also zwei Tipper in dasselbe Abfrageintervall, und beide wurden gemeldet. Anforderung K3 ist damit erfüllt, und das Halten eines Buttons ist nicht mehr nötig.

Bezahlt wird das mit einem zusätzlichen Round Trip je Abfrage. Die Antwort trägt nun den Zustand, die Anzahl der Drucke und die Anzahl der verworfenen Ereignisse, passt damit nicht mehr in einen einzigen Frame und benötigt zwei Frames für den Rückweg. Eine Abfrage kostet dadurch 5 statt 4 Round Trips, also 572 ms statt 458 ms. Die Dauer einer Reaktion bleibt davon unberührt, da der zweite Aufruf unverändert ist.

Die Wiederholung im Lauf mit 20 ms Pause ist der einzige Fall einer veralteten Antwort in allen Messungen dieser Arbeit. Sie kostete einen Round Trip, die betroffene Reaktion dauerte 1277 ms statt 1161 ms. Der Mechanismus aus Abschnitt 5.2.7 greift damit auch im Betrieb und nicht nur im Entwurf.

7.4 Ressourcenverbrauch

Auf dem Hub belegt das Programm nach dem Aufbau der Oberfläche 16272 Byte gegenüber 16128 Byte davor, sodass eine Oberfläche aus zwei Screens, zwei Labels und zwei Buttons auf dieser Seite lediglich 144 Byte kostet. Der übrige Speicher entfällt auf die Middleware und die Laufzeitumgebung. Die Werte sind in allen vier Läufen identisch, womit der Speicherbedarf weder vom Format noch von der Frame-Größe abhängt. Der gebündelte Quelltext für den Hub umfasst 68 KB.

Der Speicherbedarf auf dem Server wurde dagegen nicht gemessen, da dort die Anzeigebibliothek den größten Teil des Heaps belegt und die Middleware selbst daneben kaum ins Gewicht fällt. Eine belastbare Aussage müsste den Verbrauch vor und nach dem Aufbau der Oberfläche vergleichen.

7.5 Bewertung des Hardwareaufbaus

Die Adapterplatine ist ein Zwischenschritt weg vom Steckbrett, auf dem der Aufbau in einer ersten Vorführung noch beruhte. Da sich Display und Mikrocontroller aufstecken lassen, beschränkt sich die Hardware auf das Nötigste, nämlich auf die Verbindung beider Baugruppen. Die Platine führt alle benötigten Leitungen auf Buchsenleisten, die sich ohne besondere Ausrüstung löten lassen. Dadurch lassen sich weitere Exemplare zügig aufbauen, und die aufgesteckten Baugruppen bleiben für andere Zwecke verwendbar.

Steckverbindungen sind allerdings keine gute Wahl für die Signalintegrität und zählen im Betrieb zu den häufigsten Fehlerquellen. Für einen Aufbau, der im Labor erprobt und zwischen Versuchen umgesteckt wird, ist das vertretbar, für einen dauerhaften Einsatz dagegen nicht. Abbildung 6 zeigt beide Seiten der Platine als dreidimensionale Darstellung aus dem Entwurfswerkzeug. Neben den Buchsenleisten sind dort die Versionsnummer der Platine sowie die Bezeichnungen der Bauteile aufgedruckt, was die Bestückung und die spätere Zuordnung erleichtert.




Abbildung 6: Vorderseite (rechts) und Rückseite (links) der Adapterplatine als 3D Rendering

7.6 Diskussion der Ergebnisse

Die Messungen bestätigen die Annahme, auf der der gesamte Entwurf beruht, denn für die Dauer eines Aufrufs zählt die Anzahl der Übertragungen und nicht die übertragene Datenmenge. Jede eingesparte Übertragung spart 114 ms, unabhängig davon, wie viele Byte sie transportiert hätte. Der Wechsel von der früheren Rahmung und der **JSON** auf den heutigen Stand halbiert somit die Dauer eines Aufrufs.

Erklärungsbedürftig sind die 114 ms selbst, denn bei 115200 Baud dauert die Übertragung eines Blocks von 16 Byte deutlich weniger als eine Millisekunde. Die Zeit entsteht folglich nicht auf der Leitung, sondern in den beteiligten Bibliotheken und Ereignisschleifen, zumal auf dem Server die Verarbeitung der Transportbibliothek etwa jede Millisekunde aufgerufen wird und je Durchlauf höchstens ein Kommando bearbeitet. Wie viel Zeit dabei auf welche Seite entfällt, lässt sich mit den vorhandenen Daten nicht beantworten, dafür wäre eine Messung innerhalb der Busanbindung nötig.

Für K4 ergibt sich ein zweigeteiltes Bild, denn über ein Binding liegt die Reaktion mit höchstens 51 ms sicher innerhalb der geforderten 100 ms, über den Client dagegen um den Faktor 25 darüber. Die lokalen Bindings sind somit nicht nur eine Abkürzung, sondern die einzige Möglichkeit, eine Reaktion in der geforderten Zeit anzuzeigen. Dass ihr Satz an Aktionen klein ist, begrenzt zugleich, welche Reaktionen in dieser Zeit überhaupt möglich sind.

K3 war in der gemessenen Fassung nicht erfüllt, weil nur das jüngste Ereignis je Objekt geliefert wurde. Der Abstand zwischen zwei Abfragen ist durch die Dauer eines Aufrufs nach unten begrenzt, und in dieser Zeit endete eine kurze Berührung, ohne dass die Anwendung davon erfuhr. Mit dem geleerten Puffer und dem gemeldeten Überlauf ist die Anforderung erfüllt. Offen bleibt, dass jeder Button einzeln abgefragt wird, sodass die Anzahl der Aufrufe mit der Anzahl der Bedienelemente wächst. Abschnitt 8 greift das auf.

Die Aussagekraft der Messung ist in drei Punkten begrenzt. Erstens wurde der Übertragungsaufwand anhand eines einzigen Aufrufs, nämlich `set_text`, auf einer festen Hardwarekombination gemessen, während Aufrufe mit größeren Ergebnissen die Round Trips anders auf Hin- und Rückweg verteilen. Zweitens stammen die Zeiten auf dem Server und auf dem Client aus getrennten Uhren und wurden rechnerisch zusammengesetzt, eine durchgehende Messung von der Berührung bis zum Bild liegt somit nicht vor. Drittens wurden die Berührungen von Hand ausgelöst, sodass die Erkennungszeit zusätzlich davon abhängt, wie der Finger aufsetzt.

8 Fazit und Ausblick

Dieses Kapitel ordnet die Ergebnisse ein, indem zunächst die Grenzen des Entwurfs benannt werden, die sich aus den Messungen in Abschnitt 7 ergeben. Anschließend wird geprüft, wie weit sich die Lösung von der betrachteten Plattform gelöst hat, woran sich die möglichen Erweiterungen anschließen. Den Abschluss bildet die Zusammenfassung der Ergebnisse.

8.1 Limitierungen

Die folgenden drei Abschnitte behandeln die Grenzen des Kommunikationsmodells, die erreichbare Latenz und die Stellen, an denen die Abstraktion nicht vollständig trägt.

8.1.1 Kommunikationsmodell

Die Anwendung auf dem Client blockiert, solange ein Aufruf läuft, was unmittelbar aus der fehlenden Nebenläufigkeit in Abschnitt 3.4 folgt. Nach Abschnitt 7.3 dauert ein einzelner Aufruf rund 570 ms, im ungünstigsten Fall wartet die Anwendung sogar bis zur Obergrenze von fünf Sekunden. In dieser Zeit steht alles still, was sonst im selben Programm läuft, insbesondere die Regelung von Motoren und das Auslesen von Sensoren. Für ein Programm, das eine Anzeige bedient und gleichzeitig einen Roboter steuert, stellt dies die größte Einschränkung des Entwurfs dar.

Pybricks bietet inzwischen kooperatives Multitasking über `async` und `await` [52], womit sich das Warten auf ein Ergebnis unterbrechen ließe, ohne die übrige Anwendung anzuhalten. Der anfragegetriebene Rückkanal bliebe dabei unverändert, da weiterhin der Client jede Übertragung anstößt. Betroffen wären lediglich die Schnittstelle der Stellvertreter, die dann Koroutinen anbieten müssten, sowie die Schleife, die auf das Ergebnis wartet. Ob sich dieser Aufwand lohnt, hängt jedoch davon ab, wie viel die Anwendung neben der Anzeige zu tun hat.

Eine zweite Einschränkung betrifft den Rückfluss von Ereignissen, dessen Abstand zwischen zwei Abfragen durch die Dauer eines Aufrufs nach unten begrenzt ist und somit im Bereich einer halben Sekunde liegt. Seit der in Abschnitt 6.7 beschriebenen Änderung geht dabei zwar kein Ereignis mehr verloren, die Anwendung erfährt jedoch erst mit dieser Verzögerung davon. Hinzu kommt, dass jeder Button einzeln abgefragt wird, sodass die Anzahl der Aufrufe mit der Anzahl der Bedienelemente wächst.

8.1.2 Latenz und Durchsatz

Die Dauer eines Aufrufs ergibt sich aus der Anzahl der Round Trips multipliziert mit 114 ms, wovon zwei unabhängig von der Nachrichtenlänge auf das Abholen des Ergebnisses entfallen. Bei kurzen Aufrufen macht dieser feste Anteil bereits die Hälfte der Gesamtzeit aus.

Eine Reaktion, die über den Client läuft, benötigt zwei Aufrufe und liegt damit im Mittel bei rund 1490 ms. Die Anforderung K4 von 100 ms wird auf diesem Weg um mehr als das Zehnfache verfehlt. Erreichbar ist sie nur über ein Binding, das der Server selbst ausführt und das nach Tabelle XI unter 51 ms bleibt. Damit ist die Zahl der Reaktionen, die in der geforderten Zeit möglich sind, durch den kleinen Satz an Aktionen aus Tabelle VIII begrenzt.

Der Durchsatz war kein Entwurfsziel und fällt entsprechend gering aus, da eine Nachricht von 142 Byte den Bus bereits für 1,5 Sekunden belegt. Für Text und einzelne Bedienelemente reicht das aus, für Bilddaten oder fortlaufende Messwerte jedoch nicht.

8.1.3 Abstraktionsgrenzen

Die Aufrufstransparenz aus Abschnitt 4 trägt syntaktisch, nicht zeitlich, denn ein Aufruf sieht zwar wie ein lokaler Aufruf aus, dauert jedoch um Größenordnungen länger. Das entspricht der Einordnung aus Abschnitt 2.1 und ist eine grundsätzliche Eigenschaft entfernter Aufrufe, keine Schwäche der Umsetzung.

Beim Erweitern des Objektmodells bleiben Transport- und Kommunikationsschicht unberührt, das Objektmodell selbst aber nicht. Wie Abschnitt 6.6.4 an einem Fortschrittsbalken zeigt, braucht ein neuer Objekttyp eine Basisklasse, einen Stellvertreter, einen Adapter und zusätzlich eine Fabrikmethode in dem Objekt, das ihn erzeugt. Auch das Ereignismodell ist bisher auf Buttons zugeschnitten, da nur dort Rückrufe bei der Anzeigebibliothek angemeldet werden. Erweiterbar ist das Modell also, aber nicht ohne Eingriff an mehreren Stellen.

Die Prüfung von Referenzen stößt an eine Grenze, die sich aus ihrer Breite ergibt, da sich die Generation eines Slots nach 64 Freigaben wiederholt. Ein Stellvertreter, der die ganze Zeit besteht, passt danach wieder auf ein fremdes Objekt. Hinzu kommt, dass der Client lediglich die Stellvertreter kennt, die er selbst hält. Löscht er einen Screen, bleiben die Stellvertreter der Elemente darauf lokal gültig und werden erst vom Server abgewiesen.

Schließlich führt das schemafreie Format keine Typinformationen mit, sodass sich erst zur Laufzeit herausstellt, ob eine Methode existiert und ob die Argumente passen. Verwenden beide Seiten unterschiedliche Codecs, lässt sich die Nutzlast zwar dekodieren, ergibt aber keinen gültigen Aufruf mehr. Beide Seiten weisen diesen Fall inzwischen mit einer eindeutigen Meldung ab, verhindern lässt er sich im Entwurf jedoch nicht.

8.2 Übertragbarkeit auf andere Verbindungsklassen

Der Entwurf nimmt in den Kapiteln Abschnitt 4 und Abschnitt 5 durchgehend auf die Merkmale der Verbindungsklasse aus Abschnitt 3.5 Bezug und nicht auf den LEGO-Bus. Alles Wegabhängige liegt unterhalb der Interceptor-Schnittstelle, die lediglich aus einer einzigen Operation besteht, sodass eine andere Verbindung angebunden wird, indem genau diese Operation neu umgesetzt wird.

Prüfen lässt sich das an den Größen, die von der Verbindung abhängen, also an der Blockgröße und den daraus abgeleiteten Werten für die Nutzlast je Frame, die Breite des Längensfelds und die maximale Nachrichtenlänge. Alle vier stehen als Konstanten an einer Stelle, und Abschnitt 7 zeigt mit dem Wechsel von 13 auf 7 Byte, dass eine Änderung tatsächlich nur dort stattfindet. Für I2C oder Modbus im RTU-Modus wäre derselbe Weg gangbar, sofern die Gegenseite Blöcke fester Größe auf Anfrage austauschen kann.

Nicht übertragbar ist hingegen die Annahme, dass immer nur eine Nachricht unterwegs ist, da sie aus dem anfragegetriebenen Kanal und der fehlenden Nebenläufigkeit folgt. Auf einer Verbindung, die mehrere gleichzeitige Übertragungen erlaubt, müssten die Rekonstruktion und die Verwaltung der Ergebnisse je Kennung getrennt werden, wie Abschnitt 5.2.5 beschreibt.

8.3 Mögliche Erweiterungen

Die folgenden Erweiterungen setzen an den Grenzen aus Abschnitt 7 an, wobei die ersten beiden das Protokoll und die Anzahl der Übertragungen betreffen und die übrigen die Serialisierung, den Hardwareaufbau sowie den Umfang des Objektmodells.

8.3.1 Ergebnis mit der Bestätigung

Nach Abschnitt 7 kostet das Abholen des Ergebnisses unabhängig von der Nachrichtenlänge zwei Round Trips und somit 228 ms je Aufruf. Die meisten Aufrufe sind auf dem Server jedoch in Mikrosekunden ausgeführt, und ihr Ergebnis ist mit vier Byte kürzer als ein einzelner Frame. Statt die Ausführung aufzuschieben und das Ergebnis abfragen zu lassen, könnte der Server den Aufruf deshalb beim letzten Datenframe direkt ausführen und das Ergebnis zusammen mit der Bestätigung zurückgeben.

Der Kanal bliebe dabei anfragegetrieben, da es sich weiterhin um eine Antwort handelt. Passt das Ergebnis nicht in einen Frame, meldet der Server lediglich, dass es bereitliegt, und das Abholen läuft wie bisher ab. Für einen kurzen Aufruf sinkt die Anzahl der Round Trips somit von fünf auf drei und die Dauer entsprechend von rund 570 ms auf rund 340 ms.

Zwei Punkte sind dabei zu beachten. Zum einen ist der Bus während der Ausführung belegt, was für Aufrufe an die Anzeigebibliothek unkritisch ist, für längere Operationen jedoch ein zusätzliches Kennzeichen erfordern würde. Zum anderen prüft die Sendeschleife des Clients bisher nur die Position der Antwort und müsste zusätzlich die Kennung der Nachricht auswerten, da sonst eine veraltete Antwort das Ergebnis des vorherigen Aufrufs liefern könnte.

8.3.2 Ereignisgetriebener Rückkanal

Die zweite Erweiterung betrifft die Anzahl der Abfragen. Heute wird jeder Button einzeln abgefragt, und jede Abfrage ist ein vollständiger Aufruf. Bei fünf Buttons sind das fünf Aufrufe je Durchlauf, also nach Abschnitt 7 etwa drei Sekunden. Stattdessen könnte das Display eine Methode anbieten, die alle seit der letzten Abfrage aufgelaufenen Ereignisse aller Objekte auf einmal liefert. Der Puffer läge dann nicht je Objekt, sondern gemeinsam vor, wodurch die Anzahl der Abfragen unabhängig von der Anzahl der Bedienelemente wäre. Zugleich fiel der zusätzliche Round Trip wieder weg, den die Antwort je Button nach Abschnitt 7.3 heute kostet, da eine gemeinsame Antwort nur einmal übertragen werden muss.

Darauf aufbauend könnte die Anwendung Rückrufe je Button registrieren, statt die Zustände selbst abzufragen, sodass die Schleife nur noch aus einem einzigen Aufruf bestünde, der die Ereignisse verteilt. Eine weitere Verbesserung wäre ein Hinweis in jeder Bestätigung, ob überhaupt Ereignisse anliegen. Der Client müsste dann lediglich nachfragen, wenn es etwas abzuholen gibt, wodurch die Abfrage im Leerlauf vollständig entfiel.

8.3.3 Alternative Serialisierung

Die **JSON** benötigt nach Abschnitt 7 das 1,18-fache an Round Trips gegenüber MessagePack. Der Wechsel auf das binäre Format spart also etwa 15 % der Übertragungen. Ein schemagebundenes Format wie Protocol Buffers könnte die Nutzlast weiter verkürzen, da Schlüssel dann gar nicht mehr übertragen werden. Der Preis dafür wären ein Übersetzungsschritt und eine Beschreibung der Schnittstelle, die beide Seiten teilen, was nach Abschnitt 5.2.6 gerade der Grund für ein schemafreies Format war. Ob sich der Aufwand lohnt, ließe sich mit dem vorhandenen Messaufbau beantworten, da der Codec an einer einzigen Stelle austauschbar ist.

8.3.4 Integrierter Hardwareaufbau

Der Aufbau aus Abschnitt 6.2 besteht aus drei Baugruppen und zwei Steckverbindungen. Eine eigenständige Platine, die den Mikrocontroller, das Display und die Versorgung vereint, war als zweite Ausbaustufe geplant, wurde aus Zeitgründen jedoch nicht gebaut. Sie würde den Aufbau mechanisch robuster machen und die Spannungsversorgung sauber lösen, während sich am Protokoll, an der Latenz und an der Software nichts ändern würde. Der folgende Abschnitt umreißt, welche Funktionsgruppen eine solche Platine enthalten müsste, da die bisher verwendeten Baugruppen diese Aufgaben mitbringen und sie bei deren Wegfall neu zu lösen sind.

Ausgangspunkt ist der Sensorport des Hubs. Er führt neben Masse und den beiden Datenleitungen eine Logikversorgung von 3,3 V sowie die höhere Versorgung auf der Leitung M+, die das Gerät nach Abschnitt 6.3 ausdrücklich anfordert. Die Logikversorgung des Ports ist für die Elektronik eines Sensors ausgelegt und reicht für ein Display mit Hintergrundbeleuchtung nicht aus, weshalb die Platine ihre eigene Spannung aus M+ erzeugen muss.

Spannungsversorgung. Ein Abwärtswandler erzeugt aus den etwa 8 V der Leitung M+ die 3,3 V für Mikrocontroller, Display und Touchcontroller. Ein linearer Regler ist dafür ungeeignet, da er die Differenz in Wärme umsetzt und bei einem Strom von einigen hundert Milliampere über ein Watt abführen müsste. Der Wandler braucht außerdem einen Pufferkondensator, der den Einschaltstrom der Hintergrundbeleuchtung abfängt.

Versorgung über USB. Für die Entwicklung wird die Platine über USB versorgt, im Betrieb am Hub dagegen über M+. Beide Quellen dürfen sich nicht gegenseitig speisen, weshalb eine Umschaltung über zwei Dioden oder über einen Lastschalter nötig ist. Diese Schaltung entscheidet zugleich, welche Quelle Vorrang hat, wenn beide anliegen.

Schutz der Eingänge. Der Port ist steckbar und damit den üblichen Gefahren ausgesetzt. Vorgesehen werden sollten ein Verpolschutz auf M+, eine rückstellende Sicherung sowie Schutzdioden gegen elektrostatische Entladung auf allen Leitungen, die nach außen führen.

Anbindung an den Bus. Die beiden Datenleitungen des Ports arbeiten mit 3,3 V und können direkt an den Mikrocontroller geführt werden. Sinnvoll sind Serienwiderstände und ein definierter Ruhepegel auf der Sendeleitung, da die Gegenseite beim Verbindungsaufbau nach Abschnitt 6.3 einen festen Zustand erwartet.

Mikrocontroller mit seiner Grundbeschaltung. Dazu gehören die Abblockkondensatoren, die Beschaltung des Reset-Eingangs und die Taster für Reset und Startmodus. Besonderes Augenmerk verdienen die Pins, die beim Start abgefragt werden, da sie den Startmodus und die Flash-Spannung festlegen. Abschnitt 6.2 beschreibt den Fall, in dem die SD-Karte eine solche Leitung beim Start auf einen ungünstigen Pegel zieht.

Programmierschnittstelle. Ohne Steckplatine fehlt der Weg, die Firmware aufzuspielen. Nötig ist entweder ein Brückenbaustein von USB auf eine serielle Schnittstelle samt der üblichen Schaltung, die Reset und Startmodus automatisch setzt, oder ein Mikrocontroller mit eigener USB-Schnittstelle.

Anschluss des Displays. Das Display wird über die vorhandenen Leitungen für SPI angebunden, der Touchcontroller über I2C mit den beiden Pull-up-Widerständen, die der Bus verlangt. Die Hintergrundbeleuchtung sollte über einen Transistor geschaltet werden, damit sie sich dimmen und im Leerlauf abschalten lässt. Im heutigen Aufbau leuchtet sie dauerhaft.

Zwei Punkte gehen über die reine Schaltung hinaus. Die Platine muss sich mechanisch in den Aufbau einfügen, also zu den Maßen des Displays und zu den Befestigungspunkten des Hubs passen. Zudem sollte sie Messpunkte für die Versorgungsspannungen und die beiden Datenleitungen vorsehen, da eine Messung an einem gesteckten Aufbau sonst kaum möglich ist. Der Nutzen bliebe dabei auf Mechanik, Versorgung und Handhabung beschränkt. An der Anzahl der Übertragungen, der Latenz aus Abschnitt 7 und der Software würde sich nichts ändern.

8.3.5 Weitere Peripherieklassen

Das Objektmodell bildet bisher Screens, Labels und Buttons ab, wobei sich weitere Elemente wie Eingabefelder oder Listen nach demselben Muster ergänzen ließen. Interessanter ist jedoch der Schritt darüber hinaus, denn die Schichten unterhalb des Objektmodells kennen keine Anzeige, sondern lediglich Aufrufe an benannte Empfänger. Eine andere Geräteklasse, beispielsweise ein Sensor mit eigener Auswertung, ließe sich somit über dieselbe Middleware anbinden, indem ein weiterer Dispatcher registriert wird.

8.4 Zusammenfassung

Die vorliegende Arbeit entwirft eine Middleware, die entfernte Objekte über eine anfragegetriebene Verbindung mit sehr kleiner Paketgröße nutzbar macht, und setzt diese für die Anbindung eines Touchscreen-Displays an einen LEGO-Hub um. Der Entwurf gliedert sich in fünf Schichten, die von der Busanbindung über die Transport- und die Kommunikationsschicht bis zum Objektmodell reichen und alles Wegabhängige in der untersten Schicht bündeln.

Die Messungen zeigen, dass die Anzahl der Übertragungen die Dauer eines Aufrufs bestimmt. Ein Round Trip kostet 114 ms, unabhängig von Format und Nachrichtenlänge. Der schlankere Header und das binäre Format zusammen halbieren die Anzahl der nötigen Übertragungen gegenüber der ersten Fassung. Fünf der sechs Kommunikationsanforderungen sind erfüllt. Einzig die geforderte Antwortzeit wird nur über lokal ausgeführte Bindings eingehalten, nicht aber über den Weg durch die Steuereinheit.

Damit steht ein System zur Verfügung, das eine interaktive Oberfläche über eine Verbindung bedient, die dafür ursprünglich nicht vorgesehen war. Die verbleibenden Schwächen sind

benannt, gemessen und in ihren Ursachen verstanden, wobei für die beiden wichtigsten ein Weg vorliegt, der ohne Änderung des Kommunikationsmodells auskommt.

9 Abbildungs- und Tabellenverzeichnis

Abbildungsverzeichnis

Abbildung 1	Schichtenmodell der Architektur. Beide Seiten sind gleich aufgebaut und verkehren jeweils nur mit der unmittelbar darunterliegenden Schicht.	15
Abbildung 2	Ablauf eines Aufrufs an der Interceptor-Schnittstelle. Jede der drei Phasen besteht aus Wiederholungen derselben Operation, und jede wird vom Client angestoßen.	20
Abbildung 3	Klassendiagramm des Codecs	33
Abbildung 4	Klassen des Objektmodells auf beiden Seiten	38
Abbildung 5	Round Trips je Aufruf über der Textlänge, Median aus je 20 Aufrufen	45
Abbildung 6	Vorderseite (rechts) und Rückseite (links) der Adapterplatine als 3D Rendering	48
Abbildung 7	Schaltplan der Adapterplatine	60

Tabellenverzeichnis

Tabelle I	Vergleich der betrachteten Ansätze entlang der Auswahlkriterien	8
Tabelle II	Gegenüberstellung der Kommunikationsanforderungen und der Einschränkungen der Plattform	13
Tabelle III	Zuordnung der Module zu den Schichten aus Abschnitt 4	29
Tabelle IV	Aufbau des Frame-Headers	31
Tabelle V	Werte für die Art des Frames und ihre Bedeutung	32
Tabelle VI	Aufbau der Nutzlast je Ausprägung	35
Tabelle VII	Grenzen des Rückkanals	37
Tabelle VIII	Aktionen, die an ein Ereignis gebunden werden können	41
Tabelle IX	Fehlerfälle und ihre Behandlung	43
Tabelle X	Erfüllung der Kommunikationsanforderungen	44
Tabelle XI	Zeit von der Berührung bis zur sichtbaren Reaktion	46
Tabelle XII	Erkannte Berührungen bei zwanzig kurzen Toppertips je Variante	47

Code-Listings

Listing 1	Registrierung des einzigen Kommandos	30
Listing 2	Funktion zur Erzeugung eines Frames aus Bytes	31
Listing 3	Funktion zur Umwandlung eines Frames in Bytes	32
Listing 4	Funktion zur Erzeugung von Frames aus einer Nachricht	33
Listing 5	Berechnung der Methodenkennung aus dem Methodennamen	35
Listing 6	Funktion zur Registrierung einer Methode	36
Listing 7	Beantwortung der beiden Anfragen auf dem Server	37
Listing 8	Auflösung einer Referenz in der Registratur	38
Listing 9	Beispielprogramm auf dem Hub	59

10 Abkürzungsverzeichnis

ARQ – Automatic Repeat reQuest
CBOR – Concise Binary Object Representation
CoAP – Constrained Application Protocol
CORBA – Common Object Request Broker Architecture
gRPC – gRPC Remote Procedure Call
HTTP – Hypertext Transfer Protocol
I2C – Inter-Integrated Circuit
JSON – JavaScript Object Notation
LED – Light Emitting Diode
LPF2 – LEGO Power Functions 2.0
LVGL – Light and Versatile Graphics Library
MQTT – Message Queuing Telemetry Transport
MTU – Maximum Transmission Unit
ONC RPC – Open Network Computing Remote Procedure Call
OSI – Open Systems Interconnection
PUP – LEGO Powered Up
REST – Representational State Transfer
RFC – Request for Comments
RMI – Remote Method Invocation
RPC – Remote Procedure Call
RTU – Remote Terminal Unit
SPI – Serial Peripheral Interface
SRAM – Static Random Access Memory
TCP – Transmission Control Protocol
TFT – Thin-Film-Transistor
UART – Universal Asynchronous Receiver Transmitter
UDP – User Datagram Protocol
XML – Extensible Markup Language

Bibliografie

- [1] „Implementing Remote Procedure Calls“, *ACM Transactions on Computer Systems*, Bd. 2, Nr. 1, S. 39–59, Feb. 1984, doi: [10.1145/2080.357392](https://doi.org/10.1145/2080.357392).
- [2] „A Note on Distributed Computing | Jim Waldo“. Zugegriffen: 28. September 2026. [Online]. Verfügbar unter: <https://waldo.scholars.harvard.edu/publications/note-distributed-computing>
- [3] „Distributed Systems 3rd Edition (2017) – DISTRIBUTED-SYSTEMS.NET“. Zugegriffen: 28. September 2026. [Online]. Verfügbar unter: <https://www.distributed-systems.net/index.php/books/ds3/>
- [4] „(PDF) Pattern-oriented Software Architecture“. Zugegriffen: 28. September 2026. [Online]. Verfügbar unter: https://www.researchgate.net/publication/228722744_Pattern-oriented_software_architecture
- [5] E. Gamma, *Design Patterns: Elements of Reusable Object-Oriented Software*. Pearson Education, 1995.
- [6] „About the Common Object Request Broker Architecture Specification Version 3.4“. Zugegriffen: 28. September 2026. [Online]. Verfügbar unter: <https://www.omg.org/spec/CORBA/3.4/About-CORBA>
- [7] „Java Development Kit Version 17 API Specification“. Zugegriffen: 28. September 2026. [Online]. Verfügbar unter: <https://docs.oracle.com/en/java/javase/17/docs/specs/rmi/index.html>
- [8] C. Bormann, M. Ersue, und A. Keranen, „Terminology for Constrained-Node Networks“, Request for Comments RFC7228, Mai 2014. doi: [10.17487/RFC7228](https://doi.org/10.17487/RFC7228).
- [9] „MicroPython - Python for Microcontrollers“. Zugegriffen: 28. September 2026. [Online]. Verfügbar unter: <https://micropython.org/>
- [10] NXP Semiconductors, „I2C-Bus Specification and User Manual“, UM10204 Rev. 7.0, Okt. 2021. [Online]. Verfügbar unter: <https://www.nxp.com/docs/en/user-guide/UM10204.pdf>
- [11] „Mct.de: SPI - Serial Peripheral Interface“. Zugegriffen: 7. August 2026. [Online]. Verfügbar unter: <https://web.archive.org/web/20190116220910/http://www.mct.de/faq/spi.html>
- [12] „MODBUS Application Protocol Specification V1: Overview & Function Codes“. Zugegriffen: 28. September 2026. [Online]. Verfügbar unter: <https://www.studocu.com/de/document/universitat-duisburg-essen/advanced-mobile-communications/modbus-application-protocol-v1-1b3-2021/109806380>
- [13] „CICS Transaction Server for z/OS“. Zugegriffen: 7. August 2026. [Online]. Verfügbar unter: <https://www.ibm.com/docs/en/cics-ts/5.5.0?topic=rpc-onc-concepts>
- [14] S. Microsystems, „RPC: Remote Procedure Call Protocol Specification“, Request for Comments RFC1050, Apr. 1988. doi: [10.17487/RFC1050](https://doi.org/10.17487/RFC1050).
- [15] R. Thurlow, „RPC: Remote Procedure Call Protocol Specification Version 2“, Request for Comments RFC5531, Mai 2009. doi: [10.17487/RFC5531](https://doi.org/10.17487/RFC5531).
- [16] „JSON-RPC 2.0 Specification“. Zugegriffen: 4. August 2026. [Online]. Verfügbar unter: <https://www.jsonrpc.org/specification>
- [17] „gRPC“. Zugegriffen: 4. August 2026. [Online]. Verfügbar unter: <https://grpc.io/>
- [18] T. Bray, „The JavaScript Object Notation (JSON) Data Interchange Format“, Request for Comments RFC8259, Dez. 2017. doi: [10.17487/RFC8259](https://doi.org/10.17487/RFC8259).
- [19] „MessagePack: It's like JSON. but Fast and Small“. Zugegriffen: 4. August 2026. [Online]. Verfügbar unter: <https://msgpack.org/>
- [20] C. Bormann und P. E. Hoffman, „Concise Binary Object Representation (CBOR)“, Request for Comments RFC8949, Dez. 2020. doi: [10.17487/RFC8949](https://doi.org/10.17487/RFC8949).

-
- [21] „CBOR — Concise Binary Object Representation | Overview“. Zugegriffen: 7. August 2026. [Online]. Verfügbar unter: <https://cbor.io/>
 - [22] „Protocol Buffers“. Zugegriffen: 4. August 2026. [Online]. Verfügbar unter: <https://protobuf.dev/>
 - [23] „Nanopb — Zephyr Project Documentation“. Zugegriffen: 4. August 2026. [Online]. Verfügbar unter: <https://docs.zephyrproject.org/latest/services/serialization/nanopb.html>
 - [24] „Firmata/Arduino“. Zugegriffen: 4. August 2026. [Online]. Verfügbar unter: <https://github.com/firmata/arduino>
 - [25] „MQTT - The Standard for IoT Messaging“. Zugegriffen: 4. August 2026. [Online]. Verfügbar unter: <https://mqtt.org/>
 - [26] „DIN Media Standards Solutions“. Zugegriffen: 28. September 2026. [Online]. Verfügbar unter: <https://www.dinmedia.de/en/mechanical-engineering/BVFR020>
 - [27] „CANopen“. Zugegriffen: 28. September 2026. [Online]. Verfügbar unter: <https://www.can-cia.org/can-knowledge/canopen>
 - [28] Z. Shelby, K. Hartke, und C. Bormann, „The Constrained Application Protocol (CoAP)“, Request for Comments RFC7252, Juni 2014. doi: [10.17487/RFC7252](https://doi.org/10.17487/RFC7252).
 - [29] C. Bormann und Z. Shelby, „Block-Wise Transfers in the Constrained Application Protocol (CoAP)“, Request for Comments RFC7959, Aug. 2016. doi: [10.17487/RFC7959](https://doi.org/10.17487/RFC7959).
 - [30] „leJOS / EV3 Wiki / UART Sensor Protocol“. Zugegriffen: 28. September 2026. [Online]. Verfügbar unter: <https://sourceforge.net/p/lejos/wiki/UART%20Sensor%20Protocol/>
 - [31] „PUPRemote Documentation — Anton's Mindstorms Docs Documentation“. Zugegriffen: 7. August 2026. [Online]. Verfügbar unter: <https://docs.antonsmindstorms.com/en/latest/Software/PUPRemote/docs/index.html>
 - [32] „Handlungsorientiertes Lernen“. Zugegriffen: 7. August 2026. [Online]. Verfügbar unter: <https://education.lego.com/de-de/>
 - [33] STMicroelectronics, „STM32F413xG/STM32F413xH Datasheet: ARM Cortex-M4 32b MCU+FPU, 125 DMIPS, up to 1.5 MB Flash, 320 KB RAM“, DS11581 Rev. 4, 2018. [Online]. Verfügbar unter: <https://www.st.com/resource/en/datasheet/stm32f413cg.pdf>
 - [34] „Lego::Lab Karlsruhe“. Zugegriffen: 7. August 2026. [Online]. Verfügbar unter: <https://legolab-karlsruhe.de/mindstorms/spikeprime>
 - [35] ILI Technology Corp., „ILI9341: A-Si TFT LCD Single Chip Driver, 240rgbx320 Resolution and 262K Color“, Version1.11, 2011. [Online]. Verfügbar unter: <https://cdn-shop.adafruit.com/datasheets/ILI9341.pdf>
 - [36] FocalTech Systems, „FT6x06: Self-capacitive Touch Panel Controller“, Version0.1, 2014. [Online]. Verfügbar unter: https://cdn-shop.adafruit.com/datasheets/FT6x06+Datasheet_V0.1_Preliminary_20120723.pdf
 - [37] „LVGL — Light and Versatile Embedded UI Ecosystem“. Zugegriffen: 7. August 2026. [Online]. Verfügbar unter: <https://lvgl.io/>
 - [38] „LMS-ESP32 v2.0: The Clever Wi-Fi and Gamepad Board for LEGO SPIKE“. Zugegriffen: 7. August 2026. [Online]. Verfügbar unter: <https://www.antonsmindstorms.com/product/powerful-lms-esp32-board-for-spike-and-mindstorms/>
 - [39] R. B. Miller, „Response Time in Man-Computer Conversational Transactions“, *Proceedings of the December 9-11, 1968, fall joint computer conference, part I on - AFIPS '68 (Fall, part I)*, S. 267, 1968, doi: [10.1145/1476589.1476628](https://doi.org/10.1145/1476589.1476628).
 - [40] S. K. Card, T. P. Moran, und A. Newell, *The Psychology of Human-Computer Interaction*. Hillsdale, N.J. : L. Erlbaum Associates, 1983. Zugegriffen: 28. September 2026. [Online]. Verfügbar unter: <http://archive.org/details/psychologyofhuma00stua>
 - [41] L. Valk, „Pybricks“. Zugegriffen: 28. September 2026. [Online]. Verfügbar unter: <https://pybricks.com/>

- [42] „Core Specification“. Zugegriffen: 28. September 2026. [Online]. Verfügbar unter: <https://www.bluetooth.com/specifications/specs/core-specification-5-4/>
- [43] „(PDF) Pattern-Oriented Software Architecture: Patterns for Concurrent and Networked Objects, Volume 2“. Zugegriffen: 28. September 2026. [Online]. Verfügbar unter: https://www.researchgate.net/publication/215835789_Pattern-Oriented_Software_Architecture_Patterns_for_Concurrent_and_Networked_Objects_Volume_2
- [44] A. S. Tanenbaum und D. Wetherall, *Computernetzwerke*, 5., aktualisierte Auflage. in Always learning. München [u.a.]: Pearson, 2012.
- [45] „How Encapsulation Works Within the TCP/IP Model : Learn-Networking.Com“. Zugegriffen: 1. September 2026. [Online]. Verfügbar unter: <https://web.archive.org/web/20120807024653/http://learn-networking.com/tcp-ip/how-encapsulation-works-within-the-tcpip-model>
- [46] „RFC 9110: HTTP Semantics | RFC Editor“. Zugegriffen: 28. September 2026. [Online]. Verfügbar unter: <https://www.rfc-editor.org/info/rfc9110/>
- [47] „ILI9341 LCD Controller Driver | LVGL Open“. Zugegriffen: 23. September 2026. [Online]. Verfügbar unter: https://lvgl.io/docs/open/integration/external_display_controllers/ili9341
- [48] „Cse.Yorku.ca/~oz/Hash.Html“. Zugegriffen: 28. September 2026. [Online]. Verfügbar unter: <http://www.cse.yorku.ca/~oz/hash.html>
- [49] Niklas, „Bitsquid: Development Blog: Managing Decoupling Part 4 – The ID Lookup Table“. Zugegriffen: 28. September 2026. [Online]. Verfügbar unter: <https://bitsquid.blogspot.com/2011/09/managing-decoupling-part-4-id-lookup.html>
- [50] „Lvgl/Lv_binding_micropython“. Zugegriffen: 28. September 2026. [Online]. Verfügbar unter: https://github.com/lvgl/lv_binding_micropython
- [51] „Timer (Lv_timer) | LVGL Open“. Zugegriffen: 28. September 2026. [Online]. Verfügbar unter: <https://lvgl.io/docs/open/main-modules/timer>
- [52] „Tools – General Purpose Tools — Pybricks v4.1.0b1 Documentation“. Zugegriffen: 28. September 2026. [Online]. Verfügbar unter: <https://docs.pybricks.com/en/latest/tools/index.html>

Anhang

```

from pybricks.parameters import Button, Color, Direction, Port, Side, Stop
from pupremote import PUPRemoteHub
from pybricks.tools import wait, Stopwatch

from pybricks_bundle import *

p = PUPRemoteHub(Port.A)

interceptor = PyBricksInterceptor(p)
interceptor.register_interceptor()

display = Display(interceptor)

display.clear()

info = display.display_info()
print(info)

# --- Aufbau -----
# Display elements live on a screen, so one has to exist and be shown before
# anything can be placed on it. The second screen is created but not shown.
main_screen = display.create_screen(set_active=True, name="main")
menu_screen = display.create_screen(name="menu")

counter_label = main_screen.create_label(10, 10, 230, 20, "Counter: 0")
menu_label = menu_screen.create_label(10, 10, 230, 20, "Menue")

# Captions without umlauts: the default font of the display library carries a
# reduced set of glyphs, and a missing one is drawn as a placeholder box.
to_menu = main_screen.create_button(10, 60, 100, 40, "Menue")
to_main = menu_screen.create_button(10, 60, 100, 40, "Zurueck")

# --- Bindings -----
# Declared once, here. From now on a press switches the screen on the display
# unit itself. Each of these two calls costs the usual number of transfers -
# once. Every switch afterwards costs none.
to_menu.on_press(ACT_SHOW_SCREEN, menu_screen)
to_main.on_press(ACT_SHOW_SCREEN, main_screen)

print("bindings declared")

# --- Ablauf -----
counter = 0

while True:
    counter_label.set_text("Counter: {}".format(counter))
    counter += 1

    # The screen has already changed by the time this query happens - the
    # binding did that. What arrives here is the notification, not the trigger.
    # Polling both buttons costs one round trip each; leaving it out would not
    # affect the switching at all.
    if to_menu.is_button_pressed():
        print("menu opened")

    if to_main.is_button_pressed():
        print("back on the main screen")

    wait(1000)

```

Listing 9: Beispielprogramm auf dem Hub

60